

MARMARA ÜNİVERSİTESİ • TEKNOLOJİ FAKÜLTESİ

Bilgisayar Mühendisliği Bölümü • Bitirme Projesi

Bal Arısı Kolonilerinde Varroa Paraziti Tespiti

Geleneksel ML, CNN ve Transformer Tabanlı Yaklaşımların Karşılaştırmalı Analizi

ÖĞRENCİLER

Ömer Faruk Akçay
Gökdeniz Şeker
Doğukan Özek

DANIŞMAN

Doç. Dr. Ayşe Berna Altınel Girgin



Problem

Varroa destructor, küresel arıcılığı tehdit eden en yıkıcı ektoparazittir. Etkisiz veya geç müdahale koloni çöküşüne yol açar.

Biyolojik Tehdit

- Arıların hemolenf ve yağ dokularından beslenir.
- Bağışıklık sistemini zayıflatır.
- Viral hastalıkların yayılımını hızlandırabilir.

Mevcut Yöntemlerin Sınırları

- Manuel sayım zaman alıcıdır.
- Kullanıcı hatasına açıktır.
- Alkol yıkama gibi yöntemler arılara zarar verebilir.



Projenin Amacı, Katkısı ve Yaklaşımı

Bu çalışma, Varroa tespiti yalnızca bir sınıflandırma problemi olarak değil; küçük nesne tespiti, veri seti genellenebilirliği ve model aileleri karşılaştırması problemi olarak ele almaktadır.

01 Hedefler

- Varroa paraziti görüntüler üzerinden tespit etmek
- Problemi hem sınıflandırma hem nesne tespiti olarak ele almak
- Geleneksel ML, CNN/YOLO ve Transformer yaklaşımlarını karşılaştırmak

02 Akademik Katkı

- Bağımsız dış test seti ile gerçekçi başarı ölçümü
- Veri seti seçiminin model başarısına etkisi
- Küçük nesne tespitinde model ailelerinin karşılaştırılması

03 Yaklaşım

- 3 veri seti: bağlamsal, morfolojik, external
- Veri seti etkisi ve genellenebilirlik analizi
- Ortak metriklerle karşılaştırmalı değerlendirme

Literatür İncelemesi

9 akademik çalışma; kullanılan yöntem, veri yapısı ve uygulama ortamı açısından incelenmiştir.

Derin Öğrenme Tabanlı

YOLO, Faster R-CNN ve SSD gibi derin öğrenme tabanlı nesne tespit modelleriyle arı görüntüleri üzerinde Varroa tespiti yapılmıştır.

YÖNTEMLER

YOLO ailesi • Faster R-CNN / SSD • CNN tabanlı nesne tespiti

Yüksek doğruluk potansiyeli sunar; ancak veri kalitesi ve etiket tutarlılığına duyarlıdır.

Donanım ve Sensör Tabanlı

Kovan girişlerine veya izleme düzeneklerine kamera sistemleri yerleştirilerek sürekli koloni takibi yapılmıştır.

YÖNTEMLER

Kovan girişi izleme • Çok bantlı görüntüleme • Raspberry Pi / mobil sistemler

Gerçek zamanlı izleme potansiyeli sunar; ancak ışık, kamera açısı ve saha kurulumu kritik hale gelir.

Görüntü İşleme ve Hibrit Yaklaşımlar

Renk, şekil, segmentasyon ve el yapımı görsel özellikler kullanılarak Varroa tespiti veya sayımı yapılmıştır.

YÖNTEMLER

HSV / Hough • Segmentasyon • PCA + kNN + SVM

Daha yorumlanabilir ve düşük veri koşullarında avantajlıdır; ancak genellikle el yapımı özelliklere bağımlıdır.



Veri Seti Stratejisi

Üç katmanlı veri yapısı: iki geliştirme seti ve eğitim/model seçimine dahil edilmeyen bağımsız dış test seti.

Rol	Veri Seti	Varroasız	Varroalı	Toplam	Açıklama
Bağlamsal Öğrenme (Geliştirme)	Varroa Dataset	9,155	4,337	13,492	Arı + Varroa birlikte etiketli
Morfolojik Odaklı (Geliştirme)	HoneyBee VarroaMite	5,115	9,079	14,194	Yalnızca Varroa etiketleri
Bağımsız Dış Test (Dış Test)	Varroa Mites Detector	3,791	2,147	5,938	Eğitimden tamamen ayrı
TOPLAM				33,624	



DeneySEL Pipeline

Farklı model aileleri, kendi veri hazırlama süreçleriyle eğitilmiş; internal ve external validation üzerinden sistematik biçimde karşılaştırılmıştır.



Hem Sınıflandırma Hem Tespit

Sınıflandırma: var/yok kararı. Nesne tespiti: parazitin konumu.
İkisi ayrı modeller ve metriklerle değerlendirildi.

Üç Veri Seti Stratejisi

İki geliştirme seti (bağlamsal + morfolojik), bir bağımsız dış test seti.

Adil Karşılaştırma

Model aileleri, görev türüne uygun metriklerle ve aynı internal/external değerlendirme mantığıyla karşılaştırıldı.



Karşılaştırılan Üç Model Ailesi

Üç model ailesi; sınıflandırma, nesne tespiti ve genellenebilirlik açısından karşılaştırılmıştır.

Geleneksel ML

El yapımı özellikler

MODELLER

- SVM (Linear / RBF)
- Random Forest

TEKNİK

- HOG, HSV, LBP, PCA
- Patch tabanlı sınıflandırma
- Sliding-window tespit

CNN & YOLO

Derin öğrenme

MODELLER

- ResNet18
- EfficientNet-B0
- YOLOv8n
- YOLOv26n

TEKNİK

- Transfer learning
- 224×224 / 640×640 giriş
- End-to-end öğrenme

Transformer

Dikkat mekanizması

MODELLER

- DETR
- Deformable DETR
- RT-DETR

TEKNİK

- Global attention
- Çok ölçekli özellik
- Anchor-free tespit



ML: Veri Hazırlama ve Özellik Mühendisliği

Geleneksel ML hattında görüntü bölgeleri pozitif/negatif patch örnekleri olarak tanımlanmış ve bu bölgelerden el yapımı özellikler çıkarılmıştır.

Patch Stratejisi ve Sliding-Window

- Her veri seti için 2 denge $\times$ 3 bölge boyutu $\times$ 13 özellik kombinasyonu denendi.
- Toplamda 156 Linear SVM modeliyle geniş bir tarama yapıldı.
- Seçilen 18 kombinasyon, RBF SVM ve Random Forest ile detaylandırıldı.
- Kayan pencere ile tam görüntü üzerinde aday tespit kutuları üretildi.
- Çakışan adaylar birleştirme/filtreleme ile nihai kutulara dönüştürüldü.

Çıkarılan Özellikler

HOG	Kenar ve gradyan yönleri — şekil tanıma
HSV	Renk dağılımı — kahverengi Varroa tonu
LBP	Doku örüntüsü — yüzey yapısı
PCA	Boyut indirgeme — maliyet/gürültü azaltma

Linear SVM

Düşük maliyetli ön tarama

RBF SVM

Doğrusal olmayan, kernel tabanlı

Random Forest

Karar ağaçları topluluğu


Güçlü yön: Görüntü bölgesi düzeyinde yorumlanabilir ve düşük maliyetli sınıflandırma sağlar.

Sınırlılık: Tam görüntü tespitinde kayan pencere, çok sayıda aday pencere ve yanlış pozitif nedeniyle performans kaybına yol açabilir.



SVM ve Random Forest Sonuçları

Sınıflandırma sonuçları F1-score ile, kayan pencere tabanlı nesne tespiti ise IoU tabanlı F1 metriğiyle değerlendirilmiştir.



Not: RF / Varroa modeli internal sınıflandırmada 0.92 F1 ile başarılı olmuş, ancak final external/detection aşamasına taşınmamıştır.

BULGULAR

0.94 External F1

SVM / Varroa Dataset, external validation'da en güçlü sınıflandırma sonucunu verdi.

Öne Çıkan Kombinasyonlar

Sınıflandırmada HOG16 + HSV + LBP, detection/external aşamalarında ise HOG16 + PCA + HSV + LBP kombinasyonları öne çıktı.

Kayan Pencere Sınırı

Yüksek sınıflandırma başarısı, tam görüntüde konum belirleme başarısına doğrudan yansımadı.

Detection:

SVM ext. F1@IoU0.20 = 0.43

RF ext. F1@IoU0.20 = 0.23



CNN: Veri Hazırlığı ve Görev Ayrımı

CNN modelleri iki ayrı görev için hazırlanmıştır: binary sınıflandırma ve bounding-box tabanlı nesne tespiti.

Sınıflandırma Görevi

- Görüntü düzeyinde etiket: Varroa var (1) / yok (0).
- Binary cross-entropy loss ile eğitim.
- ResNet18 ve EfficientNet-B0 transfer learning ile.
- Son katman freeze + fine-tune stratejisi.

Augmentation

Yatay/dikey çevirme, rastgele kırpma, renk jitter, rotasyon.

Nesne Tespiti Görevi (YOLO)

- YOLO formatı: class cx cy w h (normalize edilmiş).
- XML → YOLO format dönüşümü yapılmıştır.
- 640×640 giriş; multi-scale training.
- Train/val/test split ile stabiliite sağlandı.

Görev Ayrımının Önemi

Sınıflandırma 'var mı?'; nesne tespiti 'nerede?' sorusunu yanıtlar. Ayrı modeller ve metrikler kullanıldı.



CNN Sınıflandırma: ResNet18 ve EfficientNet-Bo

ImageNet ağırlıklarıyla önceden eğitilmiş iki CNN mimarisi Varroa sınıflandırmasına uyarlanmıştır.

ResNet18

Residual Network

- 18 katmanlı derin artık bağlantı mimarisi.
- Skip connection'lar degradation sorununu çözer.
- Hafif yapısıyla hızlı eğitim ve çıkarım.
- Son FC katmanı 2 sınıf için yeniden eğitildi.

Transfer Learning Stratejisi

ImageNet ağırlıkları freeze edilib son katman eğitildi; ardından tüm ağ düşük LR ile fine-tune edildi.

EfficientNet-Bo

Compound Scaling

- Derinlik, genişlik ve çözünürlüğü dengeli ölçekler.
- Daha az parametre ile yüksek doğruluk hedeflenir.
- MBConv blokları depthwise separable conv kullanır.
- B0 versiyonu: hafif ama rekabetçi başarı.


Transfer Learning Stratejisi

ImageNet ağırlıkları freeze edilib son katman eğitildi; ardından tüm ağ düşük LR ile fine-tune edildi.



CNN Sınıflandırma Sonuçları (F1-score)

EfficientNet-B0 external validation'da CNN ailesinin en dengeli sonucunu vermiştir.



BULGULAR

0.85

EfficientNet-B0 external F1 — CNN ailesinde en güçlü genelleme.

%90.05

EfficientNet-B0 external accuracy.

Veri seti etkisi

HoneyBee ile eğitilen EfficientNet external'da düşerken Varroa Dataset versiyonu stabil kaldı.



YOLO Tabanlı Nesne Tespiti: Eğitim ve Metrikler

YOLOv8n ve YOLOv26n modelleri end-to-end nesne tespiti için eğitilmiştir. Değerlendirme mAP50 ve mAP50-95 ile yapıldı.

Eğitim Konfigürasyonu

- Giriş boyutu: 640×640 piksel.
- Epoch: 30— early stopping ile overfitting önlemi.
- Optimizer: AdamW, cosine LR scheduler.
- Augmentation: mosaic, mixup, flip, HSV shift.
- Pretrained COCO ağırlıklarıyla transfer learning.

Değerlendirme Metrikleri

Precision	Tespit edilen kutular içinde gerçekten Varroa olanlar.
Recall	Gerçek Varroa örnekleri içinde tespit edilenler.
mAP50	IoU≥0.50'de ortalama precision. Temel tespit metriği.
mAP50-95	IoU 0.50–0.95 arasında daha katı değerlendirme.

YOLOv8n

Nano — hız odaklı, rekabetçi doğruluk.

YOLOv26n

Güncel mimari; derin feature pyramid.


2 Veri Seti

Her model Varroa Dataset ve HoneyBee ile eğitildi.



YOLO Sonuçları: mAP50 ve External Düşüş

YOLO modelleri internal'da güçlü sonuçlar üretirken external'da belirgin performans düşüşü yaşandı.



GÖZLEMLER

0.629

YOLOv8n (Varroa) — YOLO ailesinde external zirvesi.

HoneyBee etkisi

HoneyBee ile eğitimde external dramatik düşüş: 0.82 → 0.24.

Genelleme sorunu

Veri seti dağılım farkı YOLO'yu ciddi etkiledi. Transformer bu düşüşü daha iyi absorbe edecek.



CNN / YOLO: Güçlü ve Zayıf Yönler

Derin öğrenme ailesinin güçlü ve zayıf yönleri; transformer mimarileriyle karşılaştırma zemini hazırlanıyor.

✓ Güçlü Yönler

Transfer Learning

ImageNet ağırlıkları sınırlı veriyle güçlü başlangıç sağladı.

Hızlı Çıkarım

YOLO gerçek zamanlı tespit için uygun; düşük gecikme.

Augmentation

Mosaic ve mixup YOLO'nun küçük veri uyumunu artırdı.

EfficientNet Dengesi

Az parametre ile yüksek sınıflandırma başarısı.

✗ Zayıf Yönler / Kısıtlar

Küçük Nesne Zorluğu

Varroa görüntüde çok küçük alan kaplar; YOLO zorlanır.

Veri Setine Bağımlılık

HoneyBee eğitiminde external mAP50 dramatik düştü.

Lokal Dikkat Sınırı

CNN'ler global bağlam bilgisini zayıf yakalar.

mAP50-95 Düşüklüğü

Konum hassasiyeti IoU>0.75 eşiklerinde belirgin azaldı.



Transformer Yaklaşımı: DETR Ailesi

Transformer mimarileri, dikkat mekanizmasıyla global bağlamı yakalayarak küçük nesne tespitinde CNN'lere avantaj sağlar.

Neden Transformer?

CNN'ler yerel alıcı alanlarla özellik çıkarır. Transformer'lar ise self-attention ile görüntünün tüm bölgeleri arasındaki ilişkileri aynı anda modelleyebilir — küçük ve kamufleli nesnelerde bu avantaj belirleyici olabilir.

DETR

Detection Transformer (2020)

- CNN backbone + Transformer encoder-decoder.
- Bipartite matching ile anchor-free tespit.
- Uzun eğitim süresi, basit mimari.

Deformable DETR

Multi-Scale Deformable Attention

- Her token yalnızca seçili referans noktalara dikkat eder.
- Hesaplama maliyeti düşer, yakınsama hızlanır.
- Çok ölçekli özellik haritaları kullanır.

RT-DETR

Real-Time Detection Transformer

- HybridEncoder: CNN + Transformer hibrit yapısı.
- IoU-aware sorgu seçimi ile verimli decoder.
- En güçlü external genelleme performansı.

★ *Projenin en başarılı tespit modeli.*



Deformable DETR ve RT-DETR: Teknik Detaylar

İki modelin mimari tercihleri ve Varroa tespitindeki önemi incelenmektedir.

Deformable DETR

Multi-Scale Deformable Attention

Her sorgu, birden fazla ölçek haritasındaki seçili referans noktalara odaklanır.

Seyrek Dikkat Avantajı

Klasik DETR'de $O(n^2)$ dikkat maliyeti büyük ölçüde azaltılır; 10x hız kazanımı.

Küçük Nesne Uyumu

Farklı ölçeklerdeki feature map'ler sayesinde mikro nesneler daha iyi temsil edilir.

External mAP₅₀ = 0.698

RT-DETR'den hafif düşük ama YOLO ailesini belirgin biçimde geçer.

★ RT-DETR

HybridEncoder

CNN ile Transformer encoder hibridlenerek hem yerel hem global özellikler yakalanır.

IoU-aware Sorgu Seçimi

Yalnızca güçlü aday bölgeler decoder'a iletilir; gereksiz hesaplama engellenir.

Gerçek Zamanlı Hız

DETR ailesi içinde en düşük gecikme — saha uygulamaları için kritik.


External mAP₅₀ = 0.712

Projenin nesne tespitindeki en yüksek external skoru.



Transformer Sonuçları (mAP50)

Transformer modelleri YOLO'ya kıyasla daha dengeli ve yüksek external performans sergiledi.



★ EN BAŞARILI

RT-DETR

Real-Time Detection Transformer

%71.20

external mAP50

Internal→External

0.815→0.712 — yalnızca 0.10 düşüş. YOLO'nun HoneyBee düşüşüyle kıyaslandığında üstün genelleme.

Projenin genel nesne tespiti şampiyonu.



Transformer Yorumu: Küçük Nesne ve Attention Avantajı

Transformer'ların Varroa tespitindeki başarısı dikkat mekanizmasının küçük nesne geometrisini nasıl yakaladığıyla açıklanmaktadır.

Küçük Nesne Tespitinin Zorluğu

- Varroa, toplam görüntünün %0.1'inden küçük alan kaplar.
- Arı tüyleri ve renk benzerliği görsel kamuflaj oluşturur.
- CNN feature pyramid'ı derin katmanlarda uzamsal bilgi kaybeder.
- YOLO'nun anchor mekanizması küçük nesneler için suboptimal kalır.
- mAP50-95 tüm modellerde belirgin düşüş yaşamıştır.

Attention Mekanizmasının Avantajı

Global Bağlam

Görüntünün her iki ucundaki pikseller arasındaki ilişkiyi tek işlemde kurar.

Çok Ölçekli Temsil

Farklı çözünürlükteki feature map'lerden eş zamanlı bilgi toplanır.

Küçük Nesne Odağı

Seyrek dikkat mekanizması Varroa'nın bulunduğu bölgelere seçici odaklanır.

Anchor-Free

Bounding box tahminleri önceden tanımlı anchor'lara bağlı değil — küçük boyutlarda esnek.



Tüm Model Ailelerinin Genel Karşılaştırması

Görev türüne ve metriğe göre her ailenin güçlü olduğu koşullar farklılaşmaktadır.

SINIFLANDIRMA ŞAMPİYONU

SVM

F1 = 0.94
(external)

El yapımı HOG/HSV/LBP özellikleriyle mükemmel genelleme.

★ NESNE TESPİTİ ŞAMPİYONU

RT-DETR

mAP50 = 0.712
(external)

Çok ölçekli attention ile projenin en güçlü genellemesi.

Model Ailesi	Sınıflandırma F1 (ext.)	Tespit mAP50 (ext.)	Güçlü Yön	Kısıt
Geleneksel ML (SVM)	0.94	0.43 (F1@IoU0.20)	Yorumlanabilir	Sliding-window yavaş
CNN — EfficientNet-B0	0.85	—	Transfer learning	Lokal bağlam sınırı
CNN — YOLOv8n	—	0.629	Hızlı, end-to-end	HoneyBee'de düşüş
Transformer — RT-DETR	—	0.712 ★	En güçlü genelleme	Hesaplama maliyeti

Bulgular ve Tartışma

01

Veri seti seçimi mimari kadar önemli

Varroa Dataset üzerinde eğitilen tüm modeller external'da daha dengeli kaldı. HoneyBee bazı modellerde dramatik düşüşe neden oldu.

02

Internal validation yanıltıcı olabilir

Yüksek internal skor gerçekçi başarıyı garanti etmez. External validation her değerlendirme protokolünde zorunludur.

03

Görev türü model seçimini belirler

Var/yok kararı için SVM ve EfficientNet-B0; konum belirleme için RT-DETR ve Deformable DETR en güçlü seçeneklerdir.

04

Transformer küçük nesnede öne çıkıyor

Global attention ve çok ölçekli temsil, Varroa'nın mikro ölçekli yapısıyla başa çıkmada CNN'lere belirgin üstünlük sağladı.

05

Küçük nesne tespiti hâlâ zorlu

mAP50-95 değerleri mAP50'ye göre tüm modellerde ciddi düşüş yaşadı; konum hassasiyeti geliştirilmesi gereken ana boyuttur.

06

Geleneksel yöntemler rekabetçi

SVM, klasik özellik mühendisliğiyle sınıflandırmada en yüksek external F1'i elde etti. Yorumlanabilirlik ve düşük maliyet avantajı sürüyor.

Genel çıkarım: Model başarısı mimari seçiminden bağımsız değildir — veri seti yapısı, anotasyon kalitesi ve external validation en az mimari kadar belirleyicidir.



Sonuç ve Gelecek Çalışmalar

ÇALIŞMANIN SONUCU

Varroa parazitinin otonom tespiti için YZ tabanlı yöntemler ümit verici sonuçlar üretmektedir.

- RT-DETR, external mAP50 = 0.712 ile en güçlü tespit modeli.
- SVM, F1 = 0.94 ile sınıflandırmada mükemmel genelleme.
- EfficientNet-B0 dengeli ve pratik bir CNN alternatifi oldu.
- External validation modelin gerçek değerini ortaya koydu.
- Veri seti seçimi model başarısında mimari kadar belirleyici.

GELECEK ÇALIŞMALAR

01 Genişletilmiş Veri Seti

Farklı kamera, ışık ve arı pozisyonlarını kapsayan çeşitli veri toplama.

02 Etiket Kalitesi

Uzman apiculturist doğrulamasıyla bounding box güvenilirliğinin artırılması.

03 Model Optimizasyonu

Hiperparametre araması, ensemble ve knowledge distillation.

04 Saha Entegrasyonu

Web/mobil arayüz ve gerçek kovan koşullarında doğrulama.

Teşekkürler

Ömer Faruk Akçay

Geleneksel ML

Gökdeniz Şeker

CNN & YOLO

Doğukan Özek

Transformer

Danışmanımız Doç. Dr. Ayşe Berna Altınel Girgin'e rehberliği süreç boyunca verdiği destek için içtenlikle teşekkür ederiz.