



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Bal Arısı Kolonilerinde Varroa Parazitinin Tespiti

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Doç. Dr. Ayşe Berna Altınel Girgin

İSTANBUL, 2026



Teknoloji Fakültesi

MARMARA ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri
Gökdeniz Şeker, Doğukan Özek, Ömer Faruk Akçay tarafından “**Bal Arısı**
Kolonilerinde Varroa Parazitinin Tespiti” başlıklı proje çalışması, 11.06.2026
tarihinde savunulmuş ve jüri üyeleri tarafından başarılı bulunmuştur.

Jüri Üyeleri

Doç.Dr. Ayşe Berna Altınel Girgin
Marmara Üniversitesi
Prof. Dr. Şahin Uyaver
Marmara Üniversitesi
Dr. Öğr. Üyesi Neşe Özdemir
Marmara Üniversitesi
Arş. Gör. Dr. Merve Pınar
Marmara Üniversitesi

(Danışman)

(Üye)

(Üye)

(Üye)

(İMZA).....

(İMZA).....

(İMZA).....

(İMZA).....

ÖNSÖZ

Proje çalışmamız süresince karşılaştığım bütün problemlerde, sabırla yardım ve bilgilerini esirgemeyen, tüm desteğini sonuna kadar yanımda hissettiğim değerli hocalarım, sayın Doç. Dr. Ayşe Berna Altınel Girgin ve sayın Arş. Gör. Nursaç Kurt' a en içten teşekkürlerimi sunarım.

Bu proje çalışması fikrinin oluşması ve ortaya çıkmasındaki önerisi ve desteğinden dolayı değerli hocam Doç. Dr. Ayşe Berna Altınel Girgin' e teşekkür ederim.

Proje çalışmam sırasında maddi ve manevi desteklerini esirgemeyen okul içerisinde ve okul dışında her zaman yanımda olan değerli çalışma arkadaşlarım ve Doç. Dr. Ayşe Berna Altınel Girgin ve Arş. Gör. Nursaç Kurt'a sonsuz teşekkürlerimi sunarım.

İÇİNDEKİLER

1. GİRİŞ	1
1.1. Proje Çalışmasının Amacı ve Önemi	1
2. YAPILAN ÇALIŞMALAR	2
2.1. Proje Kapsamının Netleştirilmesi	2
2.2. Literatür İncelemesi	3
2.2.1. Detection of Varroa Mites from Bee Images Using YOLO Architecture [1]	3
2.2.2. A Computer Vision System to Monitor The Infestation Level of Varroa Destructor in Honeybee Colony [2]	4
2.2.3. An AI-Based Open-Source Software for Varroa Mite Fall Analysis in Honeybee Colonies [3]	4
2.2.4. Detection of Varroa mites from honey bee hives by smart technology Var-Gor: a hive monitoring and image processing device [4]	5
2.2.5. Detection of Varroa destructor Infestation of Honeybees Based on Segmentation and Object Detection Convolutional Neural Networks [5]	6
2.2.6. Visual Diagnosis of the Varroa destructor Parasitic Mite in Honeybees Using Object Detector Techniques [6]	6
2.2.7. A Comparative Study of Hybrid Machine-Learning vs. Deep-Learning Approaches for Varroa Mite Detection and Counting [7]	7
2.2.8. Deep Learning Beehive Monitoring System for Early Detection of the Varroa Mite [8]	8
2.2.9. Deep Learning for Real-Time Varroa Destructor Monitoring [9]	8
2.3. Teknik Planlama	9
3. DENEYSEL ÇALIŞMALAR VE MODEL GELİŞTİRME SÜRECİ	10
3.1. Deneysel Sürecin Genel Özeti	11
3.2. Model Ailelerinin Uygulanabilirlik Açısından Değerlendirilmesi	12
3.3. Veri Setlerinin Deneysel Sürece Hazırlanması	13
3.4. Internal Validation ve External Validation Yaklaşımı	14
4. KULLANILAN VERİ SETLERİ VE ÖN İŞLEME ADIMLARI	15

4.1. Varroa Dataset Veri Setinin Hazırlanması	15
4.1.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Hazırlık	15
4.1.2. CNN Tabanlı Modeller İçin Hazırlık	16
4.1.3. Transformer Tabanlı Modeller İçin Hazırlık	17
4.2. HoneyBee VarroaMite Veri Setinin Hazırlanması	17
4.2.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Hazırlık	18
4.2.2. CNN Tabanlı Modeller İçin Hazırlık	19
4.2.3. Transformer Tabanlı Modeller İçin Hazırlık	19
4.3. Varroa Mites Detector Veri Setinin External Validation İçin Kullanılması	20
4.3.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin External Validation Hazırlığı	20
4.3.2. CNN Tabanlı Modeller İçin External Validation Hazırlığı	21
4.3.3. Transformer Tabanlı Modeller İçin External Validation Hazırlığı	22
4.4. Etiket Yapılarının Düzenlenmesi	22
4.4.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Etiket Düzenleme	23
4.4.2. CNN Tabanlı Modeller İçin Etiket Düzenleme	23
4.4.3. Transformer Tabanlı Modeller İçin Etiket Düzenleme	24
4.5. Classification Deneyleri İçin Binary Veri Yapısının Oluşturulması	24
4.5.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Binary Veri Yapısı	25
4.5.2. CNN Tabanlı Modeller İçin Binary Veri Yapısı	26
4.5.3. Transformer Tabanlı Modeller İçin Binary Veri Yapısı	26
4.6. Veri Seti Dağılımlarının Tablo Halinde Sunulması	26
4.6.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Veri Dağılımı	27
4.6.2. CNN Tabanlı Modeller İçin Veri Dağılımı	28
4.6.3. Transformer Tabanlı Modeller İçin Veri Dağılımı	30
5. MODEL EĞİTİMLERİ	31
5.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller	31

5.1.1. Support Vector Machine (SVM) Modeli	33
5.1.2. Random Forest Modeli	33
5.1.3. Sliding-Window Tabanlı Nesne Tespiti Yaklaşımı	34
5.2. CNN Tabanlı Modeller	35
5.2.1. ResNet Modeli	35
5.2.2. EfficientNet Modeli	36
5.2.3. YOLOv8 Modeli	37
5.2.4. YOLOv26 Modeli	38
5.3. Transformer Tabanlı Modeller	39
5.3.1. DETR Modeli	39
5.3.2. Deformable DETR Modeli	40
6. DENEYSEL KARŞILAŞTIRMA VE DEĞERLENDİRME METRİKLERİ	41
6.1. Sınıflandırma Modellerinde Kullanılan Metrikler	42
6.1.1. Accuracy	42
6.1.2. Precision	42
6.1.3. Recall	43
6.1.4. F1-score	43
6.2. Nesne Tespiti Modellerinde Kullanılan Metrikler	43
6.2.1. Precision	44
6.2.2. Recall	44
6.2.3. F1-score	45
6.2.4. mAP50	45
6.2.5. mAP50-95	45
6.3. Internal Validation Değerlendirme Yapısı	46
6.4. External Validation Değerlendirme Yapısı	47
7. DENEY SONUÇLARI	47
7.1. Geleneksel Makine Öğrenmesi Modellerinin Sonuçları	48
7.1.1. SVM Deney Sonuçları	49

7.1.2. Random Forest Deney Sonuçları	52
7.2. CNN Tabanlı Modellerin Sonuçları	54
7.2.1. ResNet Deney Sonuçları	54
7.2.2. EfficientNet Deney Sonuçları	56
7.2.3. YOLOv8 Deney Sonuçları	57
7.2.4. YOLOv26 Deney Sonuçları	59
7.3. Transformer Tabanlı Modellerin Sonuçları	61
7.3.1. DETR Deney Sonuçları	61
7.3.2. Deformable-DETR Deney Sonuçları	62
7.4. Tüm Modellerin Genel Sonuç Tablosu	65
8. PERFORMANS GRAFİKLERİ VE KARŞILAŞTIRMALI ANALİZ	67
8.1. Geleneksel Makine Öğrenmesi Modellerinin Grafiksel Değerlendirmesi	68
8.1.1. Geleneksel Makine Öğrenmesi Modellerinin Classification F1-score Değerlerine Göre Değerlendirilmesi	68
8.1.2. Geleneksel Makine Öğrenmesi Modellerinin Detection F1-score Değerlerine Göre Değerlendirilmesi	69
8.2. CNN Tabanlı Modellerin Grafiksel Değerlendirmesi	70
8.2.1. YOLO Modellerinin mAP50 Değerlerine Göre Değerlendirilmesi	70
8.2.2. YOLO Modellerinin Recall Değerlerine Göre Değerlendirilmesi	71
8.2.3. YOLO Modellerinin mAP50-95 Değerlerine Göre Değerlendirilmesi	72
8.2.4. YOLO Modellerinin F1-score Değerlerine Göre Değerlendirilmesi	73
8.2.5. Classification Modellerinin F1-score Değerlerine Göre Değerlendirilmesi	74
8.2.6. Classification Modellerinin Recall Değerlerine Göre Değerlendirilmesi	75
8.2.7. Classification Modellerinin External Accuracy Değerlerine Göre Değerlendirilmesi	76
8.3. Transformer Tabanlı Modellerin Grafiksel Değerlendirmesi	77
8.4. Tüm Model Ailelerinin Genel Karşılaştırması	79
8.5. Internal ve External Validation Sonuçlarının Karşılaştırılması	82

9. BULGULAR VE DEĞERLENDİRME	84
9.1. Veri Seti Seçiminin Model Başarısına Etkisi	85
9.2. Model Ailelerinin Genel Performans Karşılaştırması	86
9.3. Internal Validation ve External Validation Arasındaki Farklar	87
9.4. En Başarılı Model veya Model Ailesinin Değerlendirilmesi	89
9.5. Deney Sonuçlarının Proje Hedefleri Açısından Yorumlanması	90
10. SONUÇ VE GELECEK ÇALIŞMALAR	91
10.1. Çalışmanın Genel Sonucu	92
10.2. Elde Edilen Deneysel Kazanımlar	92
10.3. Projenin Mevcut Durumu	93
10.4. Sonraki Aşamada Yapılması Planlanan Çalışmalar	94
11. KAYNAKÇA	95

ÖZET

Bal Arısı Kolonilerinde Varroa Parazitinin Tespiti

Varroa destructor akarı, bal arısı kolonileri için en önemli biyolojik tehditlerden biri olup koloni zayıflamalarına, arı kayıplarına ve arıcılık sektöründe ciddi ekonomik zararlara neden olmaktadır. Geleneksel Varroa tespit yöntemleri genellikle manuel sayım, şeker pudrası testi, alkol banyosu ve yapışkan tabla kontrolü gibi uygulamalara dayanmaktadır. Ancak bu yöntemler zaman alıcı olmaları, kullanıcı hatasına açık olmaları ve bazı durumlarda arılara zarar verebilmeleri nedeniyle modern ve otomatik tespit yaklaşımlarına duyulan ihtiyacı artırmaktadır.

Bu çalışmada, bal arısı görüntüleri üzerinde Varroa parazitinin tespit edilmesine yönelik görüntü işleme ve yapay zekâ tabanlı yöntemler karşılaştırmalı olarak incelenmiştir. Proje kapsamında üç farklı veri seti kullanılmış; veri setleri sınıflandırma ve nesne tespiti görevlerine uygun şekilde ön işleme adımlarından geçirilmiştir. Geleneksel makine öğrenmesi yaklaşımında HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılarak SVM ve Random Forest modelleri eğitilmiş; ayrıca sliding-window tabanlı nesne tespiti uygulanmıştır. Derin öğrenme kapsamında ResNet18, EfficientNet-B0, YOLOv8n ve YOLOv26n modelleri değerlendirilmiş; transformer tabanlı yaklaşımlar kapsamında ise DETR, Deformable DETR ve RT-DETR modelleri kullanılmıştır.

Modellerin başarıları Accuracy, Precision, Recall, F1-score, mAP50 ve mAP50-95 gibi metriklerle değerlendirilmiştir. Deneysel süreçte hem internal validation hem de eğitim sürecinde kullanılmayan bağımsız external validation veri seti kullanılarak modellerin genelleme performansı analiz edilmiştir. Elde edilen sonuçlar, sınıflandırma görevinde geleneksel makine öğrenmesi ve CNN tabanlı modellerin yüksek başarı gösterebildiğini; nesne tespiti görevinde ise özellikle YOLO ve transformer tabanlı modellerin daha etkili sonuçlar sunduğunu göstermiştir. External validation sonuçları, model performansının veri seti dağılımı, görüntü kalitesi, etiket tutarlılığı ve hedef nesnenin küçük boyutlu yapısından önemli ölçüde etkilendiğini ortaya koymuştur.

Bu çalışma, Varroa tespitinde bilgisayarlı görü ve yapay zekâ tabanlı yöntemlerin uygulanabilirliğini göstermekte ve sürdürülebilir arıcılık uygulamaları için temassız,

hızlı ve dijital bir karar destek sistemine temel oluşturabilecek bir yaklaşım sunmaktadır.

Haziran, 2026

Öğrenciler

Gökdeniz Şeker

Ömer Faruk Akçay

Doğukan Özek

ABSTRACT

Detection of Varroa Parasites in Honey Bee Colonies

Varroa destructor mites are among the most significant biological threats to honey bee colonies, causing colony weakening, bee losses, and serious economic damage in apiculture. Traditional Varroa detection methods are generally based on manual counting, powdered sugar tests, alcohol washing, and sticky board monitoring. However, these methods are time-consuming, prone to human error, and may harm bees in some cases. Therefore, there is a growing need for modern and automated detection approaches.

In this study, image processing and artificial intelligence-based methods for detecting Varroa parasites in honey bee images were comparatively investigated. Three different datasets were used within the scope of the project, and these datasets were preprocessed according to classification and object detection tasks. In the traditional machine learning approach, HOG, HSV, LBP, and PCA-based features were extracted, and SVM and Random Forest models were trained. In addition, a sliding-window-based object detection approach was applied. Within the scope of deep learning, ResNet18, EfficientNet-B0, YOLOv8n, and YOLOv26n models were evaluated. Transformer-based approaches, including DETR, Deformable DETR, and RT-DETR, were also examined.

The performances of the models were evaluated using metrics such as Accuracy, Precision, Recall, F1-score, mAP50, and mAP50-95. In the experimental process, both internal validation and an independent external validation dataset that was not used during training were employed to analyze the generalization capability of the models. The results showed that traditional machine learning and CNN-based models can achieve high performance in classification tasks, while YOLO and transformer-based models provide more effective results in object detection tasks. External validation results also demonstrated that model performance is significantly affected by dataset distribution, image quality, annotation consistency, and the small object characteristics of Varroa mites.

This study demonstrates the applicability of computer vision and artificial intelligence-based methods for Varroa detection and provides a technical basis for a contactless, fast, and digital decision-support system that can contribute to sustainable beekeeping practices.

June, 2026

Students

Gökdeniz Şeker

Ömer Faruk Akçay

Doğukan Özek

ŞEKİL LİSTESİ

Şekil 1. Deneysel süreçte izlenen genel model geliştirme ve değerlendirme akışı.	12
Şekil 2. Geleneksel makine öğrenmesi tabanlı Varroa tespit akışı.	33
Şekil 3. Geleneksel ML modellerinin internal ve external classification F1-score karşılaştırması.	68
Şekil 4. Geleneksel ML modellerinin internal ve external detection F1@IoU0.20 karşılaştırması.	69
Şekil 5. YOLO modellerinin internal ve external validation mAP50 karşılaştırması	70
Şekil 6. YOLO modellerinin internal ve external validation recall karşılaştırması	71
Şekil 7. YOLO modellerinin internal ve external validation mAP50-95 karşılaştırması	72
Şekil 8. YOLO modellerinin internal ve external validation F1-score karşılaştırması	73
Şekil 9. Classification modellerinin internal ve external validation F1-score karşılaştırması	74
Şekil 10. Classification modellerinin internal ve external validation recall karşılaştırması	75
Şekil 11. Classification modellerinin external validation accuracy karşılaştırması	76
Şekil 12. Transformer modellerinin precision değerleri.	77
Şekil 13. Transformer modellerinin recall değerleri.	78
Şekil 14. Transformer modellerinin F1-score değerleri.	78
Şekil 15. Transformer modellerinin mAP50 değerleri.	79
Şekil 16. Transformer modellerinin mAP50-95 değerleri.	79
Şekil 17. Model ailelerine göre en iyi external validation sonuçları.	81
Şekil 18. Classification modellerinin internal ve external F1-score karşılaştırması.	81
Şekil 19. Nesne tespiti modellerinin internal ve external mAP50 karşılaştırması.	82
Şekil 20. Seçili modellerde internal ve external validation sonuçlarının karşılaştırılması.	83

Şekil 21. Seçili modellerde internal validation'dan external validation'a geçişte oluşan performans kaybı.

84

TABLO LİSTESİ

Tablo 1. Geleneksel makine öğrenmesi deneylerinde kullanılan veri setlerinin ön işleme sonrası split bazlı görüntü dağılımları.	27
Tablo 2. CNN tabanlı classification modelleri için veri setlerinin varroa/no_varroa sınıf dağılımları.	29
Tablo 3. Transformer tabanlı modellerde kullanılan veri setlerinin varroa içeren ve varroa içermeyen görüntü sayılarına göre dağılımı.	30
Tablo 4. SVM modellerinin öne çıkan classification ve detection sonuçları.	50
Tablo 5. Random Forest modellerinin öne çıkan classification ve detection sonuçları.	53
Tablo 6. ResNet18 modelinin internal ve external validation sonuçları.	55
Tablo 7. EfficientNet-B0 modelinin Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerindeki internal ve external validation sonuçları.	56
Tablo 8. YOLOv8n modelinin Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerindeki internal ve external validation sonuçları.	58
Tablo 9. YOLOv26n modelinin Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerindeki internal ve external validation sonuçları.	59
Tablo 10. DETR modelinin internal ve external validation sonuçları.	61
Tablo 11. Deformable DETR modelinin internal ve external validation sonuçları.	63
Tablo 12. RT-DETR modelinin internal ve external validation sonuçları.	64
Tablo 13. Classification Modellerinin Genel Sonuçları.	65
Tablo 14. Nesne Tespiti Modellerinin Genel Sonuçları.	66
Tablo 15. Model Ailelerine Göre En İyi External Sonuçlar	67

1. GİRİŞ

Dünya genelinde tarımsal üretimin sürdürülebilirliği ve biyoçeşitliliğin korunması, büyük ölçüde bal arılarının (*Apis mellifera*) polinasyon faaliyetlerine bağlıdır. Ancak son yıllarda artış gösteren toplu koloni kayıpları ve çevresel baskılar, bu kritik ekosistemi ciddi şekilde tehdit etmektedir. Bu tehditlerin başında gelen ve arıcılık sektörünün en büyük biyolojik problemi olarak kabul edilen *Varroa destructor* akarı, arı kolonilerinin çökmesine neden olan birincil parazittir.

Varroa akarları, arıların hemolenfi ve yağ dokularıyla beslenerek onların bağışıklık sistemini zayıflatmakta, aynı zamanda kanat bozukluğu virüsü gibi birçok patojenin kolonide hızla yayılmasına zemin hazırlamaktadır. Bu parazit ile mücadelede başarının anahtarı, istila seviyesinin erken ve doğru bir şekilde tespit edilmesidir.

Geleneksel olarak kullanılan şeker pudrası testi, alkol banyosu veya yapışkan tabla sayımı gibi manuel yöntemler; iş gücü yoğunluğu, hata payının yüksekliği ve zaman zaman arılara zarar vermesi gibi dezavantajlara sahiptir. Dijitalleşen dünyada "Hassas Arıcılık" (Precision Apiculture) kavramının önem kazanmasıyla birlikte; görüntü işleme, derin öğrenme algoritmaları ve IoT (Nesnelerin İnterneti) tabanlı sistemler bu alanda devrim yaratmıştır.

Bu çalışma, bal arısı görüntülerinde *Varroa* parazitin tespitine yönelik bilgisayarlı görü tabanlı yaklaşımları ele almaktadır. Proje kapsamında geleneksel yöntemlerin kısıtlamaları dikkate alınmış; geleneksel görüntü işleme ve makine öğrenmesi, CNN/YOLO tabanlı derin öğrenme modelleri ve Vision Transformer tabanlı yaklaşımlar kullanılarak *Varroa* tespitinin doğruluğu, uygulanabilirliği ve sürdürülebilir arıcılığa katkısı analiz edilmiştir.

1.1. Proje Çalışmasının Amacı ve Önemi

Bu projenin temel amacı, küresel gıda güvenliğinin ve ekolojik dengenin önemli unsurlarından biri olan bal arısı popülasyonlarını tehdit eden *Varroa destructor* parazitine karşı, görüntü işleme ve yapay zeka tabanlı dijital bir tespit yaklaşımı geliştirmek ve farklı model ailelerinin bu problem üzerindeki başarısını karşılaştırmalı olarak analiz etmektir. Bal arıları, tarımsal tozlaşmanın önemli bir bölümünü üstlenmekte; ancak *Varroa* paraziti nedeniyle yaşanan koloni zayıflamaları ve koloni kayıpları hem biyolojik çeşitliliği hem de tarımsal ekonomiyi ciddi şekilde risk altına sokmaktadır.

Geleneksel yöntemlerin iş gücü yoğunluğu, hata payı ve bazı durumlarda arılara zarar verme potansiyeli, modern arıcılığın önemli kısıtlarından biridir. Bu çalışma, bilgisayarlı görü ve yapay zekâ tabanlı tespit yaklaşımlarını arıcılık alanına uyarlayarak parazit istilasının erken aşamada, temassız ve daha hızlı şekilde tespit edilmesini hedeflemektedir. Proje kapsamında geleneksel görüntü işleme ve makine öğrenmesi

yöntemleri, CNN/YOLO tabanlı derin öğrenme modelleri ve Vision Transformer tabanlı yaklaşımlar değerlendirilmiştir. Bu sayede, farklı yapay zekâ yöntemlerinin Varroa tespitindeki doğruluk, genellenebilirlik ve uygulanabilirlik açısından karşılaştırılması amaçlanmıştır.

Projenin önemi, yalnızca bir tespit modeli geliştirmekle sınırlı değildir. Aynı zamanda, arıcılar için düşük maliyetli, hızlı ve sürdürülebilir bir karar destek mekanizmasına temel oluşturabilecek bilgisayarlı görü tabanlı bir yaklaşımın uygulanabilirliğini ortaya koymaktadır. Bu sayede kimyasal mücadele zamanlamasının daha bilinçli yapılması, arı sağlığının korunması ve dijital dönüşümün arıcılık sektöründe yaygınlaştırılması hedeflenmektedir.

2. YAPILAN ÇALIŞMALAR

Projenin başlangıç aşamasında, Varroa tespitinde kullanılan güncel teknolojileri ve dünyadaki iyi uygulama örneklerini incelemek amacıyla 9 temel akademik çalışma üzerinden literatür taraması yapılmıştır. İncelenen çalışmalar, Varroa tespitinde model başarısının yalnızca kullanılan algoritmaya değil; veri seti çeşitliliği, görüntü kalitesi, etiketleme tutarlılığı, ışık koşulları ve hedef nesnenin görüntüdeki boyutu gibi faktörlere de güçlü biçimde bağlı olduğunu göstermiştir. Bu doğrultuda açık kaynaklı farklı veri setleri incelenmiş; görüntü kalitesi, etiketleme yapısı ve dış doğrulama ihtiyacı dikkate alınarak proje kapsamında kullanılacak üç ana veri seti belirlenmiştir.

Proje kapsamında üç farklı teknik yaklaşım ele alınmıştır. Birinci yaklaşımda, geleneksel görüntü işleme ve makine öğrenmesi yöntemleri kullanılmıştır. Bu hatta HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılmış; Linear SVM, RBF SVM ve Random Forest modelleri eğitilerek önce patch düzeyinde sınıflandırma, ardından sliding-window tabanlı nesne tespiti gerçekleştirilmiştir. İkinci yaklaşımda CNN ve YOLO tabanlı derin öğrenme modelleri kullanılarak Varroa tespiti için modern nesne algılama mimarileri değerlendirilmiştir. Üçüncü yaklaşımda ise Vision Transformer tabanlı modeller kullanılarak dikkat mekanizmalarına dayalı öğrenme stratejilerinin Varroa tespitindeki başarısı incelenmiştir.

Deneysel süreçte model geliştirme için iki ayrı veri seti kullanılmış, üçüncü veri seti ise eğitim ve model seçimi süreçlerinden tamamen ayrı tutularak dış doğrulama amacıyla değerlendirilmiştir. Bu yapı sayesinde modellerin yalnızca eğitim verisine uyum sağlama başarısı değil, farklı kaynaklardan gelen bağımsız görüntüler üzerindeki genellenebilirliği de analiz edilmiştir. Elde edilen sonuçlar; Precision, Recall, F1-score, mAP ve IoU tabanlı nesne tespit metrikleri kullanılarak değerlendirilmiş ve farklı model ailelerinin güçlü ve zayıf yönleri karşılaştırılmıştır.

2.1. Proje Kapsamının Netleştirilmesi

Bu projenin kapsamı, bal arısı kolonilerinde önemli verim kayıplarına yol açan *Varroa destructor* parazitinin, görüntü işleme ve yapay zekâ tabanlı yöntemlerle tespit edilmesine yönelik süreçlerle sınırlandırılmıştır. Çalışma, parazitin biyolojik yapısının ayrıntılı incelenmesinden ziyade, bal arısı görüntüleri üzerinde Varroa tespitinin bilgisayarlı görü yöntemleriyle ne ölçüde gerçekleştirilebileceğine odaklanmaktadır.

Bu kapsamda proje üç ana teknik yaklaşım üzerinden yürütülmüştür: geleneksel görüntü işleme ve makine öğrenmesi, CNN/YOLO tabanlı derin öğrenme modelleri ve Vision Transformer tabanlı modeller. Geleneksel makine öğrenmesi hattında el yapımı görsel özellikler ve klasik sınıflandırıcılar kullanılırken, derin öğrenme tabanlı hatlarda otomatik özellik öğrenen modern mimariler değerlendirilmiştir. Böylece Varroa tespitinde farklı öğrenme yaklaşımlarının performans, genellenebilirlik ve uygulanabilirlik açısından karşılaştırılması hedeflenmiştir.

Proje, yalnızca yazılımsal model geliştirme sürecini değil, aynı zamanda bu modellerin kovan içi veya saha koşullarında kullanılabilecek dijital izleme sistemlerine temel oluşturma potansiyelini de kapsamaktadır. Bu yönüyle çalışma, “Hassas Arıcılık” uygulamaları için görüntü tabanlı, temassız ve erken uyarı sağlayabilecek sistemlerin geliştirilmesine yönelik metodolojik bir çerçeve sunmaktadır.

2.2. Literatür İncelemesi

Proje kapsamında incelenen 9 akademik çalışma, Varroa tespiti yöntemlerinin geleneksel manuel tekniklerden otonom dijital sistemlere doğru evrildiğini göstermektedir. Bununla birlikte kovan içi ışıklandırma, arı hareketliliği, görüntü kalitesi, veri seti çeşitliliği ve etiketleme tutarlılığı gibi çevresel ve teknik faktörlerin tespit başarısı üzerinde kritik etkiler oluşturduğu görülmüştür.

İncelenen makalelerin ortak sonucu, dijital yaklaşımların manuel sayımlara kıyasla daha hızlı, daha tekrarlanabilir ve karar destek sistemlerine daha uygun çözümler sunduğudur. Bu literatür sentezi, projenin teknik metodolojisi, veri seti seçimi ve farklı model ailelerinin karşılaştırılması için temel dayanak noktasını oluşturmuştur.

2.2.1. Detection of Varroa Mites from Bee Images Using YOLO Architecture [1]

Bu çalışmada, bal arıları üzerinde bulunan Varroa destructor akarlarının görüntülerden tespiti için altı farklı YOLO modeli sistematik olarak karşılaştırılmıştır. Çalışmada YOLOv5, YOLOv8, YOLOv9, YOLOv10, YOLOv11 ve YOLOv12 modelleri; halka açık VarroaDataset’ten oluşturulan kontrollü bir veri seti ile gerçek dünya koşullarını daha iyi temsil eden ikinci bir veri seti üzerinde test edilmiştir. Modeller precision, recall, F1-score, AP@50, AP@50:95, parametre sayısı, işlem süresi ve FPS gibi ölçütlerle değerlendirilmiştir. Sonuçlar, YOLO tabanlı yöntemlerin Varroa tespitinde

yüksek başarı ve düşük işlem süresi sağladığını göstermiştir. Özellikle YOLOv12x, genel doğruluk ve ortalama hassasiyet açısından en başarılı model olarak öne çıkmıştır.

Çalışma ayrıca model başarısının yalnızca ağ mimarisine değil, veri seti kalitesine de güçlü biçimde bağlı olduğunu göstermiştir. Kontrollü ortamdan gelen Dataset1’de bazı bounding box etiketlerinin gerçek akar boyutundan büyük olması ve bazı eksik etiketlerin bulunması, özellikle AP@50:95 değerlerini olumsuz etkilemiştir. Buna karşın görüntü ve etiket kalitesi daha tutarlı olan Dataset2’de tüm YOLO modelleri çok yüksek performans göstermiştir. Hız sonuçlarında YOLOv10x ve YOLOv11x dikkat çekerken, doğruluk ve hız dengesi bakımından YOLOv12x en güçlü çözüm olarak değerlendirilmiştir. Bu nedenle çalışma, YOLO ailesinin Varroa tespiti için hem akademik hem de gerçek zamanlı uygulamalarda güçlü bir seçenek olduğunu ortaya koymaktadır.

2.2.2. A Computer Vision System to Monitor The Infestation Level of Varroa Destructor in Honeybee Colony [2]

Bu çalışmada, bal arısı kolonilerindeki Varroa destructor bulaşma düzeyini otomatik olarak izlemek amacıyla taşınabilir bir bilgisayarlı görü sistemi geliştirilmiştir. Çalışmada kovan girişine yerleştirilen özel bir Video Monitoring Unit (VMU) kullanılmış, arılar dar geçitlerden tek sıra halinde geçirilerek çok bantlı ışıklandırma altında videoya alınmıştır. Görüntü işleme hattında önce arılar arka plandan ayrılmış, ardından arıların konumu ve yönü tahmin edilmiş, daha sonra özelleştirilmiş bir konvolüsyonel sinir ağı ile arı üzerindeki akar bölgeleri aranmıştır. Son aşamada arılar video boyunca takip edilerek aynı arının birden fazla kez sayılması engellenmiş ve bulaşma oranı hesaplanmıştır. Bu yönüyle çalışma, yalnızca akar tespitine değil, koloni düzeyinde enfestasyon oranı tahminine odaklanmıştır.

Çalışmanın deneysel sonuçları, önerilen sistemin pratik açıdan umut verici olduğunu göstermektedir. Test videosunda 1775 arı ve 98 görünür akar içeren veri üzerinde sistem, gerçek bulaşma oranı olan %5.52’ye karşılık %5.80’lik bir tahmin üretmiştir. Arı sayımında F1-score 0.97, Varroa tespitinde ise 0.91 elde edilmiştir. Ayrıca çalışma, çok bantlı aydınlatmanın ve özellikle yakın kızılötesi bileşenin akar ile arı piksellerini ayırmada faydalı olduğunu göstermiştir. Bununla birlikte yanlış pozitiflerin özellikle arının bazı anatomik bölgelerinden kaynaklandığı, tek açıdan çekim yapılmasının görünürlük sorunlarına yol açtığı ve mekanik düzenekte iyileştirme gereksinimi bulunduğu belirtilmiştir. Bu nedenle çalışma, Varroa tespitinin sadece bir model problemi değil, aynı zamanda görüntüleme koşulları ve takip altyapısı problemi olduğunu ortaya koymaktadır.

2.2.3. An AI-Based Open-Source Software for Varroa Mite Fall Analysis in Honeybee Colonies [3]

Bu çalışmada, bal arısı kolonilerindeki Varroa destructor akarlarının sticky board görüntülerinden otomatik olarak tespit ve sayımı için VarroDetector adlı açık kaynaklı bir yazılım geliştirilmiştir. Çalışmada iki ticari arılıktan toplanan sticky sheet'ler kontrollü ışık altında akıllı telefonlarla fotoğraflanmış, görüntüler önce yeşil ipler yardımıyla sayım bölgelerine ayrılmış, ardından ilgili alan içinde YOLOv11 Nano kullanılarak akar tespiti yapılmıştır. Model, yüksek çözünürlüklü görüntüler üzerinde eğitilmiş ve küçük nesne olan akarların ayırt edilebilmesi için büyük giriş boyutu ile çalıştırılmıştır. Yazılımın internet bağlantısı gerektirmemesi, standart bilgisayarlarda GPU olmadan çalışabilmesi ve kullanıcıya manuel düzeltme imkanı sunması çalışmanın pratik yönünü güçlendirmektedir.

Çalışmanın test sonuçları, VarroDetector'ın gerçek akar sayımı ile çok yüksek düzeyde ilişkili olduğunu göstermektedir. Farklı akıllı telefonlarla çekilen yeni sticky sheet görüntülerinde yazılımın gerçek sayımla korelasyonu $R^2 = 0.98-0.99$ aralığında bulunmuştur. Ayrıca görüntü yönü değiştiğinde de yazılım yüksek tutarlılık göstermiştir. Çalışma, özellikle sticky sheet başına 50'den fazla akar bulunduğunda VarroDetector'ın insan gözle yapılan sayımdan daha güvenilir hale geldiğini ve işlem süresinin akar sayısından bağımsız olarak düşük kaldığını ortaya koymuştur. Buna karşılık düşük akar yoğunluklarında ve düşük kaliteli görüntülerde performansın zayıflayabileceği belirtilmiştir. Bu nedenle çalışma, Varroa izleme sürecinde açık kaynaklı, hızlı ve saha kullanımına uygun bir otomatik sayım çözümü önermektedir.

2.2.4. Detection of Varroa mites from honey bee hives by smart technology Var-Gor: a hive monitoring and image processing device [4]

Bu çalışmada, bal arılarında önemli koloni kayıplarına neden olan Varroa destructor parazitinin erken aşamada tespit edilebilmesi amacıyla Var-Gor adı verilen akıllı bir kovan giriş izleme sistemi geliştirilmiştir. Araştırmada, Varroa bulaşının geleneksel yöntemlerle çoğunlukla geç fark edilmesi nedeniyle kimyasal mücadelede gecikmeler yaşandığı ve bunun hem arı sağlığı hem de bal verimi üzerinde olumsuz etkiler oluşturduğu vurgulanmıştır. Geliştirilen sistem, kovan girişine monte edilen bir cihaz kutusu içerisinde yer alan otomatik odaklamalı kamera, görüntü işleme arayüzü ve mobil uygulama desteğinden oluşmaktadır. Cihaz, arıların kovana giriş sırasında görüntülerini alarak arı şekli ve Varroa akarının eliptik yapısını eşleştirme algoritmalarıyla analiz etmektedir. Çalışmada görüntüler; şekil eşleştirme, renk sınıflandırması ve segmentasyon adımlarından geçirilerek Varroa içeren arılar tespit edilmektedir.

Makalenin deneysel bölümünde sistem laboratuvar ortamında eğitilmiş ve veri setinin %60'ı Varroa taşıyan, %40'ı sağlıklı arılardan oluşturulmuştur. Sistem, saniyede yedi görüntü işleyebilmekte ve her görüntü için yaklaşık 150 ms işlem süresiyle çalışmaktadır. Yapılan testlerde eğitilmiş örnekler üzerinde %100 doğruluk oranına ulaşıldığı belirtilmiştir. Ayrıca sistemin güneş enerjisi ile çalışacak şekilde tasarlanması,

Wi-Fi tabanlı bildirim altyapısı ve mobil uygulama üzerinden erken uyarı göndermesi çalışmanın dikkat çeken yenilikçi yönleri arasındadır. Araştırmacılar, özellikle akarın arı üzerindeki konumu ve renk değişimlerinin gelecekte model başarısını etkileyebileceğini belirtmiş ve sistemin saha koşullarında daha fazla veri ile geliştirilmesi gerektiğini ifade etmiştir. Bu çalışma, görüntü işleme destekli erken Varroa tespiti açısından mevcut bitirme projesi için önemli bir altyapı oluşturmaktadır.

2.2.5. Detection of Varroa destructor Infestation of Honeybees Based on Segmentation and Object Detection Convolutional Neural Networks [5]

Bu çalışmada, bal arılarında Varroa destructor bulaşının tespiti için segmentasyon ve nesne tespit yöntemlerini birleştiren derin öğrenme tabanlı bir yaklaşım önerilmiştir. Araştırmacılar, açık alanda çekilen arı görüntülerinde arka planın karmaşık olması, arı hareketlerinden kaynaklanan bulanıklık ve Varroa akarının çok küçük boyutta olması nedeniyle doğrudan nesne tespitinin yeterli doğruluk vermediğini belirtmiştir. Bu nedenle ilk aşamada Fully Convolutional Network (FCN) kullanılarak arılar arka plandan ayrılmış, ardından yalnızca arı bölgesi üzerinde YOLOX tabanlı nesne tespit modeli çalıştırılmıştır. Ayrıca model içerisine Coordinate Attention (CA) mekanizması eklenerek küçük nesne olan Varroa akarına ait detay özelliklerin daha iyi öğrenilmesi sağlanmıştır. Veri seti Çin'deki bir arılıkta toplanan 4320 yüksek çözünürlüklü görüntüden oluşturulmuş, yalnızca 105 görüntüde Varroa bulunduğu için sınıf dengesizliğini azaltmak amacıyla yapay veri çoğaltma uygulanmıştır.

Deneysel sonuçlarda geliştirilen F-YOLOX_b modelinin diğer nesne tespit yöntemlerinden daha başarılı olduğu gösterilmiştir. Modelin mAP değeri %95.31, bal arısı tespitinde F1 skoru %94.83, Varroa tespitinde ise %96.85 olarak rapor edilmiştir. Özellikle dikkat mekanizması ve iyileştirilmiş kayıp fonksiyonunun birlikte kullanılmasıyla Varroa tespit performansında belirgin artış sağlanmış, klasik YOLOX modeline göre mAP değerinde %14.08 artış elde edilmiştir. Ayrıca modelin hesapladığı Varroa bulaş oranı %1.13 olup gerçek ölçüm olan %1.19 değerine oldukça yakın bulunmuştur. Çalışmada geliştirilen yöntemin arı kolonilerini strese sokmadan, kovan girişinde belirli aralıklarla otomatik ölçüm yapabilecek düzeyde olduğu belirtilmiş ve ileride kenar cihazlar üzerinde gerçek zamanlı çalıştırılabileceği ifade edilmiştir. Bu çalışma, mevcut bitirme projesinde kullanılacak açık veri kümeleri üzerinde modern nesne tespit mimarilerinin uygulanması açısından önemli bir referans niteliğindedir.

2.2.6. Visual Diagnosis of the Varroa destructor Parasitic Mite in Honeybees Using Object Detector Techniques [6]

Bu çalışmada, bal arılarında ciddi koloni kayıplarına neden olan **Varroa destructor** parazitin tespiti için modern nesne tespit yöntemleri kullanılmıştır. Araştırmacılar, geleneksel Varroa izleme yöntemlerinin zaman alıcı ve iş gücü gerektiren yapısından dolayı bilgisayarlı görü tabanlı çevrim içi izleme sistemlerine ihtiyaç duyulduğunu

belirtmiştir. Çalışmada doğrudan nesne segmentasyonu ve sınıflandırmayı ayrı ayrı yapmak yerine, tek aşamada tespit sağlayan YOLOv5 ve SSD (Single Shot Detector) mimarileri karşılaştırılmıştır. Ayrıca anomali tespiti amacıyla Deep SVDD yöntemi de denenmiştir. Kullanılan veri seti toplam 803 görüntüden oluşturulmuş, bunların bir kısmı açık kaynak veri kümelerinden alınmış, bir kısmı ise farklı ortamlarda toplanmıştır. Veri setinde sağlıklı arılar, polenli arılar, erkek arılar, ana arılar, Varroa bulaşmış arılar ve yalnızca akar görüntüleri olmak üzere altı sınıf tanımlanmıştır. Eğitim verisi artırma teknikleriyle genişletilmiş ve 24.684 örneğe çıkarılmıştır.

Deneysel sonuçlarda YOLOv5 modelinin özellikle Varroa bulaşmış arıların tespitinde en yüksek performansı verdiği görülmüştür. Healthy and Ill Bees veri kümesi üzerinde eğitilen YOLOv5-X modeli, enfekte arı tespitinde 0.908 mAP[0.5] ve 0.874 F1 skoru elde etmiştir. Buna karşılık SSD modeli daha düşük doğruluk göstermiş, ancak MobileNetV2 tabanlı sürümünde Varroa tespitinde umut verici sonuçlar elde edilmiştir. Araştırmada doğrudan akar tespiti yerine enfekte arının tespit edilmesinin bazı durumlarda daha başarılı olduğu vurgulanmıştır; çünkü akar her görüntüde net görünmese bile arı üzerindeki deformasyonlar öğrenilebilmektedir. Çalışmanın en önemli katkılarından biri, gerçek zamanlı çalışabilecek düşük maliyetli bir izleme sistemine temel oluşturabilecek nesne tespit yaklaşımını göstermesidir. Bu yönüyle çalışma, açık veri setleri üzerinde YOLO tabanlı modern nesne tespit modelleri geliştirmeyi hedefleyen mevcut bitirme projesi için güçlü bir metodolojik referans oluşturmaktadır.

2.2.7. A Comparative Study of Hybrid Machine-Learning vs. Deep-Learning Approaches for Varroa Mite Detection and Counting [7]

Bu çalışmada, bal arılarına zarar veren Varroa akarlarını (Varroa destructor) tespit etmek amacıyla kovan altı panolarından (mite-drop boards) elde edilen hiperspektral görüntülerden oluşan bir veri seti kullanılmıştır. Her bir görüntü 25 farklı spektral banda (675–975 nm) sahip olup yüksek detay barındırmaktadır. Eğitim için sadece 6 görüntü (içerisinde 15 işaretlenmiş akar bulunan) ve test/doğrulama için 6 görüntü (38 akar bulunan) kullanılarak verinin kısıtlı olduğu bir senaryo oluşturulmuştur. Araştırmacılar bu veri seti üzerinde iki farklı yaklaşımı karşılaştırmıştır: Geleneksel Makine Öğrenimi (ML) yaklaşımı olarak Temel Bileşenler Analizi (PCA), k-En Yakın Komşu (kNN) ve Destek Vektör Makinesi (SVM) ardışık düzeni kullanılmışken; Derin Öğrenme (DL) yaklaşımı olarak ise 25 kanallı girdiye uyarlanmış, ResNet-50 ve ResNet-101 omurgalarına sahip Faster R-CNN modelleri tercih edilmiştir.

Karşılaştırma sonucunda, kısıtlı veri koşulları altında geleneksel makine öğrenimi (PCA + kNN + SVM) modeli, derin öğrenme modellerine kıyasla çok daha başarılı olmuştur. Makine öğrenimi ardışık düzeni, test setindeki 38 akarın 37'sini doğru tespit ederek %99.83 kesinlik (precision), %99.47 duyarlılık (recall) ve %99.18 F1-Skoru gibi son derece yüksek metrikler elde etmiştir. Buna karşılık, Faster R-CNN (ResNet-50 ve

ResNet-101) modelleri sırasıyla 28 ve 30 akarı tespit edebilmiş ve F1-Skorları %84.8 ile %89.4'te kalmıştır. Bu durum, çok az sayıda eğitim verisi (sadece 6 görsel) olduğunda derin öğrenme mimarilerinin aşırı öğrenmeye (overfitting) eğilimli olmasından kaynaklanmaktadır. Ayrıca geleneksel makine öğrenimi modeli, GPU'ya ihtiyaç duymadan standart bir CPU üzerinde çok daha kısa sürede eğitilebilmesi ve anlık sonuç (inference) üretebilmesi yönüyle de kaynak verimliliği açısından açık ara üstün bulunmuştur

2.2.8. Deep Learning Beehive Monitoring System for Early Detection of the Varroa Mite [8]

Çalışmada kullanılan veriseti, kovan içerisine yerleştirilen özel bir kamera modülü ile elde edilen görüntülerden oluşturulmuştur. Bu görüntüler öncelikle bulanık veya düşük çözünürlüklü olanların elenmesi için manuel bir filtreden geçirilmektedir; fotoğraflar minimum 5 Mpx, 800x600 piksel çözünürlüğünde ve JPEG formatındadır. Veriseti, kovan içindeki arı yoğunluğunu (örneğin hiç arı olmaması, 10'dan az arı, 50'den fazla arı vb.) temsil eden 5 farklı sınıfa (Class 0 - Class 4) ayrılmış olup, her sınıf için en az 1000 adet olmak üzere eğitim için toplam 5000 adet görüntü kullanılmıştır. Temizlenen görüntüler "LabelImg" aracı kullanılarak manuel olarak etiketlenmiş ve bu verilerin %70-80'i eğitim seti, kalan %20-30'luk kısım ise test seti olarak ayrılmıştır. Sistemin ikinci aşaması olan Varroa akarı tespitinin doğrulama testleri için ise, önceki algoritma adımlarından elde edilmiş 100'ü Varroa taşıyan, 100'ü ise taşımayan toplam 200 arı konturu fotoğrafı kullanılmıştır.

Kullanılan model ve algoritmalara bakıldığında, sistem iki aşamalı melez bir tespit mimarisi üzerine kurulmuştur: Birinci aşama derin öğrenme ile arıların tespit edilmesi, ikinci aşama ise bilgisayarlı görü ile bu arılar üzerindeki Varroa akarının saptanmasıdır. Arıların tespiti için Bölgesel Evrişimli Sinir Ağları (Regional CNN) algoritmalarından olan Faster R-CNN ve SSD (Single Shot MultiBox Detector) algoritmaları temel alınmıştır. Sistemde doğruluk ve hız performanslarını karşılaştırmak amacıyla PyTorch altyapısında önceden eğitilmiş üç farklı CNN modeli kullanılmıştır: Bunlar endüstriyel gömülü sistemlere uygun hafif modeller olan MobileNet V2 ve MobileNet V3 ile daha ağır ve karmaşık bir model olan ResNet-50 FPN modelleridir. Arılar tespit edildikten sonra, arı bölgeleri (ROI) üzerinde Varroa akarını bulmak amacıyla görüntü işleme algoritmaları devreye girmektedir; bu aşamada görüntüleri RGB'den HSV formatına dönüştüren HSV renk maskeleye (color masking) ve akarın dairesel fiziksel yapısını tespit etmeyi sağlayan Hough dönüşümü (Hough transformation) algoritmaları kullanılmaktadır.

2.2.9. Deep Learning for Real-Time Varroa Destructor Monitoring [9]

Bu çalışmada kullanılan **veri seti**, Tayvan'daki ticari bir arıcılık tesisinden (Chen Home Honey) kovan girişlerine özel olarak kurulan bir ahşap görüntüleme odası aracılığıyla

elde edilmiştir. Veri toplama sürecinde bir Raspberry Pi 4 bilgisayar ve Kamera Modülü V2 kullanılarak üç gün boyunca 15 saniyelik aralıklarla 1980x1080 piksel çözünürlüğünde yaklaşık 6.000 fotoğraf çekilmiştir. Modelin eğitilmesi için bu fotoğraflar arasından 1.500 adet sağlıklı arı ve 100 adet gözle görülebilir Varroa akarı barındıran arı görüntüsü seçilmiştir. Eğitim verilerini desteklemek ve çeşitliliği artırmak amacıyla, daha önceki bir çalışma olan VarroaDataset'ten (Stefan ve Kampel, 2020) elde edilen 160x280 piksel çözünürlüğündeki yüksek kaliteli akar görüntüleri de veri setine dâhil edilmiştir. Görüntülerdeki hedefler, LabelImg aracı kullanılarak "arı" (bee) ve "varroa" olmak üzere iki ayrı sınıf olarak manuel bir şekilde etiketlenmiş ve koordinatları belirlenmiştir.

Kullanılan modeller ve algoritmalar incelendiğinde, araştırmacıların gerçek zamanlı nesne tespiti için derin öğrenme tabanlı YOLOv5s (You Only Look Once, version 5 small) çerçevesini tercih ettikleri görülmektedir. YOLOv5s, gerçek zamanlı tespit işlemleri için özel olarak optimize edilmiş, bilgisayar işlem yükü hafif ve hızlı bir derin öğrenme mimarisidir. Algoritma, PyTorch derin öğrenme kütüphanesi üzerinde uygulanmış ve modelin başlangıç eğitimini hızlandırmak için önceden eğitilmiş yolov5s ağırlık dosyaları kullanılmıştır. Geliştirilen bu derin öğrenme modelinin başarısını ve kararlılığını ölçmek için algoritmaya 50 epok ve 300 epok olmak üzere iki farklı döngü süresinde eğitim verilmiş; sonuç olarak 300 epok eğitilen modelin özellikle kısmen gizlenmiş küçük akarları tespit etmede çok daha yüksek bir doğruluk (0.974 ortalama hassasiyet) sağladığı kanıtlanmıştır.

2.3. Teknik Planlama

Projenin teknik planlama süreci, literatürde yer alan açık kaynaklı ve akademik veri setlerinin incelenmesiyle başlatılmıştır. Bu aşamada farklı platformlardaki bal arısı ve Varroa veri setleri; görüntü çözünürlüğü, etiketleme kalitesi, sınıf yapısı, ışıklandırma koşulları, örneklem çeşitliliği ve dış doğrulama için uygunluk açısından değerlendirilmiştir. Yapılan ön araştırma sonucunda, tek bir veri seti ile sınırlı kalmak yerine model başarısını farklı veri dağılımları altında test edebilmek amacıyla üç ana veri seti belirlenmiştir.

Projenin veri stratejisi üç temel rol üzerine kurulmuştur:

- **Bağlamsal öğrenme veri seti:** Hem arı hem de Varroa etiketlerini içeren veri seti, modelin paraziti yalnızca morfolojik özellikleriyle değil, arı gövdesi üzerindeki konumu ve arı-akar arasındaki boyutsal ilişkiyle birlikte öğrenebilmesi için kullanılmıştır.
- **Morfolojik odaklı veri seti:** Yalnızca Varroa akarına odaklanan etiket yapısına sahip veri seti, modelin arı bağlamından bağımsız olarak akarın renk, doku ve şekil özelliklerine odaklanmasını sağlamak amacıyla kullanılmıştır.

- **Bağımsız dış test veri seti:** Üçüncü veri seti, eğitim, model seçimi ve parametre ayarlama süreçlerinden tamamen ayrı tutulmuş; yalnızca nihai aşamada modellerin farklı kaynaklı bağımsız test verisi üzerindeki genellenebilirliğini ölçmek için kullanılmıştır.

Proje kapsamında üç farklı teknik yaklaşım karşılaştırmalı olarak ele alınmıştır:

- **Geleneksel görüntü işleme ve makine öğrenmesi yaklaşımı:** Bu hatta görüntülerden HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılmış; Linear SVM, RBF SVM ve Random Forest modelleriyle önce patch düzeyinde sınıflandırma, ardından sliding-window tabanlı nesne tespiti gerçekleştirilmiştir.
- **CNN ve YOLO tabanlı derin öğrenme yaklaşımı:** Bu hatta ResNet, EfficientNet ve YOLO tabanlı modeller kullanılarak Varroa tespiti hem sınıflandırma hem de nesne algılama problemi olarak değerlendirilmiştir.
- **Vision Transformer tabanlı yaklaşım:** Bu hatta dikkat mekanizmalarına dayalı transformer mimarilerinin Varroa tespiti problemindeki başarısı incelenmiş ve diğer model aileleriyle karşılaştırılmıştır.

Deneysel süreçte model geliştirme ve değerlendirme aşamaları birbirinden ayrılmıştır. Model eğitimleri ve ara seçimler yalnızca geliştirme veri setleri üzerinde yapılmış, bağımsız dış doğrulama veri seti ise hiçbir eğitim veya parametre ayarlama sürecinde kullanılmamıştır. Bu sayede modellerin yalnızca kendi eğitim verisine uyum sağlama başarısı değil, farklı kaynaklardan gelen görüntüler üzerindeki genellenebilirliği de analiz edilmiştir.

Modellerin performansı; Precision, Recall, F1-score, mAP ve IoU tabanlı nesne tespit metrikleriyle değerlendirilmiştir. Geleneksel makine öğrenmesi hattında ayrıca patch-level classification başarısı ile full-image sliding-window detection başarısı ayrı ayrı incelenmiştir. Böylece sınıflandırma düzeyinde yüksek başarı gösteren modellerin, gerçek görüntü üzerinde nesne tespiti problemine aktarıldığında nasıl davrandığı analiz edilmiştir.

Bu teknik planlama doğrultusunda proje, yalnızca tek bir model mimarisinin performansını ölçmekten ziyade, farklı öğrenme yaklaşımlarının Varroa tespiti problemindeki güçlü ve zayıf yönlerini karşılaştırmayı hedeflemiştir. Elde edilen sonuçlar, arıcılıkta kullanılabilecek temassız, görüntü tabanlı ve sürdürülebilir karar destek sistemleri için teknik bir temel oluşturacak şekilde değerlendirilmiştir.

3. DENEYSEL ÇALIŞMALAR VE MODEL GELİŞTİRME SÜRECİ

Bu bölümde, Varroa tespiti problemi kapsamında yürütülen deneysel süreç ve model geliştirme aşamaları açıklanmaktadır. Çalışmada farklı veri setleri ve farklı model aileleri kullanılarak hem sınıflandırma hem de nesne tespiti görevleri

değerlendirilmiştir. Bu kapsamda veri setlerinin hazırlanması, model ailelerinin uygulanabilirlik açısından incelenmesi, internal değerlendirme yapısı ve external validation yaklaşımı bütüncül bir deneysel süreç olarak ele alınmıştır.

3.1. Deneysel Sürecin Genel Özeti


Bu çalışmada, bal arıları üzerinde görülen Varroa destructor parazitinin tespit edilmesine yönelik farklı model aileleri kullanılarak deneysel çalışmalar yürütülmüştür. Projede amaç, farklı algoritmaların Varroa tespiti problemindeki uygulanabilirliğini incelemek ve elde edilen sonuçları karşılaştırmalı olarak değerlendirmektir. Bu kapsamda geleneksel makine öğrenmesi yöntemleri, CNN tabanlı derin öğrenme modelleri, YOLO tabanlı nesne tespiti modelleri ve transformer tabanlı yaklaşımlar deneysel sürece dahil edilmiştir.

Deneysel süreçte kullanılan modeller, problemin ele alınış biçimine göre sınıflandırma ve nesne tespiti yaklaşımları altında değerlendirilmiştir. Sınıflandırma tabanlı modeller, bir görüntüde ya da görüntüden elde edilen belirli bir görüntü bölgesinde Varroa parazitinin bulunup bulunmadığını tahmin etmeye odaklanırken, nesne tespiti tabanlı modeller parazitin görüntü üzerindeki konumunu belirlemeyi amaçlamıştır. Geleneksel makine öğrenmesi hattında ise bu iki yaklaşım ardışık biçimde birleştirilmiştir. Önce görüntü bölgeleri üzerinde Varroa var/yok sınıflandırması yapan modeller geliştirilmiş, ardından bu modeller sliding-window yöntemiyle tam görüntü üzerinde gezdirilerek Varroa konumlarının tespit edilmesi sağlanmıştır. Böylece proje kapsamında Varroa tespiti hem sınıflandırma hem de konum belirleme problemi olarak ele alınmıştır.

Çalışmada farklı kaynaklardan elde edilen veri setleri kullanılmıştır. Bu veri setleri, model eğitime ve değerlendirme sürecine uygun hale getirilebilmesi için çeşitli ön işleme adımlarından geçirilmiştir. Etiket yapılarının düzenlenmesi, sınıf isimlerinin standartlaştırılması, geçersiz etiketlerin kontrol edilmesi, veri setlerinin eğitim/test rollerinin belirlenmesi ve model türlerine uygun veri yapılarının oluşturulması bu sürecin temel adımlarını oluşturmuştur.

Deneysel çalışmalar kapsamında her model ailesi için eğitim ve değerlendirme süreçleri ayrı ayrı yürütülmüştür. Modellerin performansları, kendi veri setleri üzerinde elde edilen iç test sonuçları ve uygun durumlarda bağımsız dış test veri seti üzerinde yapılan dış değerlendirme sonuçları dikkate alınarak incelenmiştir. Bu yaklaşım, modellerin yalnızca eğitim verisine yakın örneklerdeki başarısını değil, farklı veri dağılımlarına karşı gösterdiği genellenebilirlik düzeyini de değerlendirmeye yardımcı olmuştur.

Deneysel süreç genel olarak veri setlerinin hazırlanması, modellerin eğitilmesi, uygun metriklerle değerlendirilmesi, sonuçların tablo ve grafiklerle raporlanması ve elde edilen çıktıların yorumlanması adımlarından oluşmuştur. Bu sayede farklı model ailelerinin Varroa tespiti problemindeki güçlü ve zayıf yönleri daha sistematik biçimde incelenmiştir.



Şekil 1. Deneysel süreçte izlenen genel model geliştirme ve değerlendirme akışı.

3.2. Model Ailelerinin Uygulanabilirlik Açısından Değerlendirilmesi

Varroa parazitinin tespiti problemi, görüntü işleme ve makine öğrenmesi açısından farklı yaklaşımlarla ele alınabilecek bir problemdir. Bu nedenle çalışmada yalnızca tek bir model türüne bağlı kalınmamış, farklı model aileleri deneysel sürece dahil edilmiştir. Geleneksel makine öğrenmesi modelleri, CNN tabanlı derin öğrenme modelleri, YOLO tabanlı nesne tespiti modelleri ve transformer tabanlı yaklaşımlar bu kapsamda değerlendirilmiştir.

Geleneksel makine öğrenmesi modelleri, daha düşük hesaplama maliyetiyle çalışabilmeleri ve önceden çıkarılmış görsel özellikler üzerinden yorumlanabilir sonuçlar sunabilmeleri açısından önemlidir. Support Vector Machine ve Random Forest gibi modeller, özellikle HOG, HSV, LBP ve PCA gibi özellik çıkarım yöntemleriyle birlikte kullanıldığında görüntü bölgeleri üzerinde sınıflandırma yapmaya uygun yaklaşımlardır. Bu çalışmada geleneksel makine öğrenmesi modelleri önce Varroa var/yok sınıflandırması için kullanılmış, ardından sliding-window tabanlı bir yapı içerisinde tam görüntü üzerinde Varroa konumlarının belirlenmesi amacıyla değerlendirilmiştir. Bu modellerin incelenmesi, derin öğrenme tabanlı yöntemlere kıyasla daha klasik ve daha düşük maliyetli yaklaşımların Varroa tespiti problemindeki başarısını görmek açısından önemlidir.

CNN tabanlı modeller, görüntülerden otomatik özellik çıkarabilmeleri nedeniyle görsel sınıflandırma problemlerinde yaygın olarak kullanılmaktadır. ResNet ve EfficientNet gibi mimariler, görüntü düzeyinde Varroa bulunup bulunmadığını belirlemek amacıyla kullanılabilir. Bu modeller, görüntüyü bütün olarak değerlendirilerek *varroa* ve *no_varroa* sınıfları arasında ayırım yapmayı hedeflemektedir. Bu nedenle CNN tabanlı

sınıflandırma modelleri, Varroa var/yok kararının verilmesi gereken senaryolar için uygundur.

YOLO tabanlı nesne tespiti modelleri ise yalnızca görüntüde Varroa olup olmadığını belirlemekle kalmaz, aynı zamanda Varroa parazitinin görüntü üzerindeki konumunu da bounding box ile tahmin eder. Bu özellik, Varroa parazitinin arı üzerindeki yerinin görsel olarak gösterilmesi gereken durumlarda önemli bir avantaj sağlar. YOLOv8 ve YOLOv26 modellerinin deneysel sürece dahil edilmesi, farklı nesne tespiti yaklaşımlarının küçük nesne karakteri taşıyan Varroa tespiti problemindeki uygulanabilirliğini incelemek açısından önemlidir.

Transformer tabanlı modeller ise görüntü içerisindeki daha geniş bağlamsal ilişkileri öğrenebilme potansiyeline sahiptir. Vision Transformer gibi modeller, görüntüyü parçalara ayırarak bu parçalar arasındaki ilişkileri değerlendirebilir. Bu yaklaşım, CNN tabanlı modellerden farklı bir temsil öğrenme yöntemi sunduğu için deneysel süreçte ayrı bir model ailesi olarak ele alınmıştır.

Genel olarak bu çalışmada farklı model ailelerinin kullanılması, Varroa tespiti probleminin yalnızca tek bir yöntem üzerinden değil, farklı öğrenme yaklaşımları üzerinden değerlendirilmesini sağlamıştır. Böylece sınıflandırma ve nesne tespiti görevleri ayrı ayrı incelenmiş, model ailelerinin problem açısından güçlü ve sınırlı yönlerinin karşılaştırılmasına zemin hazırlanmıştır.

3.3. Veri Setlerinin Deneysel Sürece Hazırlanması

Deneysel süreçte kullanılan veri setleri, model eğitime ve değerlendirme aşamalarına uygun hale getirilebilmesi için öncelikle incelenmiş ve etiket yapıları kontrol edilmiştir. Çalışmada farklı kaynaklardan elde edilen veri setleri kullanıldığı için, veri setleri arasında sınıf adları, etiket formatları, görüntü dağılımları ve anotasyon tutarlılığı açısından farklılıklar bulunabilmektedir. Bu nedenle modellerin tutarlı şekilde eğitilebilmesi ve karşılaştırılabilmesi için veri setlerinin ortak bir deneysel yapıya dönüştürülmesi gerekmiştir.

Nesne tespiti modelleri için veri setleri YOLO formatında düzenlenmiştir. Bu kapsamda görüntüler ve bu görüntülere ait etiket dosyaları train, validation ve test ayrımları içinde değerlendirilmiştir. Varroa tespiti çalışmasının temel hedefi arı üzerindeki Varroa paraziti tespit etmek olduğu için, nesne tespiti deneylerinde etiket yapısı tek sınıflı *varroa* formatına uygun hale getirilmiştir. Böylece YOLO tabanlı modellerin doğrudan hedef nesneye odaklanması amaçlanmıştır.

Sınıflandırma tabanlı modeller için ise veri setleri binary classification yapısına dönüştürülmüştür. Bu yapıda görüntüler *varroa* ve *no varroa* olmak üzere iki sınıf altında ele alınmıştır. Görüntüde geçerli bir *varroa* etiketi bulunması durumunda görüntü *varroa*, geçerli Varroa etiketi bulunmaması durumunda ise *no_varroa* sınıfına dahil

edilmiştir. Bu işlem sayesinde ResNet, EfficientNet ve diğer sınıflandırma tabanlı modellerin görüntü düzeyinde Varroa var/yok tahmini yapabilmesi sağlanmıştır.

Geleneksel makine öğrenmesi tabanlı modeller için ise veri hazırlama süreci görüntü düzeyinden farklı olarak görüntü bölgeleri üzerinden yürütülmüştür. Bu kapsamda -YOLO etiketleri kullanılarak pozitif ve negatif görüntü bölgelerini tanımlayan patch metadata dosyaları oluşturulmuştur. Varroa etiketi içeren geçerli bölgeler pozitif örnek, Varroa içermeyen uygun bölgeler ise negatif örnek olarak değerlendirilmiştir. Daha sonra bu bölgelerden HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılarak SVM ve Random Forest modellerinde kullanılacak binary sınıflandırma veri yapısı oluşturulmuştur. Bu süreçte görüntü bölgesi boyutu, sınıf dengesi ve özellik seti gibi değişkenler farklı deney kombinasyonları olarak ele alınmıştır.

Veri hazırlama sürecinde geçersiz veya problemli etiketlerin kontrol edilmesi önemli bir adım olmuştur. Genişliği veya yüksekliği sıfır olan bounding box kayıtları, alan değeri geçersiz olan etiketler, sınıf formatı hataları ve model eğitimi olumsuz etkileyebilecek tutarsız anotasyonlar kontrol edilmiştir. Böylece eğitim sürecinde modellerin hatalı etiketlerden kaynaklı öğrenme problemleri yaşamasının önüne geçilmesi hedeflenmiştir.

Hazırlanan veri setleri, modellerin kendi eğitim ve değerlendirme süreçlerinde kullanılacak şekilde düzenlenmiştir. Bunun yanında farklı veri kaynağı üzerinde değerlendirme yapılabilmesi için bağımsız dış test veri seti de deneysel sürece dahil edilmiştir. Bu veri seti eğitim, model seçimi ve parametre ayarlama süreçlerinden ayrı tutulmuş; modellerin farklı görüntü dağılımlarında ne ölçüde başarılı olabildiğini analiz etmek amacıyla kullanılmıştır.

3.4. Internal Validation ve External Validation Yaklaşımı

Deneysel süreçte modellerin performansını daha sağlıklı değerlendirebilmek için validation yaklaşımı iki farklı açıdan ele alınmıştır. İlk olarak modellerin kendi eğitim veri setlerine ait validation bölümleri üzerinde değerlendirme yapılmıştır. Bu değerlendirme, modelin eğitim aldığı veri dağılımına yakın örnekler üzerindeki başarısını ölçmek amacıyla kullanılmıştır. Bu yaklaşım çalışmada internal validation olarak ele alınmıştır.

Internal validation, modelin kendi veri seti içerisindeki öğrenme başarısını görmek açısından önemlidir. Bir modelin kendi validation split'i üzerinde yüksek başarı göstermesi, modelin o veri setindeki görüntü yapısını ve örüntüleri öğrenebildiğini gösterir. Ancak yalnızca internal validation sonuçlarına bakmak, modelin farklı veri kaynaklarında aynı başarıyı göstereceği anlamına gelmez. Bu nedenle çalışmada farklı veri dağılımlarına karşı model performansını değerlendirmek için external validation yaklaşımı da dikkate alınmıştır.

External validation kapsamında, model eğitim sürecinde kullanılmayan farklı bir veri seti üzerinde değerlendirme yapılması hedeflenmiştir. Bu çalışmada external validation amacıyla Varroa Mites Detector veri seti kullanılmıştır. Bu veri seti, modellerin eğitiminde kullanılmayarak dış doğrulama veri seti olarak ele alınmıştır. Böylece modellerin yalnızca eğitim veri setlerine yakın görüntülerdeki başarısı değil, farklı kaynaklardan gelen görüntüler karşısındaki genelleme kabiliyeti de incelenmiştir.

Internal ve external validation sonuçlarının birlikte değerlendirilmesi, model başarısının daha gerçekçi biçimde analiz edilmesini sağlamaktadır. Internal validation sonuçları modelin kendi veri setindeki başarısını gösterirken, external validation sonuçları modelin farklı veri dağılımlarına karşı dayanıklılığını ortaya koymaktadır. Özellikle Varroa tespiti gibi görüntü koşullarının, anotasyon yapısının ve nesne görünürlüğüne değişebildiği problemlerde external validation önemli bir değerlendirme adımıdır.

Bu yaklaşım sayesinde modellerin yalnızca eğitim sürecindeki başarıları değil, farklı veri kaynaklarına ne ölçüde genellenebildiği de analiz edilmiştir. Böylece model ailelerinin Varroa tespiti problemindeki güçlü ve zayıf yönleri daha kapsamlı biçimde değerlendirilebilmiştir.

4. KULLANILAN VERİ SETLERİ VE ÖN İŞLEME ADIMLARI

Bu bölümde, deneysel çalışmalarda kullanılan veri setleri ve bu veri setlerinin farklı model aileleri için nasıl hazırlandığı açıklanmaktadır. Çalışmada üç temel veri seti kullanılmıştır: Varroa Dataset, HoneyBee VarroaMite ve Varroa Mites Detector. Bu veri setleri; etiket yapıları, sınıf dağılımları, görüntü özellikleri ve kullanım amaçları açısından birbirinden farklılık göstermektedir. Bu nedenle her veri seti, geleneksel makine öğrenmesi, CNN tabanlı modeller ve transformer tabanlı modeller için ayrı ön işleme adımlarından geçirilmiştir.

4.1. Varroa Dataset Veri Setinin Hazırlanması

Varroa Dataset, proje kapsamında kullanılan temel geliştirme veri setlerinden biridir. Bu veri seti, bal arısı görüntüleri üzerinde Varroa parazitinin tespit edilmesine yönelik etiketler içermektedir. Veri setinin yapısında hem arı hem de Varroa etiketlerinin bulunması, bağlamsal öğrenme açısından önemli bir avantaj sağlamaktadır. Bu nedenle Varroa Dataset, farklı model ailelerinde hem sınıflandırma hem de nesne tespiti görevleri için ayrı biçimlerde hazırlanmıştır.

4.1.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Hazırlık

Varroa Dataset, geleneksel makine öğrenmesi tabanlı modeller için doğrudan görüntü sınıflandırma formatında kullanılmamış, bunun yerine görüntü bölgeleri üzerinden çalışan bir yapı hazırlanmıştır. Veri setinin orijinal YOLO etiket yapısında hem arı hem de Varroa sınıfları bulunduğu için, öncelikle etiket dosyaları incelenmiş ve pozitif örnek

kaynağı olarak yalnızca Varroa sınıfına ait geçerli bounding box kayıtları dikkate alınmıştır. Arı sınıfına ait etiketler, Varroa pozitif örneği olarak değerlendirilmemiştir.

Bu aşamada görüntü ve etiket dosyalarının eşleşmesi, boş etiket dosyaları, geçersiz YOLO satırları ve uç değer niteliği taşıyan bounding box kayıtları kontrol edilmiştir. Geçerli Varroa etiketleri pozitif örnek üretiminde kullanılırken, Varroa içermeyen uygun görüntüler negatif örnek kaynağı olarak değerlendirilmiştir. Böylece geleneksel makine öğrenmesi modelleri için görüntünün tamamı yerine, Varroa bulunan veya bulunmayan belirli görüntü bölgelerine dayalı bir binary classification yapısı oluşturulmuştur.

Varroa Dataset üzerinde farklı bağlam seviyelerini inceleyebilmek amacıyla birden fazla patch boyutu kullanılmıştır. Bu kapsamda 80×80 , 96×96 ve 112×112 boyutlarında görüntü bölgeleri oluşturulmuştur. Daha küçük patch boyutları hedef nesneye daha yakın ve dar bir bağlam sunarken, daha büyük patch boyutları Varroa parazitinin arı üzerindeki çevresel bağlamıyla birlikte değerlendirilmesine olanak sağlamıştır. Bu patch boyutları, veri keşfi aşamasında incelenen Varroa bounding box boyutları ve görüntü yapısı dikkate alınarak belirlenmiştir.

Hazırlanan pozitif ve negatif örnekler fiziksel görüntü dosyaları olarak toplu şekilde kaydedilmemiştir. Bunun yerine her örneğin kaynak görüntüsü, sınıf bilgisi, koordinatları, patch boyutu, veri ayrımı ve örnek türü gibi bilgilerini içeren patch metadata dosyaları oluşturulmuştur. Bu yaklaşım, gereksiz dosya çoğalmasını önlemiş ve sonraki aşamada özellik çıkarımının daha kontrollü şekilde yapılmasını sağlamıştır.

Patch metadata oluşturulduktan sonra HOG, HSV, LBP ve PCA tabanlı özellik çıkarım süreci uygulanmıştır. Elde edilen özellikler, Linear SVM, RBF SVM ve Random Forest modellerinin eğitiminde kullanılacak sayısal veri yapısını oluşturmuştur. Böylece Varroa Dataset, geleneksel makine öğrenmesi hattında önce görüntü bölgeleri düzeyinde Varroa var/yok sınıflandırması için hazırlanmış, daha sonra bu sınıflandırıcıların sliding-window tabanlı nesne tespiti sürecinde kullanılmasına uygun hale getirilmiştir.

4.1.2. CNN Tabanlı Modeller İçin Hazırlık

Varroa Dataset veri seti, CNN tabanlı modeller kapsamında hem nesne tespiti hem de sınıflandırma görevleri için hazırlanmıştır. Bu çalışmada CNN tabanlı modeller içerisinde ResNet18, EfficientNet-B0, YOLOv8n ve YOLO26n modelleri kullanılmıştır. ResNet18 ve EfficientNet-B0 modelleri görüntü düzeyinde binary classification amacıyla kullanılırken, YOLOv8n ve YOLO26n modelleri nesne tespiti amacıyla değerlendirilmiştir.

YOLO tabanlı modeller için Varroa Dataset, tek sınıflı nesne tespiti formatına dönüştürülmüştür. Veri setinin orijinal yapısında arı ve varroa gibi farklı sınıflar bulunabildiği için, çalışma hedefi doğrultusunda yalnızca varroa sınıfı dikkate alınmıştır. Varroa dışındaki sınıflar eğitim sürecine dahil edilmemiş ve geçerli varroa

etiketleri 0: *varroa* olacak şekilde standartlaştırılmıştır. Böylece YOLOv8n ve YOLO26n modellerinin doğrudan hedef nesne olan varroa parazite odaklanması sağlanmıştır.

ResNet18 ve EfficientNet-B0 modelleri için aynı veri seti binary classification formatına dönüştürülmüştür. Bu dönüşümde YOLO etiket dosyaları kontrol edilmiş, etiket dosyasında en az bir geçerli varroa bounding box bulunan görüntüler *varroa* sınıfına dahil edilmiştir. Etiket dosyası boş olan veya geçerli varroa etiketi içermeyen görüntüler ise *no_varroa* sınıfı olarak kabul edilmiştir. Bu sayede sınıflandırma modelleri görüntü düzeyinde varroa var/yok tahmini yapabilecek hale getirilmiştir.

Classification deneylerinde görüntüler 224x224 boyutuna dönüştürülmüş ve ImageNet üzerinde önceden eğitilmiş modellerle uyumlu olacak şekilde normalize edilmiştir. YOLO modellerinde ise 640x640 giriş görüntü boyutu kullanılmıştır. Varroa paraziti küçük nesne karakteri taşıdığı için, nesne tespiti modellerinde görüntü boyutunun korunması modelin hedef nesneyi daha iyi öğrenebilmesi açısından önemli görülmüştür.

4.1.3. Transformer Tabanlı Modeller İçin Hazırlık

Varroa Dataset veri seti, Transformer tabanlı nesne tespiti modellerinin değerlendirilmesi amacıyla hazırlanmıştır. Bu kapsamda DETR, Deformable DETR ve RT-DETR mimarileri kullanılmıştır. Proje kapsamında kullanılan veri setinin ön işleme adımlarında, modellerin uçtan uca dikkat mekanizmalarına dayalı özgün yapılarını korumak ve veri uyumsuzluklarını önlemek amacıyla harici bir manipülasyon yerine doğrudan bu mimarilere ait resmi ve yerleşik görüntü işlemcileri kullanılmıştır.

Bu doğrultuda, ilgili veri setindeki tüm görüntüler ve etiketler, modellerin kendi protokollerine tabi tutulmuştur. Bu süreçte yerleşik işlemciler, nesnelerin morfolojik bütünlüğünü korumak adına en-boy oranını gözeterek otomatik yeniden boyutlandırma yapmış, omurga ağlarının standartlarına uyum sağlamak amacıyla kanal tabanlı normalizasyon uygulamış ve veri yığımındaki farklı çözünürlükleri eşitlemek için dolgulama işlemi gerçekleştirmiştir.

Ayrıca, Transformer bloklarının bu dolgulu alanları ayırt edebilmesi için piksel maskeleri üretilmiş ve hedef sınırlayıcı kutu koordinatları modellerin doğrudan işleyebileceği merkez odaklı, normalize edilmiş bir formata dönüştürülmüştür. Böylece veri setinin öznitelik bütünlüğü korunarak modellerin girdi gereksinimleriyle tam uyumlu, standardize edilmiş tensör yapıları elde edilmiş ve eğitim sürecine aktarılmıştır.

4.2. HoneyBee VarroaMite Veri Setinin Hazırlanması

HoneyBee VarroaMite veri seti, proje kapsamında kullanılan ikinci geliştirme veri setidir. Bu veri seti, Varroa parazitinin arı görüntüleri üzerinde tespit edilmesine yönelik etiketler içermektedir. Varroa Dataset'ten farklı olarak bu veri setinde hedef yapı daha çok Varroa akarına odaklanmaktadır. Bu nedenle HoneyBee VarroaMite veri seti,

morfolojik odaklı öğrenme yaklaşımını değerlendirmek ve farklı veri dağılımlarının model başarısı üzerindeki etkisini incelemek amacıyla kullanılmıştır.

Veri seti, geleneksel makine öğrenmesi, CNN tabanlı modeller ve transformer tabanlı modeller için ayrı ön işleme adımlarından geçirilmiştir. Bu süreçte görüntü ve etiket dosyalarının eşleşmesi, geçerli Varroa etiketlerinin belirlenmesi, problemli etiket kayıtlarının kontrol edilmesi ve model ailelerine uygun veri yapılarının oluşturulması temel hazırlık adımlarını oluşturmuştur.

4.2.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Hazırlık

HoneyBee VarroaMite veri seti, geleneksel makine öğrenmesi hattında Varroa odaklı ikinci geliştirme veri seti olarak kullanılmıştır. Bu veri setinin etiket yapısı Varroa akarına odaklandığı için, geçerli YOLO etiket satırları pozitif örnek kaynağı olarak değerlendirilmiştir. Etiket dosyasında geçerli Varroa bounding box bilgisi bulunan bölgeler pozitif örnek, Varroa içermeyen uygun görüntü bölgeleri ise negatif örnek olarak kullanılmıştır.

Veri hazırlama sürecinde görüntü ve etiket dosyalarının eşleşmesi, boş etiket dosyaları, geçersiz YOLO satırları ve uç değer niteliği taşıyan bounding box kayıtları kontrol edilmiştir. Bu kontroller sonucunda model eğitimini olumsuz etkileyebilecek hatalı veya tutarsız etiketlerin veri hazırlama sürecine etkisi azaltılmıştır. HoneyBee VarroaMite veri setinde boş etiket dosyaları, Varroa içermeyen görüntüler olarak değerlendirilmiş; ancak geçersiz etiket satırı bulunan görüntüler negatif örnek kaynağı olarak kullanılmamıştır.

Bu veri setinde Varroa nesne boyutları ve görüntü yapısı dikkate alınarak 48×48, 64×64 ve 80×80 boyutlarında görüntü bölgeleri hazırlanmıştır. Bu farklı boyutlar, modelin hedef nesneye yakın dar bağlam ile daha geniş çevresel bağlam arasındaki performans farkını incelemek için kullanılmıştır. Bu patch boyutları, HoneyBee VarroaMite veri setindeki Varroa nesne boyutları ve görüntü yapısı dikkate alınarak belirlenmiştir.

Varroa Dataset'te olduğu gibi, HoneyBee VarroaMite veri setinde de görüntü bölgeleri fiziksel dosyalar olarak toplu biçimde kaydedilmemiştir. Bunun yerine her örneğin kaynak görüntüsü, koordinat bilgisi, sınıf etiketi, patch boyutu, veri ayrımı ve örnek türünü içeren patch metadata dosyaları oluşturulmuştur. Bu metadata yapısı daha sonra özellik çıkarım aşamasında kullanılmıştır.

Hazırlanan görüntü bölgelerinden HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılmıştır. Bu özellikler kullanılarak Linear SVM, RBF SVM ve Random Forest modelleri için binary classification veri yapısı oluşturulmuştur. Böylece HoneyBee VarroaMite veri seti, geleneksel makine öğrenmesi hattında Varroa odaklı morfolojik öğrenme yaklaşımını temsil edecek şekilde hazırlanmıştır.

4.2.2. CNN Tabanlı Modeller İçin Hazırlık

HoneyBee VarroaMite veri seti de CNN tabanlı modeller kapsamında hem sınıflandırma hem de nesne tespiti deneyleri için hazırlanmıştır. Bu veri seti, arı görüntüleri üzerinde Varroa parazitinin tespit edilmesine yönelik etiketlenmiş görüntülerden oluşmaktadır. Deneysel süreçte bu veri seti, Varroa Dataset ile benzer şekilde YOLOv8n, YOLO26n, ResNet18 ve EfficientNet-B0 modellerinde kullanılmıştır.

YOLOv8n ve YOLO26n modelleri için HoneyBee VarroaMite veri seti tek sınıflı nesne tespiti formatında değerlendirilmiştir. Veri setindeki etiketler kontrol edilmiş ve hedef sınıf *varroa* olacak şekilde düzenlenmiştir. Böylece nesne tespiti modelleri, görüntü üzerinde Varroa parazitinin konumunu bounding box ile tespit edecek şekilde eğitilmiştir.

ResNet18 ve EfficientNet-B0 modelleri için HoneyBee VarroaMite veri seti binary classification yapısına dönüştürülmüştür. Etiket dosyasında en az bir geçerli Varroa bounding box bulunan görüntüler *varroa*, geçerli Varroa etiketi bulunmayan görüntüler ise *no_varroa* sınıfı olarak değerlendirilmiştir. Bu yapı sayesinde sınıflandırma modelleri, görüntünün tamamına bakarak Varroa paraziti bulunup bulunmadığını tahmin edecek biçimde eğitilmiştir.

HoneyBee VarroaMite veri seti, Varroa Dataset ile birlikte kullanılarak farklı eğitim veri kaynaklarının model başarısı üzerindeki etkisini incelemek amacıyla değerlendirilmiştir. Bu nedenle her model, Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerinde ayrı ayrı eğitilmiş ve daha sonra external validation veri seti üzerinde test edilmiştir. Bu yaklaşım, veri setleri arasındaki dağılım farklarının CNN tabanlı modeller üzerindeki etkisini analiz etmeyi mümkün kılmıştır.

4.2.3. Transformer Tabanlı Modeller İçin Hazırlık

HoneyBee VarroaMite veri seti, Transformer tabanlı nesne tespiti modellerinin değerlendirilmesi amacıyla hazırlanmıştır. Bu kapsamda DETR, Deformable DETR ve RT-DETR mimarileri kullanılmıştır. Proje kapsamında kullanılan veri setinin ön işleme adımlarında, modellerin uçtan uca dikkat mekanizmalarına dayalı özgün yapılarını korumak ve veri uyumsuzluklarını önlemek amacıyla harici bir manipülasyon yerine doğrudan bu mimarilere ait resmi ve yerleşik görüntü işlemcileri kullanılmıştır.

Bu doğrultuda, ilgili veri setindeki tüm görüntüler ve etiketler, modellerin kendi protokollerine tabi tutulmuştur. Bu süreçte yerleşik işlemciler, nesnelerin morfolojik bütünlüğünü korumak adına en-boy oranını gözeterek otomatik yeniden boyutlandırma yapmış, omurga ağlarının standartlarına uyum sağlamak amacıyla kanal tabanlı normalizasyon uygulamış ve veri yığınındaki farklı çözünürlükleri eşitlemek için dolgulama işlemi gerçekleştirmiştir.

Ayrıca, Transformer bloklarının bu dolgulu alanları ayırt edebilmesi için piksel maskeleri üretilmiş ve hedef sınırlayıcı kutu koordinatları modellerin doğrudan işleyebileceği merkez odaklı, normalize edilmiş bir formata dönüştürülmüştür. Böylece veri setinin öznitelik bütünlüğü korunarak modellerin girdi gereksinimleriyle tam uyumlu, standardize edilmiş tensör yapıları elde edilmiş ve eğitim sürecine aktarılmıştır.

4.3. Varroa Mites Detector Veri Setinin External Validation İçin Kullanılması

Varroa Mites Detector veri seti, proje kapsamında bağımsız dış test veri seti olarak kullanılmıştır. Bu veri seti, model geliştirme, model seçimi ve parametre ayarlama süreçlerinde kullanılmamış; yalnızca nihai aşamada modellerin farklı bir veri kaynağı üzerindeki genellenebilirliğini değerlendirmek amacıyla deneysel sürece dahil edilmiştir.

Bu veri setinin ayrı tutulması, geliştirilen modellerin yalnızca kendi eğitim veri setlerine yakın görüntülerdeki başarısını değil, farklı görüntüleme koşulları ve farklı etiketleme yapısına sahip veriler üzerindeki başarısını da analiz etmeyi sağlamıştır. Özellikle Varroa tespiti gibi hedef nesnenin küçük olduğu, görüntü koşullarının değişebildiği ve anotasyon yapısının model performansını etkileyebildiği problemlerde dış değerlendirme önemli bir aşamadır.

Varroa Mites Detector veri seti; geleneksel makine öğrenmesi, CNN tabanlı modeller ve transformer tabanlı modeller için ayrı hazırlık süreçlerinden geçirilmiştir. Her model ailesinde, bu veri seti eğitim veya tuning amacıyla değil, yalnızca external validation kapsamında nihai değerlendirme amacıyla kullanılmıştır.

4.3.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin External Validation Hazırlığı

Geleneksel makine öğrenmesi hattında Varroa Mites Detector veri seti, sabitlenmiş finalist modellerin bağımsız dış test verisi üzerindeki başarısını ölçmek için kullanılmıştır. Bu aşamada veri seti herhangi bir model eğitimi, yeniden eğitim, hiperparametre seçimi veya eşik ayarlama amacıyla kullanılmamıştır. Böylece external validation sürecinde veri sızıntısı oluşmaması ve modellerin gerçek genellenebilirlik düzeyinin ölçülmesi amaçlanmıştır.

External validation hazırlığında öncelikle veri setinin test bölümündeki görüntü ve etiket dosyaları kontrol edilmiştir. Görüntü-label eşleşmeleri, boş etiket dosyaları, geçersiz YOLO satırları ve Varroa bounding box kayıtları incelenmiştir. Geçerli Varroa etiketleri, dış değerlendirme sırasında hem classification diagnostic hem de full-image detection değerlendirmesi için referans olarak kullanılmıştır.

Geleneksel makine öğrenmesi hattında external validation iki aşamada ele alınmıştır. İlk aşamada, finalist modellerin görüntü bölgeleri üzerindeki Varroa var/yok sınıflandırma

başarısını görebilmek için external classification diagnostic yapısı hazırlanmıştır. Bu amaçla Dataset3 üzerinde yalnızca değerlendirme için pozitif ve negatif görüntü bölgeleri tanımlanmış, bu bölgelerden ilgili model konfigürasyonlarına uygun HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılmıştır. Bu işlem model eğitimi amacı taşımamış, yalnızca sabit modellerin dış veri üzerindeki sınıflandırma davranışını incelemek için uygulanmıştır.

İkinci aşamada ise aynı finalist modeller, sabit detection parametreleriyle tam görüntü üzerinde sliding-window tabanlı nesne tespiti için kullanılmıştır. Bu süreçte modeller görüntü üzerinde belirli adımlarla gezdirilmiş, her pencere için Varroa skoru üretilmiş, eşik değerini geçen aday bölgeler post-processing adımlarından geçirilmiş ve nihai tespit kutuları oluşturulmuştur. Eşik değeri, stride, kümeleme eşiği ve kutu boyutu gibi parametreler external validation verisine göre değiştirilmemiştir.

Bu hazırlık sayesinde Varroa Mites Detector veri seti, geleneksel makine öğrenmesi hattında hem görüntü bölgesi düzeyindeki sınıflandırma davranışını hem de tam görüntü üzerindeki nesne tespiti performansını değerlendirmek için kullanılmıştır. Böylece modellerin bağımsız dış veri üzerindeki genellenebilirliği, eğitim veri setlerinden farklı bir dağılım altında analiz edilmiştir.

4.3.2. CNN Tabanlı Modeller İçin External Validation Hazırlığı

Varroa Mites Detector veri seti, CNN tabanlı modellerin external validation sürecinde kullanılmıştır. Bu veri seti, model eğitimlerinde kullanılmamış ve yalnızca eğitilen modellerin farklı bir veri kaynağı üzerindeki genelleme başarısını ölçmek amacıyla değerlendirilmiştir. Bu sayede modellerin yalnızca kendi eğitim veri setlerine yakın görüntülerdeki performansı değil, daha önce görmedikleri farklı veri dağılımındaki başarıları da incelenmiştir.

YOLOv8n ve YOLO26n modelleri için Varroa Mites Detector veri seti tek sınıflı varroa nesne tespiti formatında hazırlanmıştır. Bu yapıda her görüntüye ait etiket dosyası kontrol edilmiş ve varroa paraziti temsil eden bounding box bilgileri değerlendirilmiştir. Model, external validation aşamasında bu veri setindeki varroa nesnelerini tespit etmeye çalışmıştır.

ResNet18 ve EfficientNet-B0 modelleri için aynı external validation veri seti binary classification formatına dönüştürülmüştür. Etiket dosyasında geçerli varroa bounding box bulunan görüntüler *varroa*, geçerli varroa etiketi bulunmayan görüntüler ise *no_varroa* sınıfına dahil edilmiştir. Böylece classification modellerinin farklı veri kaynağındaki varroa var/yok tahmin başarıları ölçülmüştür.

External validation veri setinin ayrı tutulması, CNN tabanlı modellerin genelleme performansını değerlendirmek açısından önemli bir adımdır. Özellikle varroa tespiti gibi görüntü çözünürlüğü, ışık koşulları, arı pozisyonu, varroa görünürlüğü ve anotasyon

tarzı deęiřebilen problemlerde, external validation sonuçları modelin gereki bařarısını daha iyi gstermektedir.

4.3.3. Transformer Tabanlı Modeller İin External Validation Hazırlığı

Varroa Mites Detector veri seti, Transformer tabanlı nesne tespiti modellerinin external validation srecinde deęerlendirilmesi amacıyla hazırlanmıřtır. Bu kapsamda DETR, Deformable DETR ve RT-DETR mimarileri kullanılmıřtır. Proje kapsamında kullanılan veri setinin n iřleme adımlarında, modellerin utan ua dikkat mekanizmalarına dayalı zgn yapılarını korumak ve veri uyumsuzluklarını nlemek amacıyla harici bir maniplasyon yerine doęrudan bu mimarilere ait resmi ve yerleřik grnt iřlemcileri kullanılmıřtır.

Bu doęrultuda, ilgili veri setindeki tm grntler ve etiketler, modellerin kendi protokollerine tabi tutulmuřtur. Bu srete yerleřik iřlemciler, nesnelerin morfolojik btnlęn korumak adına en-boy oranını gzeterek otomatik yeniden boyutlandırma yapmıř, omurga aęlarının standartlarına uyum saęlamak amacıyla kanal tabanlı normalizasyon uygulamıř ve veri yığındaki farklı znrlkleri eřitlemek iin dolgulama iřlemi gerekleřtirmiřtir.

Ayrıca, Transformer bloklarının bu dolgulu alanları ayırt edebilmesi iin piksel maskeleri retilmiř ve hedef sınırlayıcı kutu koordinatları modellerin doęrudan iřleyebileęi merkez odaklı, normalize edilmiř bir formata dnřtrlmřtr. Bylece veri setinin znitelik btnlę korunarak modellerin girdi gereksinimleriyle tam uyumlu, standardize edilmiř tensr yapıları elde edilmiř ve eęitim srecine aktarılmıřtır.

4.4. Etiket Yapılarının Dzenlenmesi

Projede kullanılan veri setleri farklı kaynaklardan elde edildięi iin etiket yapıları, sınıf adları ve anotasyon biimleri arasında bazı farklılıklar bulunmaktadır. Bu nedenle model eęitimleri ve deęerlendirmeleri ncesinde etiket dosyaları incelenmiř, geerli sınıf bilgileri belirlenmiř ve model ailelerinin ihtiya duyduęu formata uygun dzenlemeler yapılmıřtır.

Nesne tespiti modellerinde etiketler, hedef nesnenin grnt zerindeki konumunu belirten bounding box bilgileriyle birlikte kullanılmıřtır. Sınıflandırma tabanlı modellerde ise bu etiketler doęrudan konum tahmini iin deęil, grntnn veya grnt blgesinin Varroa ierip iermedięini belirlemek amacıyla kullanılmıřtır. Bu nedenle etiket dzenleme sreci, model ailesine ve deney trne gre farklı biimlerde uygulanmıřtır.

Etiket dzenleme srecinde geersiz YOLO satırları, hatalı sınıf bilgileri, sıfır geniřlik veya ykseklіęe sahip bounding box kayıtları ve model eęitimini olumsuz etkileyebilecek u deęer nitelięindeki anotasyonlar kontrol edilmiřtir. Bylece her model ailesinin daha tutarlı ve gvenilir veri ile eęitilmesi hedeflenmiřtir.

4.4.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Etiket Düzenleme

Geleneksel makine öğrenmesi hattında etiket düzenleme süreci, görüntü bölgeleri üzerinden oluşturulacak pozitif ve negatif örneklerin doğru belirlenebilmesi amacıyla yürütülmüştür. Bu süreçte YOLO formatındaki etiket dosyaları okunmuş, her görüntü için geçerli Varroa bounding box kayıtları belirlenmiş ve bu kayıtlar pozitif örnek üretimi için temel alınmıştır.

Varroa Dataset veri setinde hem arı hem de Varroa sınıflarına ait etiketler bulunduğu için, sınıf ayrımı özellikle korunmuştur. Bu veri setinde yalnızca Varroa sınıfına ait geçerli bounding box kayıtları pozitif örnek olarak değerlendirilmiş, arı sınıfına ait etiketler Varroa pozitif örneği olarak kullanılmamıştır. HoneyBee VarroaMite veri setinde ise etiket yapısı Varroa akarına odaklandığı için geçerli YOLO satırları pozitif kaynak olarak değerlendirilmiştir.

Negatif örneklerin belirlenmesinde, görüntüde geçerli Varroa etiketi bulunmaması temel alınmıştır. Ancak bu süreçte veri setlerine özgü istisnalar dikkate alınmıştır. Varroa Dataset içerisinde boş etiket dosyaları güvenilir negatif kaynak olarak kullanılmamış ve bu görüntüler dışlanmıştır. HoneyBee VarroaMite veri setinde ise boş etiket dosyaları `no_varroa` görüntüleri olarak değerlendirilmiş; buna karşılık geçersiz YOLO satırı içeren görüntüler negatif örnek kaynağı olarak kullanılmamıştır.

Etiket düzenleme aşamasında ayrıca uç değer niteliğindeki Varroa bounding box kayıtları kontrol edilmiştir. Normalden belirgin biçimde büyük veya tutarsız görünen bounding box kayıtları pozitif örnek üretiminden çıkarılmıştır. Bu işlem görüntünün tamamının dışlanması anlamına gelmemektedir; yalnızca problemli bounding box kaydından pozitif görüntü bölgesi üretilmemiştir. Aynı görüntüde başka geçerli Varroa etiketleri varsa bu etiketler kullanılmaya devam edilmiştir.

Bu düzenlemeler sonucunda geleneksel makine öğrenmesi modelleri için daha güvenilir pozitif ve negatif örnekler tanımlanmış, sonraki aşamada oluşturulan patch metadata dosyalarının hatalı veya tutarsız etiketlerden etkilenmesi azaltılmıştır. Böylece HOG, HSV, LBP ve PCA tabanlı özellik çıkarımı ile SVM ve Random Forest modellerinin eğitimi için daha kontrollü bir binary sınıflandırma yapısı hazırlanmıştır.

4.4.2. CNN Tabanlı Modeller İçin Etiket Düzenleme

CNN tabanlı modeller için etiket düzenleme süreci, modelin görev tipine göre iki farklı şekilde ele alınmıştır. YOLOv8n ve YOLO26n modelleri nesne tespiti yaptığı için etiket dosyalarında sınıf id bilgisi ve bounding box koordinatları korunmuştur. ResNet18 ve EfficientNet-B0 modelleri ise görüntü düzeyinde sınıflandırma yaptığı için bu etiketler doğrudan bounding box tahmini için değil, görüntünün *varroa* veya *no_varroa* sınıfına ayrılması için kullanılmıştır.

YOLO tabanlı modellerde tüm veri setleri tek sınıflı *varroa* yapısına dönüştürülmüştür. Varroa Dataset içerisinde bulunan Varroa dışındaki sınıflar eğitim sürecinden çıkarılmış ve geçerli Varroa etiketleri 0: *varroa* olacak şekilde düzenlenmiştir. Bu standardizasyon, farklı veri setlerinde sınıf id değerlerinin tutarlı hale getirilmesini sağlamıştır.

Etiket dosyalarında bulunan bounding box kayıtları da kontrol edilmiştir. Genişliği veya yüksekliği sıfır olan, alan değeri geçersiz olan ya da model eğitimi olumsuz etkileyebilecek tutarsız etiketler temizlenmiştir. Bu işlem, özellikle nesne tespiti modellerinde hatalı bounding box bilgilerinin model öğrenmesini olumsuz etkilemesini önlemek amacıyla yapılmıştır.

Boş etiket dosyaları tamamen kaldırılmamıştır. Bu dosyalar, görüntüde Varroa bulunmadığını gösteren negatif örnekler olarak değerlendirilmiştir. YOLO modellerinde bu görüntüler arka plan örneklerinin öğrenilmesine katkı sağlarken, classification modellerinde *no_varroa* sınıfının oluşturulmasında kullanılmıştır.

4.4.3. Transformer Tabanlı Modeller İçin Etiket Düzenleme

DETR, Deformable DETR ve RT-DETR gibi Transformer tabanlı nesne tespiti modellerinin nesne konumlarını doğru anlamlandırabilmesi ve kayıp fonksiyonlarını hatasız hesaplayabilmesi için etiket verilerinin belirli bir matematiksel standartta düzenlenmesi gerekmektedir. Bu doğrultuda, veri setindeki sınırlayıcı kutuların geleneksel [x_min, y_min, x_max, y_max] formatındaki köşe koordinatları, modellerin yerleşik görüntü işlemcileri tarafından merkez odaklı [x_center, y_center, width, height] formatına dönüştürülmüştür. Görüntülerin en-boy oranı korunarak yeniden boyutlandırılması ve dolgulanması süreçleriyle senkronize şekilde yürütülen bu adımda, tüm etiket koordinatları piksel değerlerinden arındırılarak [0, 1] aralığına normalize edilmiştir. Bu düzenleme sayesinde hem görsel öznitelikler ile konum etiketleri arasındaki mekânsal tutarlılık korunmuş hem de modellerin piksellerden bağımsız, ölçeklenebilir bağıntılar kurması sağlanmıştır.

4.5. Classification Deneyleri İçin Binary Veri Yapısının Oluşturulması

Classification deneylerinde temel amaç, modelin verilen bir örnekte Varroa paraziti bulunup bulunmadığını iki sınıf üzerinden tahmin etmesini sağlamaktır. Bu nedenle veri setleri, model ailesine göre uygun binary classification yapısına dönüştürülmüştür. Genel olarak pozitif sınıf Varroa içeren örnekleri, negatif sınıf ise Varroa içermeyen örnekleri temsil etmektedir.

CNN tabanlı sınıflandırma modellerinde bu yapı görüntü düzeyinde kurulmuştur. Bir görüntünün etiket dosyasında geçerli Varroa bounding box kaydı bulunuyorsa görüntü Varroa sınıfına, geçerli Varroa etiketi bulunmuyorsa *no_varroa* sınıfına atanmıştır. Geleneksel makine öğrenmesi hattında ise binary yapı doğrudan tam görüntü üzerinden değil, görüntülerden elde edilen bölgeler üzerinden oluşturulmuştur.

Bu ayrım, model ailelerinin çalışma biçimlerinden kaynaklanmaktadır. CNN tabanlı sınıflandırma modelleri görüntünün tamamını girdi olarak alırken, geleneksel makine öğrenmesi modelleri önceden belirlenen görüntü bölgelerinden çıkarılan sayısal özellikler üzerinden sınıflandırma yapmıştır. Bu nedenle binary veri yapısı her model ailesi için aynı amaca hizmet etse de uygulama düzeyi farklılık göstermiştir.

4.5.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Binary Veri Yapısı

Geleneksel makine öğrenmesi tabanlı modeller için binary veri yapısı, tam görüntüler yerine görüntü bölgeleri üzerinden oluşturulmuştur. Bu yapıda pozitif sınıf, geçerli Varroa bounding box kayıtlarından elde edilen görüntü bölgelerini; negatif sınıf ise Varroa içermeyen uygun görüntü bölgelerini temsil etmektedir. Böylece modellerin görevi, verilen bir görüntü bölgesinde Varroa paraziti bulunup bulunmadığını tahmin etmek olarak tanımlanmıştır.

Pozitif örnekler, veri setlerindeki geçerli Varroa etiketlerinden üretilmiştir. Varroa Dataset veri setinde yalnızca Varroa sınıfına ait bounding box kayıtları pozitif örnek olarak kullanılmış, arı sınıfına ait etiketler pozitif kaynak olarak değerlendirilmemiştir. HoneyBee VarroaMite veri setinde ise geçerli YOLO etiket satırları Varroa odaklı pozitif örnek kaynağı olarak kabul edilmiştir. Uç değer niteliğindeki veya tutarsız bounding box kayıtları pozitif örnek üretiminden çıkarılmıştır.

Negatif örnekler, Varroa içermeyen görüntülerden veya Varroa bounding box'larıyla çakışmayan uygun görüntü bölgelerinden elde edilmiştir. Bu süreçte negatif örneklerin yanlışlıkla Varroa içeren bölgelerden seçilmemesi için koordinat ve çakışma kontrolleri uygulanmıştır. Ayrıca negatif örnekler, modelin arka plan ve arı dokusu gibi Varroa dışı görsel örüntüleri öğrenebilmesi için farklı görüntü bölgelerinden seçilmiştir.

Bu çalışma kapsamında her patch boyutu için iki farklı sınıf dengesi yaklaşımı oluşturulmuştur: balanced ve neg4x. Balanced yapıda pozitif ve negatif örnek sayıları eşit tutulmuştur. Neg4x yapıda ise negatif örnek sayısı pozitif örnek sayısının dört katı olacak şekilde düzenlenmiştir. Balanced yapı kontrollü ve dengeli bir sınıflandırma ortamı sağlarken, neg4x yapı tam görüntü üzerinde karşılaşılan yoğun negatif pencere durumunu daha iyi temsil etmek amacıyla kullanılmıştır. Bu iki yapı, modelin dengeli veri ile eğitildiğinde ve daha fazla negatif örnek gördüğünde nasıl performans gösterdiğini karşılaştırmak amacıyla değerlendirilmiştir.

Oluşturulan binary veri yapısı, fiziksel patch görüntüleri olarak toplu biçimde kaydedilmemiştir. Bunun yerine her örneğe ait kaynak görüntü, koordinat, sınıf etiketi, patch boyutu, split bilgisi ve örnek türü gibi bilgiler patch metadata dosyalarında tutulmuştur. Daha sonra bu metadata dosyaları üzerinden HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılmış ve elde edilen sayısal özellik tabloları SVM ile Random Forest modellerinin eğitiminde kullanılmıştır.

4.5.2. CNN Tabanlı Modeller İçin Binary Veri Yapısı

CNN tabanlı sınıflandırma modelleri olan ResNet18 ve EfficientNet-B0 için veri setleri binary classification formatına dönüştürülmüştür. Bu dönüşümün amacı, modellerin görüntüde Varroa paraziti bulunup bulunmadığını iki sınıf üzerinden tahmin edebilmesini sağlamaktır. Bu kapsamda sınıflar *varroa* ve *no_varroa* olarak belirlenmiştir.

Binary veri yapısı oluşturulurken YOLO formatındaki etiket dosyalarından yararlanılmıştır. Her görüntünün etiket dosyası kontrol edilmiş ve etiket dosyasında en az bir geçerli Varroa bounding box bulunması durumunda görüntü *varroa* sınıfına atanmıştır. Etiket dosyası boş olan veya geçerli Varroa etiketi içermeyen görüntüler ise *no_varroa* sınıfına dahil edilmiştir.

Bu yapı sayesinde ResNet18 ve EfficientNet-B0 modelleri, nesnenin görüntü üzerindeki konumunu tahmin etmek yerine görüntünün tamamı üzerinden sınıflandırma yapacak şekilde eğitilmiştir. YOLO modellerinden farklı olarak bu modeller bounding box üretmemekte, yalnızca görüntü düzeyinde Varroa var/yok kararı vermektedir.

Classification deneylerinde görüntüler 224x224 boyutuna getirilmiş ve ImageNet ön eğitilmiş modellerle uyumlu olacak şekilde normalize edilmiştir. Bu işlem, transfer learning yaklaşımının daha etkili kullanılmasını sağlamıştır. Böylece ResNet18 ve EfficientNet-B0 modellerinin önceden öğrenilmiş görsel özelliklerden yararlanarak Varroa sınıflandırma görevine uyarlanması hedeflenmiştir.

4.5.3. Transformer Tabanlı Modeller İçin Binary Veri Yapısı

DETR, Deformable DETR ve RT-DETR mimarileri doğası gereği çok sınıflı nesne tespiti yapabilme kapasitesine sahip olsalar da, projede tek bir hedef nesneye odaklanıldığı için etiketleme mantığı ikili (binary) bir veri yapısına indirgenmiştir. Bu doğrultuda veri yapısı; hedef nesnenin bulunduğu sınırlayıcı kutuları ifade eden "pozitif" sınıf (Sınıf 0) ve nesne barındırmayan alanları ya da boş nesne sorgularını (object queries) ifade eden "negatif/arka plan" (no-object) sınıfı olmak üzere iki temele oturtulmuştur. Transformer modelinin sınıflandırma kafası, her bir nesne sorgusu için bu ikili yapı üzerinden olasılık tahminleri üretmektedir.

4.6. Veri Seti Dağılımlarının Tablo Halinde Sunulması

Veri seti dağılımlarının incelenmesi, model eğitim sürecinde sınıf dengesizliğinin ve veri setleri arasındaki farklılıkların anlaşılması açısından önemlidir. Varroa tespiti probleminde bazı veri setlerinde Varroa içermeyen görüntüler daha fazla iken, bazı veri setlerinde Varroa içeren görüntüler daha baskın durumdadır. Bu farklılıklar, modellerin öğrenme davranışını, yanlış pozitif üretme eğilimini ve farklı veri kaynaklarına genellenebilirliğini doğrudan etkileyebilmektedir.

Bu nedenle çalışmada kullanılan veri setleri train, validation ve test ayrımları temelinde incelenmiş; Varroa içeren ve Varroa içermeyen örneklerin dağılımları tablo halinde sunulmuştur. Bu dağılımlar, hem classification deneylerinde kullanılan binary veri yapısını hem de nesne tespiti deneylerinde kullanılan görüntü bazlı veri dengesini yorumlamak için temel referans olarak değerlendirilmiştir.

4.6.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller İçin Veri Dağılımı

Geleneksel makine öğrenmesi tabanlı modellerde veri dağılımı iki düzeyde değerlendirilmiştir. İlk düzeyde, veri setlerindeki görüntülerin Varroa içerip içermediği incelenmiştir. Bu inceleme, pozitif ve negatif kaynak görüntülerin genel dağılımını görmek açısından önemlidir. İkinci düzeyde ise patch metadata oluşturulduktan sonra elde edilen pozitif ve negatif görüntü bölgelerinin sayıları değerlendirilmiştir. Bu ayırım önemlidir; çünkü geleneksel makine öğrenmesi hattında modeller doğrudan tam görüntüler üzerinde değil, görüntülerden elde edilen bölgelerden çıkarılan özellikler üzerinde eğitilmiştir.

Varroa Dataset veri setinde Varroa içermeyen görüntülerin sayısı, Varroa içeren görüntülerden daha fazladır. Bu durum, negatif örneklerin oluşturulması açısından avantaj sağlarken, pozitif örneklerin dikkatli seçilmesini gerektirmiştir. HoneyBee VarroaMite veri setinde ise Varroa içeren görüntü sayısı daha yüksektir. Bu farklılık, iki veri setinin model geliştirme sürecinde farklı öğrenme koşulları sunduğunu göstermektedir. Varroa Mites Detector veri seti ise model geliştirme sürecine dahil edilmemiş, yalnızca external validation aşamasında bağımsız dış test veri seti olarak kullanılmıştır.

Geleneksel makine öğrenmesi hattında kullanılan görüntü düzeyindeki temel dağılımlar aşağıdaki tabloda verilmiştir.

Tablo 1. Geleneksel makine öğrenmesi deneylerinde kullanılan veri setlerinin ön işleme sonrası split bazlı görüntü dağılımları.

Veri Seti	Split	Varroa İçermeyen Görüntü	Varroa İçeren Görüntü	Toplam Görüntü
Varroa	Train	5521	2696	8217
Varroa	Validation	1441	426	1867

Varroa	Test	2190	1218	3408
HoneyBee	Train	4556	8058	12614
HoneyBee	Validation	273	517	790
HoneyBee	Test	286	504	790
External	Train	3058	1691	4749
External	Validation	375	218	593
External	Test	358	238	596

Tablodaki dağılımlar incelendiğinde, veri setleri arasında belirgin sınıf dengesi farklılıkları olduğu görülmektedir. Varroa Dataset içerisinde Varroa içermeyen görüntüler daha baskınken, HoneyBee VarroaMite veri setinde Varroa içeren görüntülerin oranı daha yüksektir. External validation amacıyla kullanılan Varroa Mites Detector veri setinde ise özellikle test bölümünde Varroa içermeyen görüntülerin daha fazla olduğu görülmektedir. Bu farklılıklar, modellerin internal ve external değerlendirme sonuçları arasındaki performans değişimlerini yorumlamak açısından dikkate alınmıştır.

Geleneksel makine öğrenmesi modelleri için bu görüntü düzeyindeki dağılımlar doğrudan eğitim girdisi anlamına gelmemektedir. Asıl model girdileri, bu görüntülerden elde edilen pozitif ve negatif görüntü bölgelerinden çıkarılan HOG, HSV, LBP ve PCA tabanlı özelliklerdir. Bu nedenle görüntü düzeyindeki dağılımlar, patch metadata oluşturma sürecinin kaynak veri yapısını açıklamak için kullanılmıştır.

4.6.2. CNN Tabanlı Modeller İçin Veri Dağılımı

CNN tabanlı modeller için oluşturulan binary classification veri yapısında veri setleri *varroa* ve *no_varroa* sınıflarına ayrılmıştır. Bu dağılım, ResNet18 ve EfficientNet-B0 modellerinin eğitim ve değerlendirme süreçlerinde kullanılmıştır. Aynı zamanda bu dağılım, veri setleri arasındaki sınıf dengesini incelemek açısından da önemlidir.

Varroa Dataset içerisinde *no_varroa* sınıfının daha yüksek sayıda olduğu görülmektedir. Buna karşılık HoneyBee VarroaMite veri setinde *varroa* sınıfına ait görüntü sayısı daha fazladır. External validation için kullanılan Varroa Mites Detector veri setinde ise *no_varroa* sınıfı daha baskındır. Bu farklılıklar, modellerin eğitim sürecinde sınıf dağılımlarından etkilenmesine neden olabilecek önemli bir faktördür.

CNN tabanlı classification deneylerinde kullanılan sınıf dağılımları aşağıdaki tabloda verilmiştir.

Tablo 2. CNN tabanlı classification modelleri için veri setlerinin varroa/no_varroa sınıf dağılımları.

Veri Seti	Split	Varroa İçermeyen Görüntü	Varroa İçeren Görüntü	Toplam Görüntü
Varroa	Train	5522	2695	8217
Varroa	Valid	1441	426	1867
Varroa	Test	2192	1216	3408
HoneyBee	Train	4556	8058	12614
HoneyBee	Valid	273	517	790
HoneyBee	Test	286	504	790
External	Train	3058	1691	4749
External	Valid	375	218	593
External	Test	358	238	596

Tablodaki dağılımlar incelendiğinde veri setlerinin sınıf dengesi açısından birbirinden farklı olduğu görülmektedir. Bu durum, modellerin internal validation ve external validation performansları arasındaki farklılıkların nedenlerinden biri olarak değerlendirilebilir. Özellikle external validation veri setindeki sınıf dağılımının eğitim

veri setlerinden farklı olması, modelin genelleme başarısını doğrudan etkileyebilmektedir.

4.6.3. Transformer Tabanlı Modeller İçin Veri Dağılımı

Varroa Dataset içerisinde *no_varroa* sınıfının daha yüksek sayıda olduğu görülmektedir. Buna karşılık HoneyBee VarroaMite veri setinde *varroa* sınıfına ait görüntü sayısı daha fazladır. External validation için kullanılan Varroa Mites Detector veri setinde ise *no_varroa* sınıfı daha baskındır. Bu farklılıklar, modellerin eğitim sürecinde sınıf dağılımlarından etkilenmesine neden olabilecek önemli bir faktördür.

Transformer tabanlı detection ve classification deneylerinde kullanılan sınıf dağılımları aşağıdaki tabloda verilmiştir.

Tablo 3. Transformer tabanlı modellerde kullanılan veri setlerinin varroa içeren ve varroa içermeyen görüntü sayılarına göre dağılımı.

Veri Seti	Split	Varroa İçermeyen Görüntü	Varroa İçeren Görüntü	Toplam Görüntü
Varroa	Train	5522	2695	8217
Varroa	Valid	1441	426	1867
Varroa	Test	2192	1216	3408
HoneyBee	Train	4556	8058	12614
HoneyBee	Valid	273	517	790
HoneyBee	Test	286	504	790
External	Train	3058	1691	4749
External	Valid	375	218	593
External	Test	358	238	596

Tablodaki dağılımlar incelendiğinde veri setlerinin sınıf dengesi açısından birbirinden farklı olduğu görülmektedir. Bu durum, modellerin internal validation ve external validation performansları arasındaki farklılıkların nedenlerinden biri olarak değerlendirilebilir. Özellikle external validation veri setindeki sınıf dağılımının eğitim veri setlerinden farklı olması, modelin genelleme başarısını doğrudan etkileyebilmektedir.

5. MODEL EĞİTİMLERİ

Bu bölümde, Varroa tespiti problemi kapsamında kullanılan farklı model ailelerinin eğitim süreçleri açıklanmaktadır. Çalışmada geleneksel makine öğrenmesi tabanlı modeller, CNN tabanlı sınıflandırma modelleri, YOLO tabanlı nesne tespiti modelleri ve transformer tabanlı nesne tespiti modelleri ayrı ayrı değerlendirilmiştir. Her model ailesi, kendi mimari yapısına ve görev türüne uygun veri hazırlama, eğitim ve değerlendirme adımlarıyla ele alınmıştır.

Model eğitimleri, veri setlerinin train, validation ve test ayrımları korunarak gerçekleştirilmiştir. Eğitim aşamasında modeller yalnızca train verisi üzerinde öğrenme yapmış, validation verisi model seçimi ve ara performans değerlendirmesi için kullanılmıştır. Nihai performans değerlendirmelerinde ise test verileri ve bağımsız external validation veri seti dikkate alınmıştır. Bu yapı, farklı model ailelerinin hem kendi veri dağılımları içerisindeki başarısını hem de farklı veri kaynaklarına karşı genellebilirliğini incelemeye olanak sağlamıştır.

5.1. Geleneksel Makine Öğrenmesi Tabanlı Modeller


Geleneksel makine öğrenmesi tabanlı deneylerde, Varroa tespiti problemi doğrudan tam görüntü üzerinden değil, görüntülerden elde edilen bölgeler üzerinden ele alınmıştır. Bu yaklaşımda öncelikle pozitif ve negatif görüntü bölgeleri tanımlanmış, ardından bu bölgelerden sayısal görsel özellikler çıkarılmıştır. Elde edilen özellikler, klasik makine öğrenmesi modellerinin eğitiminde kullanılmıştır.

Bu kapsamda HOG, HSV, LBP ve PCA tabanlı özellikler kullanılmıştır. HOG özellikleri görüntü bölgelerindeki kenar, yönelim ve şekil örüntülerini temsil etmek için kullanılmıştır. HSV tabanlı renk özellikleri, Varroa paraziti ile arı yüzeyi veya arka plan arasındaki renk dağılımı farklarını yakalamayı amaçlamıştır. LBP özellikleri ise yerel doku örüntülerini temsil ederek Varroa yüzey yapısının ayırt edilmesine katkı sağlamıştır. PCA ise özellikle yüksek boyutlu HOG özelliklerinde boyut indirgeme amacıyla değerlendirilmiş; böylece hem model eğitim maliyetinin azaltılması hem de gereksiz veya gürültülü özelliklerin etkisinin sınırlandırılması hedeflenmiştir.

Model geliştirme sürecinde Support Vector Machine ve Random Forest algoritmaları kullanılmıştır. SVM modelleri doğrusal ve RBF kernel tabanlı yapılarla değerlendirilmiş, Random Forest modeli ise karar ağaçları topluluğu üzerinden

sınıflandırma yapacak şekilde eğitilmiştir. İlk aşamada, hesaplama maliyetinin daha düşük olması nedeniyle Linear SVM modelleri kullanılarak farklı patch boyutları, balanced ve neg4x sınıf dengesi yaklaşımları ve farklı özellik seti kombinasyonları üzerinde geniş bir tarama yapılmıştır. Bu tarama sayesinde çok sayıda olası model konfigürasyonu karşılaştırılmış; daha sonra başarılı bulunan kombinasyonlar seçilerek RBF SVM ve Random Forest modelleriyle daha ayrıntılı eğitimler gerçekleştirilmiştir.

Geleneksel makine öğrenmesi hattında modeller önce görüntü bölgesi düzeyinde Varroa var/yok sınıflandırması yapmak üzere eğitilmiştir. Daha sonra seçilen modeller, sliding-window tabanlı bir yapı içerisinde tam görüntü üzerinde gezdirilerek Varroa konumlarının tahmin edilmesinde kullanılmıştır. Bu nedenle bu yaklaşımda sınıflandırma başarısı ile nesne tespiti başarısı ayrı aşamalarda değerlendirilmiştir.



Şekil 2. Geleneksel makine öğrenmesi tabanlı Varroa tespit akışı.

5.1.1. Support Vector Machine (SVM) Modeli

Support Vector Machine (SVM), geleneksel makine öğrenmesi tabanlı model geliştirme sürecinde kullanılan temel algoritmalarından biridir. Bu çalışmada SVM modelleri, görüntü bölgelerinden çıkarılan HOG, HSV, LBP ve PCA tabanlı özellikler üzerinden Varroa var/yok sınıflandırması yapmak amacıyla kullanılmıştır. SVM algoritmasının temel amacı, iki sınıfı birbirinden en iyi şekilde ayıran karar sınırını oluşturmaktır.

SVM deneyleri iki farklı yapı altında ele alınmıştır. İlk aşamada Linear SVM modelleri kullanılarak geniş bir model taraması gerçekleştirilmiştir. Bu aşamada farklı veri setleri, patch boyutları, sınıf dengesi yaklaşımları ve özellik setleri karşılaştırılmıştır. Linear SVM modelleri, hesaplama maliyetinin daha düşük olması ve çok sayıda kombinasyonu hızlı biçimde değerlendirmeye olanak sağlaması nedeniyle ilk tarama aşamasında tercih edilmiştir.

Linear SVM taraması sonucunda başarılı bulunan patch ve özellik kombinasyonları belirlenmiş, daha sonra bu kombinasyonlar üzerinde RBF kernel tabanlı SVM modelleri eğitilmiştir. RBF SVM, doğrusal olmayan karar sınırları oluşturabilmesi nedeniyle daha karmaşık sınıf ayrımlarını öğrenme potansiyeline sahiptir. Bu nedenle RBF SVM modelleri, Linear SVM ile belirlenen güçlü aday kombinasyonlar üzerinde daha ayrıntılı bir değerlendirme yapmak amacıyla kullanılmıştır.

SVM modellerinin eğitiminde yalnızca train split kullanılmış, validation split ise model seçimi ve ara değerlendirme amacıyla değerlendirilmiştir. Nihai model başarısı ise test split üzerinde ölçülmüştür. Bu yapı, modelin eğitim verisine aşırı uyum sağlamasının önüne geçmek ve değerlendirme sürecini daha güvenilir hale getirmek amacıyla uygulanmıştır.

SVM modellerinden elde edilen karar skorları, yalnızca görüntü bölgesi düzeyinde sınıflandırma için değil, aynı zamanda sliding-window tabanlı nesne tespiti sürecinde de kullanılmıştır. Tam görüntü üzerinde farklı konumlarda oluşturulan pencereler SVM modeliyle değerlendirilmiş, Varroa içerme olasılığı yüksek olan bölgeler aday tespit olarak alınmıştır. Daha sonra bu aday bölgeler eşikleme ve birleştirme adımlarından geçirilerek nihai Varroa tespitleri elde edilmiştir.

5.1.2. Random Forest Modeli

Random Forest, geleneksel makine öğrenmesi tabanlı deneylerde kullanılan bir diğer sınıflandırma algoritmasıdır. Bu model, birden fazla karar ağacının birlikte çalışmasına dayanan topluluk öğrenmesi yaklaşımını kullanır. Her bir karar ağacı, veri setinin farklı alt örnekleri ve özellikleri üzerinde eğitilir; nihai sınıflandırma kararı ise ağaçların ortak tahminleri üzerinden oluşturulur.

Bu çalışmada Random Forest modeli, görüntü bölgelerinden çıkarılan HOG, HSV, LBP ve PCA tabanlı özellikler kullanılarak Varroa var/yok sınıflandırması yapmak amacıyla değerlendirilmiştir. Random Forest algoritması, doğrusal olmayan ilişkileri öğrenebilmesi, farklı özellik türlerini birlikte kullanabilmesi ve aykırı değerlere karşı görece dayanıklı olması nedeniyle geleneksel makine öğrenmesi hattına dahil edilmiştir.

Random Forest modelleri, Linear SVM taraması sonucunda başarılı bulunan seçili patch ve özellik kombinasyonları üzerinde eğitilmiştir. Böylece tüm olası kombinasyonlar üzerinde yüksek maliyetli bir eğitim yapmak yerine, önce daha hızlı Linear SVM modelleriyle güçlü adaylar belirlenmiş; ardından bu adaylar Random Forest modeliyle daha ayrıntılı olarak değerlendirilmiştir. Bu yaklaşım, deneysel sürecin daha verimli ve yönetilebilir olmasını sağlamıştır.

Model eğitimi sırasında yalnızca train split kullanılmış, validation split ise ara değerlendirme ve model performansının izlenmesi için kullanılmıştır. Nihai başarı değerlendirmesi test split üzerinde yapılmıştır. Bu sayede Random Forest modellerinin eğitim verisi dışında kalan örneklerdeki başarısı daha güvenilir biçimde ölçülmüştür.

Random Forest modelleri de SVM modelleri gibi yalnızca görüntü bölgesi düzeyinde sınıflandırma amacıyla kullanılmamış, aynı zamanda sliding-window tabanlı nesne tespiti sürecine dahil edilmiştir. Tam görüntü üzerinde oluşturulan pencerelerden çıkarılan özellikler Random Forest modeliyle değerlendirilmiş, Varroa içerme olasılığı yüksek bölgeler aday tespit olarak belirlenmiştir. Bu adaylar daha sonra eşikleme ve birleştirme işlemlerinden geçirilerek nihai tespit sonuçları elde edilmiştir.

5.1.3. Sliding-Window Tabanlı Nesne Tespiti Yaklaşımı

Geleneksel makine öğrenmesi tabanlı modeller doğrudan tam görüntü üzerinde bounding box tahmini yapan nesne tespit modelleri değildir. Bu nedenle SVM ve Random Forest modellerinin tam görüntü üzerinde Varroa konumlarını belirleyebilmesi için sliding-window tabanlı bir tespit yaklaşımı kullanılmıştır. Bu yaklaşımda sınıflandırma modeli, görüntünün farklı bölgelerinde gezdirilerek her bölgenin Varroa içerip içermediği değerlendirilmiştir.

Sliding-window sürecinde tam görüntü üzerinde belirli boyutlarda pencereler oluşturulmuş ve bu pencereler belirli adım aralıklarıyla görüntü üzerinde kaydırılmıştır. Her pencere için HOG, HSV, LBP ve PCA tabanlı özellikler çıkarılmış, ardından ilgili pencere eğitilmiş SVM veya Random Forest modeliyle değerlendirilmiştir. Modelin Varroa sınıfına ait skorunun belirlenen eşik değerini aşması durumunda ilgili pencere aday tespit olarak kabul edilmiştir. Bu süreçte skor eşiği, stride divisor, cluster IoU threshold ve weighted box size factor gibi parametreler tespit performansını etkileyen temel değişkenler olarak değerlendirilmiştir. Skor eşiği aday pencerenin Varroa tespiti olarak kabul edilmesi için gereken minimum model skorunu, stride divisor pencerenin görüntü üzerinde hangi adım aralığıyla kaydırılacağını, cluster IoU threshold birbirine

yakın aday kutuların hangi örtüşme düzeyinde aynı nesneye ait kabul edileceğini, weighted box size factor ise birleştirme sonrası oluşturulan nihai kutunun boyutunu kontrol etmek amacıyla kullanılmıştır.

Aynı Varroa nesnesi etrafında birden fazla aday pencere oluşabildiği için, aday tespitler son aşamada birleştirme ve filtreleme işlemlerinden geçirilmiştir. Bu kapsamda birbirine yakın veya çakışan kutular gruplandırılmış, skor ve konum bilgileri dikkate alınarak nihai tespit kutuları oluşturulmuştur. Birleştirme sürecinde yüksek skorlu adayların konum bilgileri daha fazla dikkate alınmış ve nihai kutu boyutu ilgili parametreler yardımıyla ayarlanmıştır. Böylece çok sayıda aday pencere arasından daha anlamlı, tekrarı azaltılmış ve skor açısından daha güvenilir tespit sonuçları elde edilmiştir.

Bu yaklaşım sayesinde geleneksel makine öğrenmesi modelleri, yalnızca görüntü bölgesi düzeyinde sınıflandırma yapmakla kalmamış, tam görüntü üzerinde Varroa parazitinin konumunu tahmin edebilecek bir nesne tespiti hattına dönüştürülmüştür. Ancak bu yapı, doğrudan nesne tespiti yapan YOLO veya transformer tabanlı modellere kıyasla daha fazla ara adıma sahiptir. Bu nedenle sınıflandırma başarısı yüksek olsa bile tam görüntü tespit başarısı; pencere boyutu, kaydırma adımı, eşik değeri, kutu birleştirme yöntemi ve hedef nesnenin görüntüdeki boyutu gibi faktörlerden etkilenebilmektedir.

5.2. CNN Tabanlı Modeller

Bu bölümde varroa parazitinin tespiti için kullanılan CNN tabanlı modeller açıklanmıştır. Çalışma kapsamında CNN tabanlı modeller iki farklı görev türü üzerinden ele alınmıştır. ResNet18 ve EfficientNet-B0 modelleri görüntü düzeyinde binary classification amacıyla kullanılmıştır. Bu modellerin temel görevi, verilen bir görüntüde varroa paraziti bulunup bulunmadığını varroa ve no_varroa sınıfları üzerinden tahmin etmektir.

YOLOv8n ve YOLOv26n modelleri ise nesne tespiti amacıyla kullanılmıştır. Bu modeller yalnızca görüntüde varroa olup olmadığını belirlemekle kalmayıp, varroa parazitinin görüntü üzerindeki konumunu bounding box ile tahmin etmeyi hedeflemiştir. Bu nedenle CNN tabanlı modeller hem sınıflandırma hem de nesne tespiti açısından değerlendirilmiş, farklı görev yapılarının varroa tespiti problemindeki uygulanabilirliği incelenmiştir.

5.2.1. ResNet Modeli

Bu çalışmada CNN tabanlı sınıflandırma modellerinden biri olarak ResNet18 modeli kullanılmıştır. ResNet mimarisi, derin sinir ağlarında ortaya çıkabilen gradyan kaybolması problemini azaltmak amacıyla artık bağlantılar kullanan bir yapıya sahiptir. Bu sayede model, daha derin katmanlarda özellik çıkarımı yaparken önceki katmanlardan gelen bilgiyi koruyabilmektedir.

Proje kapsamında ResNet18 modeli, nesne tespiti yapmak yerine binary classification amacıyla kullanılmıştır. Bu nedenle modelin görevi, bir görüntüde Varroa parazitinin bulunup bulunmadığını belirlemek olarak tanımlanmıştır. YOLO formatındaki etiket dosyaları kullanılarak görüntüler iki sınıfa ayrılmıştır: *varroa* ve *no_varroa*. Etiket dosyasında en az bir geçerli Varroa bounding box bulunan görüntüler *varroa*, geçerli Varroa etiketi bulunmayan görüntüler ise *no_varroa* sınıfı olarak kabul edilmiştir.

ResNet18 modeli ImageNet üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır. Modelin son tam bağlantılı katmanı, iki sınıflı sınıflandırma problemine uygun olacak şekilde yeniden düzenlenmiştir. Eğitim sürecinde giriş görüntüleri 224x224 boyutuna getirilmiş ve model *CrossEntropyLoss* kayıp fonksiyonu ile eğitilmiştir. Optimizasyon işlemi için Adam optimizasyon algoritması kullanılmıştır.

ResNet18 modeli hem Varroa Dataset hem de HoneyBee VarroaMite veri setleri üzerinde ayrı ayrı eğitilmiştir. Her eğitim sonrasında model önce kendi validation split'i üzerinde değerlendirilmiş, ardından eğitimde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation işlemine tabi tutulmuştur. Bu sayede modelin yalnızca kendi veri setindeki başarısı değil, farklı veri kaynağına karşı genelleme performansı da ölçülmüştür.

5.2.2. EfficientNet Modeli

Bu çalışmada CNN tabanlı sınıflandırma modellerinden biri olarak EfficientNet-B0 modeli kullanılmıştır. EfficientNet mimarisi, model derinliği, genişliği ve giriş görüntü çözünürlüğünü dengeli şekilde ölçeklendiren bir CNN yapısına sahiptir. Bu özellik sayesinde EfficientNet modelleri, daha az parametreyle yüksek başarı elde edebilen verimli bir yapı sunmaktadır. Proje kapsamında tercih edilen EfficientNet-B0, EfficientNet ailesinin daha hafif ve temel versiyonu olduğu için eğitim süresi, bellek kullanımı ve performans dengesi açısından uygun görülmüştür.

Bu projede EfficientNet-B0 modeli, YOLO modellerinden farklı olarak nesne konumlandırma değil, binary classification görevi için kullanılmıştır. Modelin amacı, verilen bir arı görüntüsünde varroa parazitinin bulunup bulunmadığını belirlemektir. Bu nedenle veri setleri iki sınıfa ayrılmıştır: *varroa* ve *no_varroa*. YOLO formatındaki etiket dosyalarında en az bir geçerli varroa bounding box bulunan görüntüler *varroa*, geçerli varroa etiketi bulunmayan görüntüler ise *no_varroa* sınıfı olarak kabul edilmiştir.

EfficientNet-B0 modeli, ImageNet üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır. Modelin son sınıflandırma katmanı, çalışmadaki iki sınıflı problem yapısına uygun olacak şekilde yeniden düzenlenmiştir. Eğitim sırasında giriş görüntüleri 224x224 boyutuna getirilmiş ve standart normalizasyon işlemleri uygulanmıştır. Model, *CrossEntropyLoss* kayıp fonksiyonu ve Adam optimizasyon algoritması kullanılarak eğitilmiştir.

EfficientNet-B0 modeli hem Varroa Dataset hem de HoneyBee VarroaMite veri setleri üzerinde ayrı ayrı eğitilmiştir. Her eğitimden sonra model ilk olarak kendi veri setinin validation split'i üzerinde değerlendirilmiştir. Daha sonra modelin farklı veri kaynaklarına karşı genelleme başarısını ölçmek amacıyla, eğitim sürecinde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır. Bu sayede EfficientNet-B0 modelinin yalnızca kendi veri dağılımındaki başarısı değil, farklı veri setindeki performansı da analiz edilmiştir.

EfficientNet-B0 modelinin kullanılmasındaki temel amaç, ResNet18'e alternatif olarak daha verimli bir CNN mimarisinin varroa sınıflandırma problemindeki başarısını incelemektir. Özellikle küçük nesne içeren biyolojik görüntülerde, modelin görüntü düzeyinde varroa var/yok kararını ne kadar doğru verebildiği değerlendirilmiştir. Bu nedenle EfficientNet-B0 sonuçları, ResNet18 modeliyle birlikte CNN tabanlı binary classification deneylerinin temel bileşenlerinden biri olarak ele alınmıştır.

5.2.3. YOLOv8 Modeli

Bu çalışmada nesne tespiti modellerinden biri olarak YOLOv8n modeli kullanılmıştır. YOLO ailesi, görüntü üzerindeki nesneleri tek aşamada tespit eden hızlı ve pratik bir nesne algılama mimarisidir. Bu yapı sayesinde model, görüntüdeki hedef nesnenin hem sınıfını hem de konumunu aynı anda tahmin edebilmektedir. Proje kapsamında YOLOv8n modelinin tercih edilmesinin temel nedeni, hafif yapısı sayesinde Google Colab ortamında daha hızlı eğitilebilmesi ve küçük nesne tespiti problemlerinde temel bir karşılaştırma modeli sunmasıdır.

YOLOv8n modeli, bu projede tek sınıflı nesne tespiti problemi için kullanılmıştır. Modelin görevi, arı görüntüsü üzerinde bulunan varroa paraziti tespit etmek ve bu parazitin görüntü üzerindeki konumunu bounding box ile belirlemektir. Bu nedenle veri setlerindeki etiket yapısı varroa olacak şekilde standartlaştırılmıştır. Varroa Dataset veri setinde bulunan bee sınıfı eğitimden çıkarılmış, yalnızca varroa sınıfı korunmuştur. HoneyBee VarroaMite veri seti ise aynı şekilde tek sınıflı varroa tespiti amacıyla kullanılmıştır.

Eğitim sürecinde görüntü boyutu 640x640 olarak belirlenmiştir. Bu boyutun seçilmesinin nedeni, varroa parazitin küçük nesne karakteri taşımasıdır. Daha düşük görüntü boyutları eğitim süresini azaltabilse de küçük nesnelerin ayrıntılarının kaybolmasına neden olabilir. Bu nedenle YOLOv8n eğitimlerinde 640x640 giriş boyutu korunmuştur.

YOLOv8n modeli hem Varroa Dataset hem de HoneyBee VarroaMite veri setleri üzerinde ayrı ayrı eğitilmiştir. Her eğitim sonucunda model önce kendi veri setinin validation split'i üzerinde değerlendirilmiştir. Daha sonra modelin farklı veri kaynaklarına karşı genelleme başarısını ölçmek amacıyla, eğitimde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır. Böylece

modelin yalnızca kendi veri setindeki başarısı değil, farklı veri dağılımındaki performansı da incelenmiştir.

YOLOv8n modeli için değerlendirme metrikleri olarak Precision, Recall, mAP50 ve mAP50-95 kullanılmıştır. Precision değeri modelin yaptığı pozitif tahminlerin ne kadar doğru olduğunu, recall değeri ise gerçek varroa nesnelerinin ne kadarının yakalandığını göstermektedir. mAP50 modeli IoU 0.50 eşliğinde değerlendirirken, mAP50-95 daha sıkı IoU eşiklerinde bounding box konumlandırma başarısını ölçmektedir. Bu nedenle YOLOv8n sonuçları, hem tespit başarısı hem de konumlandırma hassasiyeti açısından değerlendirilmiştir.

5.2.4. YOLOv26 Modeli

Bu çalışmada kullanılan bir diğer nesne tespiti modeli YOLOv26n modelidir. YOLOv26, YOLO ailesinin güncel modellerinden biri olarak ele alınmış ve varroa paraziti tespiti probleminde YOLOv8n modeline alternatif bir nesne algılama yaklaşımı sunması amacıyla kullanılmıştır. Modelin “n” yani nano versiyonu tercih edilmiştir. Bunun temel nedeni, daha düşük parametre sayısına sahip olması ve Google Colab ortamında daha hızlı ve daha düşük kaynak tüketimiyle eğitilebilmesidir.

YOLOv26n modeli bu projede tek sınıflı object detection problemi için kullanılmıştır. Modelin görevi, arı görüntüsü üzerinde bulunan varroa parazitini tespit etmek ve bu parazitin görüntü üzerindeki konumunu bounding box ile göstermektir. Bu nedenle veri setlerindeki sınıf yapısı varroa olacak şekilde standartlaştırılmıştır. Varroa Dataset içerisindeki bee sınıfı eğitim sürecinden çıkarılmış, yalnızca varroa etiketleri korunmuştur. HoneyBee VarroaMite veri seti ise doğrudan tek sınıflı varroa tespiti amacıyla kullanılmıştır.

YOLOv26n eğitimlerinde giriş görüntü boyutu 640x640 olarak belirlenmiştir. Varroa paraziti görüntü içerisinde küçük alan kaplayan bir nesne olduğu için, görüntü boyutunun çok fazla küçültülmesi modelin küçük nesne ayrıntılarını kaybetmesine neden olabilir. Bu nedenle YOLOv8n deneylerinde olduğu gibi YOLOv26n deneylerinde de 640x640 giriş boyutu korunmuştur. Böylece modellerin aynı problem koşullarında değerlendirilmesi sağlanmıştır.

Model, hem Varroa Dataset hem de HoneyBee VarroaMite veri setleri üzerinde ayrı ayrı eğitilmiştir. Her eğitimden sonra model ilk olarak kendi veri setinin validation split'i üzerinde değerlendirilmiştir. Daha sonra modelin farklı veri kaynağına karşı genelleme başarısını ölçmek amacıyla, eğitimde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır. Bu yapı sayesinde YOLOv26n modelinin hem kendi veri dağılımındaki başarısı hem de farklı veri dağılımındaki performansı analiz edilmiştir.

YOLOv26n modeli için değerlendirme metrikleri olarak Precision, Recall, mAP50 ve mAP50-95 kullanılmıştır. Precision metriği modelin varroa olarak tahmin ettiği

bölgelerin ne kadarının doğru olduğunu gösterirken, recall metriği gerçek varroa örneklerinin ne kadarının yakalandığını ifade etmektedir. mAP50 metriği IoU 0.50 eşliğinde genel tespit başarısını, mAP50-95 metriği ise daha katı IoU eşiklerinde bounding box konumlandırma hassasiyetini ölçmektedir. Bu metrikler sayesinde YOLOv26n modeli hem tespit doğruluğu hem de konumlandırma başarısı açısından değerlendirilmiştir.

YOLOv26n modelinin bu çalışmadaki kullanım amacı, farklı YOLO mimarilerinin varroa gibi küçük nesne tespiti problemlerindeki davranışını incelemektir. Modelin daha hafif yapısı, eğitim süresi ve kaynak kullanımı açısından avantaj sağlamaktadır. Ancak küçük nesne tespiti problemi, yalnızca modelin hafifliğiyle değil, veri setinin görüntü dağılımı, anotasyon yapısı ve hedef nesnenin görünürlüğüyle de doğrudan ilişkilidir. Bu nedenle YOLOv26n sonuçları internal ve external validation ayrımıyla değerlendirilmiş ve modelin farklı veri kaynaklarındaki genelleme başarısı ayrıca analiz edilmiştir.

5.3. Transformer Tabanlı Modeller

Nesne tespiti literatüründe uzun süre baskın olan evrişimli sinir ağları (CNN) ve çapa (anchor) tabanlı yöntemler; el yapımı bileşenlere, eşik değerlerine ve karmaşık yakınsaklık bastırma (NMS) gibi son işleme adımlarına ihtiyaç duymaktadır. Bu çalışmada, söz konusu sınırlılıkları aşmak ve görüntüdeki nesneler ile arka plan arasındaki küresel bağlamsal ilişkileri uçtan uca (end-to-end) doğrudan bir küme tahmini (set prediction) problemi olarak ele almak amacıyla Transformer tabanlı mimariler değerlendirilmiştir.

Bu doğrultuda; mimarinin temel referans noktası olan DETR (Detection Transformer), onun küçük nesnelerdeki odaklanma sorununu ve yüksek hesaplama maliyetini gidermek üzere geliştirilen Deformable DETR ve yüksek doğruluk performansını gerçek zamanlı (real-time) işlem verimliliğiyle birleştiren RT-DETR modelleri seçilmiştir. Kendilerine özgü dikkat mekanizmaları (attention mechanisms) sayesinde piksel seviyesindeki uzun menzilli bağıntıları modelleyebilen bu yapılar, varroa paraziti gibi mikro ölçekli hedef nesnelerin ve arı özniteliklerinin geometrik olarak ayırt edilmesinde geleneksel yöntemlere karşı güçlü bir alternatif sunmaktadır.

5.3.1. DETR Modeli

Bu çalışmada kullanılan temel Transformer tabanlı nesne tespiti yaklaşımı DETR (Detection Transformer) modelidir. DETR, geleneksel CNN tabanlı ve çapa (anchor) bağımlı mekanizmalara alternatif olarak, nesne algılama sürecini uçtan uca doğrudan bir küme tahmini problemi olarak ele almak amacıyla değerlendirilmiştir.

Modelin eğitimi kapsamında, varroa paraziti tespiti görevine odaklanılarak veri yapısı tek sınıflı nesne tespiti problemine uygun hale getirilmiştir. Giriş görüntülerinin ön

işleme sürecinde, nesnelerin morfolojik yapılarını ve küçük ayrıntılarını korumak adına en-boy oranını gözeten bir strateji izlenmiştir.

Yerleşik görüntü işlemcisi aracılığıyla ölçeklenen görüntülerde veri yığını uyumluluğunu sağlamak için dolgulama yapılmış ve bu dolgu alanlarını modelin küresel dikkat mekanizmasından gizleyen piksel maskeleri devreye sokulmuştur. Eğitim sürecinin ardından model, ilk olarak kendi veri setinin doğrulama (internal validation) kümesi üzerinde test edilmiştir.

Ardından, küresel dikkat mekanizmasının farklı veri dağıtımlarına karşı gösterdiği genelleme başarısını ölçmek amacıyla, eğitimde kullanılmayan bağımsız Varroa Mites Detector veri seti ile harici doğrulama (external validation) gerçekleştirilmiştir. Değerlendirme metrikleri olarak Precision, Recall, mAP50 ve mAP50-95 kullanılarak modelin hem tespit doğruluğu hem de konumlandırma hassasiyeti analiz edilmiştir.

5.3.2. Deformable DETR Modeli

Çalışmada değerlendirilen bir diğer önemli mimari, standart DETR modelinin yavaş yakınsama ve küçük nesnelerdeki sınırlı çözünürlük problemlerine alternatif olarak ele alınan Deformable DETR modelidir.

Bu model, çok ölçekli (multi-scale) öznitelik haritalarını sadece belirli ve sınırlı örnekleme noktaları üzerinden işleyen seyrek dikkat mekanizmasıyla varroa paraziti gibi küçük nesnelerin tespitinde yapısal bir avantaj sunması amacıyla kullanılmıştır. Tıpkı temel mimaride olduğu gibi, tek sınıflı nesne tespiti hedefine yönelik olarak etiket yapısı standardize edilmiştir.

Modelin yerleşik işlemcisi, en-boy oranını koruyarak görüntüleri ölçeklendirmiş ve dinamik dolgulama adımlarıyla ağ girdilerini hazır hale getirmiştir. Küçük alan kaplayan parazitlerin öznitelik kaybına uğramasını önlemek adına piksel maskelerinden yararlanılmış, böylece modelin optimize bir girdi şemasıyla eğitilmesi sağlanmıştır.

Eğitim tamamlandıktan sonra model içsel doğrulama (internal validation) aşamasından geçirilmiş; hemen ardından, çok ölçekli seyrek dikkat yapısının antrenman dışı veri kaynaklarındaki genelleme ve aşırı öğrenme (overfitting) direncini ölçmek amacıyla Varroa Mites Detector veri setiyle harici doğrulama (external validation) testleri yürütülmüştür. Performans analizi Precision, Recall, mAP50 ve mAP50-95 metrikleri üzerinden gerçekleştirilmiştir.

5.3.3. RT-DETR Model

Projede ele alınan son Transformer tabanlı mimari, uçtan uca dikkat mekanizmasının avantajlarını gerçek zamanlı (real-time) çalışma hızıyla birleştiren RT-DETR modelidir. Bu model, hem yüksek işlem verimliliği hem de hassas doğruluk dengesi sunarak varroa tespiti probleminde operasyonel bir alternatif sunması amacıyla değerlendirilmiştir.

Mimarinin karakteristik davranışlarını ve çoklu nesne algılama kabiliyetini incelemek adına eğitim ve test süreçlerinde, hem morfolojik olarak daha büyük olan arı (bee) sınıfı hem de mikro ölçekli varroa paraziti sınıfı bir arada ele alınmıştır. Giriş görüntülerinin hazırlanmasında, nesne özniteliklerini koruyan en-boy oranı odaklı ölçeklendirme ve dinamik dolgulama protokolleri uygulanmıştır.

Dikkat mekanizmasının dolgu piksellerinden etkilenmesini önlemek adına piksel maskeleri kullanılarak girdi standardizasyonu sağlanmıştır. Model, eğitim döngüsünün ardından öncelikle kendi doğrulama split'i (internal validation) üzerinde değerlendirilmiştir.

Sonrasında, gerçek zamanlı Transformer optimizasyonlarının ve hibrit kodlayıcı (hybrid encoder) yapısının farklı veri dağılımlarına karşı genelleme kabiliyetini objektif bir şekilde ölçebilmek adına harici doğrulama (external validation) süreçlerine tabi tutulmuştur. Değerlendirmeler; hassasiyet, duyarlılık mAP50 ile mAP50-95 metrikleri üzerinden hem genel hem de sınıf bazında yürütülmüştür.

6. DENEYSEL KARŞILAŞTIRMA VE DEĞERLENDİRME METRİKLERİ

Bu çalışmada kullanılan modeller farklı görev türlerine sahip olduğu için değerlendirme sürecinde modelin yapısına uygun metrikler kullanılmıştır. Görüntü düzeyinde sınıflandırma yapan modeller için Accuracy, Precision, Recall ve F1-score metrikleri tercih edilmiştir. Nesne tespiti yapan modeller için ise Precision, Recall, F1-score, mAP50 ve mAP50-95 metrikleri dikkate alınmıştır.

Sınıflandırma modelleri, bir görüntüde veya görüntüden elde edilen belirli bir görüntü bölgesinde Varroa paraziti bulunup bulunmadığını tahmin etmeye odaklanmaktadır. Bu grupta geleneksel makine öğrenmesi tabanlı modeller, CNN tabanlı sınıflandırma modelleri ve transformer tabanlı sınıflandırma modelleri yer almaktadır. Nesne tespiti modelleri ise yalnızca görüntüde varroa olup olmadığını değil, aynı zamanda Varroa parazitinin görüntü üzerindeki konumunu bounding box ile belirlemeyi amaçlamaktadır.

Geleneksel makine öğrenmesi hattında sınıflandırma ve nesne tespiti değerlendirmeleri iki ayrı aşamada ele alınmıştır. İlk aşamada modellerin görüntü bölgeleri üzerindeki varroa/no_varroa sınıflandırma başarısı ölçülmüş, ikinci aşamada ise aynı modeller sliding-window yaklaşımıyla tam görüntü üzerinde çalıştırılarak nihai tespit kutuları üzerinden değerlendirilmiştir. Böylece klasik sınıflandırıcıların yalnızca sınıflandırma başarısı değil, tam görüntü nesne tespiti problemine aktarıldığında gösterdiği performans da analiz edilmiştir.

Bu nedenle çalışmada kullanılan metrikler iki ana grupta ele alınmıştır. İlk grup, sınıflandırma modellerinde kullanılan metriklerden oluşmaktadır. İkinci grup ise nesne

tespiti modellerinde kullanılan metriklerden oluşmaktadır. Bu ayrım, farklı görevlerde çalışan modellerin daha doğru ve adil şekilde değerlendirilmesini sağlamaktadır.

6.1. Sınıflandırma Modellerinde Kullanılan Metrikler

Sınıflandırma modellerinde temel amaç, verilen bir örneğin Varroa içerip içermediğini doğru şekilde belirlemektir. CNN tabanlı sınıflandırma modellerinde bu değerlendirme görüntü düzeyinde yapılırken, geleneksel makine öğrenmesi tabanlı modellerde görüntülerden elde edilen bölgeler üzerinden gerçekleştirilmiştir. Her iki durumda da problem iki sınıflı bir yapı olarak ele alınmış ve örnekler Varroa ile no_varroa sınıfları altında değerlendirilmiştir.

Sınıflandırma modellerinin performansını değerlendirmek için Accuracy, Precision, Recall ve F1-score metrikleri kullanılmıştır. Bu metrikler modelin genel doğruluğunu, pozitif tahminlerinin güvenilirliğini, gerçek Varroa içeren örnekleri yakalama başarısını ve precision-recall dengesini analiz etmek için kullanılmıştır. Özellikle sınıf dağılımlarının veri setleri arasında farklılık göstermesi nedeniyle, yalnızca Accuracy metriğine bağlı kalınmamış; Precision, Recall ve F1-score değerleri de birlikte yorumlanmıştır.

6.1.1. Accuracy

Accuracy, modelin yaptığı toplam tahminler içerisinde doğru tahminlerin oranını göstermektedir. Bu metrik, sınıflandırma modellerinin genel başarı düzeyini özetlemek için kullanılan temel ölçütlerden biridir.

Bu çalışmada Accuracy değeri, modelin Varroa ve no_varroa sınıflarını genel olarak ne kadar doğru ayırt edebildiğini göstermek için kullanılmıştır. Accuracy değerinin yüksek olması, modelin veri setindeki örneklerin büyük kısmını doğru sınıflandırdığını ifade eder.

Ancak Accuracy metriği tek başına her zaman yeterli değildir. Özellikle veri setinde sınıf dengesizliği bulunduğunda model çoğunluk sınıfına yönelerek yüksek Accuracy değeri üretebilir. Bu nedenle Accuracy değeri, Precision, Recall ve F1-score metrikleriyle birlikte değerlendirilmiştir.

6.1.2. Precision

Precision, modelin pozitif olarak tahmin ettiği örneklerin ne kadarının gerçekten pozitif olduğunu göstermektedir. Varroa tespiti bağlamında Precision, modelin Varroa olarak sınıflandırdığı örneklerin ne kadarının gerçekten Varroa içerdiğini ifade eder.

Precision değerinin yüksek olması, modelin yanlış pozitif tahmin üretme oranının düşük olduğunu gösterir. Başka bir ifadeyle model bir örnek için Varroa tahmini yaptığında, bu tahminin doğru olma olasılığı daha yüksektir.

Precision değerinin düşük olması ise modelin Varroa bulunmayan örnekleri de yanlışlıkla Varroa olarak sınıflandırabildiğini gösterebilir. Bu nedenle Precision, özellikle yanlış alarm üretme eğilimini değerlendirmek açısından önemli bir metriktir.

6.1.3. Recall

Recall, veri setinde gerçekten pozitif olan örneklerin ne kadarının model tarafından doğru şekilde yakalandığını göstermektedir. Varroa tespiti bağlamında Recall, gerçekten Varroa içeren örneklerin ne kadarının model tarafından Varroa olarak sınıflandırıldığını ifade eder.

Recall değerin yüksek olması, modelin Varroa içeren örnekleri büyük oranda yakalayabildiğini gösterir. Recall değerin düşük olması ise modelin bazı Varroa içeren örnekleri kaçırdığını ve bunları no_varroa olarak sınıflandırdığını ifade eder.

Varroa tespiti probleminde Recall önemli bir metriktir. Çünkü gerçek Varroa örneklerinin kaçırılması, pratik kullanım açısından yanlış alarm üretmekten daha riskli olabilir. Bu nedenle Recall değeri, modelin Varroa örneklerini yakalama başarısını değerlendirmek için dikkate alınmıştır.

6.1.4. F1-score

F1-score, Precision ve Recall metriklerinin harmonik ortalamasıdır. Bu metrik, modelin pozitif tahmin doğruluğu ile gerçek pozitifleri yakalama başarısını birlikte değerlendirmektedir.

F1-score özellikle sınıf dengesizliği bulunan veri setlerinde önemli bir değerlendirme ölçütüdür. Çünkü yalnızca Accuracy değerine bakıldığında modelin başarısı olduğundan yüksek görünebilir. F1-score ise Precision ve Recall değerlerini birlikte dikkate aldığı için daha dengeli bir başarı göstergesi sunar.

Bu çalışmada F1-score, sınıflandırma modellerinin genel dengesini değerlendirmek için kullanılmıştır. Yüksek F1-score değeri, modelin hem yanlış pozitif tahminleri sınırlı tuttuğunu hem de gerçek Varroa örneklerini başarılı şekilde yakalayabildiğini göstermektedir.

6.2. Nesne Tespiti Modellerinde Kullanılan Metrikler

Nesne tespiti modellerinde amaç yalnızca görüntüde Varroa paraziti bulunup bulunmadığını belirlemek değildir. Bu modeller aynı zamanda Varroa parazitin görüntü üzerindeki konumunu bounding box ile tahmin etmektedir. Bu nedenle nesne tespiti modellerinin değerlendirilmesinde, sınıflandırma modellerinden farklı olarak konumlandırma başarısını da dikkate alan metrikler kullanılmıştır.

Bu çalışmada nesne tespiti modellerinin performansını değerlendirmek için Precision, Recall, F1-score, mAP50 ve mAP50-95 metrikleri kullanılmıştır. Precision ve Recall değerleri modelin doğru tespit yapma ve gerçek Varroa nesnelerini yakalama başarısını gösterirken, mAP50 ve mAP50-95 değerleri bounding box tahminlerinin doğruluğunu ve konumlandırma hassasiyetini değerlendirmek amacıyla kullanılmıştır.

Geleneksel makine öğrenmesi hattında ise nesne tespiti metrikleri, SVM ve Random Forest modellerinin sliding-window yaklaşımıyla ürettiği nihai tespit kutuları üzerinden hesaplanmıştır. Bu modeller doğrudan bounding box tahmini yapan mimariler olmadığı için, tam görüntü üzerinde oluşturulan aday pencereler sınıflandırılmış, eşik değerini geçen bölgeler aday tespit olarak alınmış ve birleştirme işlemleri sonucunda nihai tespit kutuları oluşturulmuştur. Bu nedenle geleneksel makine öğrenmesi tabanlı modellerin nesne tespiti performansı, sınıflandırma başarısından ayrı olarak değerlendirilmiştir.

6.2.1. Precision

Nesne tespiti modellerinde Precision, modelin Varroa olarak tahmin ettiği nesnelerin ne kadarının gerçekten doğru olduğunu göstermektedir. Başka bir ifadeyle, model tarafından oluşturulan Varroa bounding box'larının ne kadarının gerçek Varroa nesnesiyle eşleştiğini ölçmektedir.

Precision değerinin yüksek olması, modelin yanlış pozitif tespit üretme oranının düşük olduğunu gösterir. Bu durumda model, bir bölgede Varroa olduğunu söylediğinde bu tahmine daha fazla güvenilebilir.

Precision değerinin düşük olması ise modelin Varroa olmayan bölgeleri de Varroa olarak işaretleyebildiğini gösterir. Bu nedenle Precision metriği, nesne tespiti modellerinin yanlış alarm üretme eğilimini değerlendirmek açısından önemlidir.

6.2.2. Recall

Recall, görüntülerde gerçekten bulunan Varroa nesnelerinin ne kadarının model tarafından doğru şekilde tespit edildiğini göstermektedir. Bu metrik, modelin gerçek Varroa örneklerini yakalama başarısını ifade etmektedir.

Recall değerinin yüksek olması, modelin görüntülerde bulunan Varroa örneklerinin büyük bölümünü tespit edebildiğini gösterir. Recall değerinin düşük olması ise modelin bazı Varroa parazitlerini kaçırdığını ifade eder.

Varroa tespiti probleminde Recall önemli bir metriktir. Çünkü modelin gerçek Varroa parazitlerini kaçırmaması, uygulama açısından istenmeyen bir durumdur. Bu nedenle nesne tespiti modellerinde Recall değeri, modelin Varroa nesnelerini ne kadar iyi yakalayabildiğini değerlendirmek için kullanılmıştır.

6.2.3. F1-score

F1-score, nesne tespiti modellerinde Precision ve Recall değerlerinden hesaplanan dengeli bir başarı ölçütüdür. Bu metrik, modelin pozitif tespit doğruluğu ile gerçek nesneleri yakalama başarısını birlikte değerlendirmektedir.

Precision değeri yüksek ancak Recall değeri düşük olan bir model, az sayıda fakat güvenilir tespit yapıyor olabilir. Recall değeri yüksek ancak Precision değeri düşük olan bir model ise daha fazla Varroa yakalarken daha fazla yanlış alarm üretebilir. F1-score bu iki durumu birlikte ele aldığı için modelin genel tespit dengesini değerlendirmeye yardımcı olur.

Bu çalışmada nesne tespiti modellerinde mAP50 ve mAP50-95 metrikleriyle birlikte F1-score değeri de kullanılmıştır. Geleneksel makine öğrenmesi tabanlı sliding-window tespit sonuçlarında ise hedef nesnenin küçük boyutlu olması ve pencere tabanlı tespit yapısının kullanılması nedeniyle IoU 0.20 ve IoU 0.30 eşiklerinde F1-score değerleri ayrıca takip edilmiştir.

6.2.4. mAP50

mAP50, nesne tespiti modellerinde yaygın olarak kullanılan temel performans metriklerinden biridir. Bu metrik, modelin tahmin ettiği bounding box ile gerçek bounding box arasındaki örtüşme oranı olan IoU değerinin 0.50 eşiklerinde değerlendirilmesiyle hesaplanmaktadır.

Eğer modelin tahmin ettiği bounding box ile gerçek bounding box arasındaki IoU değeri 0.50 veya daha yüksekse, bu tahmin doğru tespit olarak kabul edilmektedir. Bu nedenle mAP50, modelin hem doğru sınıf tahmini yapmasını hem de nesneyi yaklaşık olarak doğru konumda bulmasını değerlendiren bir metriktir.

Bu çalışmada mAP50 metriği, nesne tespiti modellerinin genel tespit başarısını değerlendirmek için kullanılmıştır. mAP50 değerinin yüksek olması, modelin Varroa paraziti doğru sınıf olarak tanıyabildiğini ve konumunu genel olarak doğru belirleyebildiğini göstermektedir.

6.2.5. mAP50-95

mAP50-95 metriği, mAP50'ye göre daha kapsamlı ve daha katı bir değerlendirme ölçütüdür. Bu metrik, IoU eşiklerinin 0.50'den 0.95'e kadar farklı değerlerde hesaplanması ve bu değerlerin ortalamasının alınmasıyla elde edilmektedir.

mAP50-95, modelin bounding box tahminlerini ne kadar hassas konumlandırabildiğini daha ayrıntılı biçimde göstermektedir. Daha yüksek IoU eşikleri, tahmin edilen bounding box'ın gerçek bounding box ile daha fazla örtüşmesini gerektirir. Bu nedenle

mAP50-95 metriği, yalnızca nesnenin yaklaşık olarak bulunup bulunmadığını değil, konumlandırma hassasiyetini de değerlendirmektedir.

mAP50-95 değerinin mAP50'ye göre daha düşük çıkması beklenen bir durumdur. Çünkü daha yüksek IoU eşiklerinde doğru tespit kabul edilmek için bounding box konumunun daha hassas olması gerekir. Varroa paraziti görüntü içerisinde küçük bir nesne olduğu için bounding box konumundaki küçük sapmalar bile mAP50-95 değerini önemli ölçüde düşürebilmektedir.

6.3. Internal Validation Değerlendirme Yapısı

Internal validation, modellerin geliştirildikleri veri setlerinin kendi validation bölümleri üzerinde değerlendirilmesini ifade etmektedir. Bu değerlendirme, modelin eğitim aldığı veri dağılımına yakın örnekler üzerindeki başarısını ölçmek ve model geliştirme sürecinde ara performans kontrolü yapmak amacıyla kullanılmıştır. Böylece modelin kendi veri setindeki görüntü yapısını, etiket dağılımını ve görsel örüntüleri ne ölçüde öğrenebildiği incelenmiştir.

Bu çalışmada internal validation yaklaşımı, farklı model ailelerinin ilk performans değerlendirmelerini yapmak için kullanılmıştır. Sınıflandırma modellerinde internal validation sonuçları Accuracy, Precision, Recall ve F1-score metrikleriyle değerlendirilmiştir. Nesne tespiti modellerinde ise Precision, Recall, F1-score, mAP50 ve mAP50-95 gibi metrikler dikkate alınmıştır. Bu sayede her model, kendi görev tipine uygun başarı ölçütleriyle analiz edilmiştir.

Geleneksel makine öğrenmesi hattında validation split, model adaylarının seçimi ve sliding-window tespit parametrelerinin ayarlanması için kullanılmıştır. Linear SVM modelleriyle yapılan geniş tarama sonucunda başarılı patch ve özellik kombinasyonları belirlenmiş, ardından seçilen kombinasyonlar üzerinde RBF SVM ve Random Forest modelleri eğitilmiştir. Daha sonra detection aşamasında kullanılacak eşik değeri, pencere kaydırma adımı ve kutu birleştirme parametreleri validation verisi üzerinde ayarlanmıştır.

Internal validation sonuçları, modelin kendi veri seti içerisindeki başarısını görmek açısından önemlidir. Ancak bu sonuçlar, modelin farklı veri kaynaklarında aynı başarıyı göstereceğini tek başına garanti etmez. Çünkü aynı veri setine ait train ve validation bölümleri genellikle benzer görüntü koşullarına, benzer anotasyon yapısına ve benzer sınıf dağılımına sahip olabilir. Bu nedenle internal validation sonuçları model başarısının ilk göstergesi olarak değerlendirilmiş, daha kapsamlı yorum için internal test ve external validation sonuçlarıyla birlikte ele alınmıştır.

Özellikle görüntü tabanlı problemlerde ışık koşulları, arı pozisyonları, görüntü çözünürlüğü, hedef nesnenin büyüklüğü ve etiketleme biçimi model performansını etkileyebilmektedir. Internal validation, bu faktörlerin aynı veri kaynağı içindeki etkisini

ölçerken, modelin farklı veri dağılımlarına karşı dayanıklılığını doğrudan göstermez. Bu nedenle çalışmada internal validation sonuçları modelin veri seti içi öğrenme başarısını değerlendirmek için kullanılmıştır.

6.4. External Validation Değerlendirme Yapısı

External validation, modelin eğitim ve model geliştirme sürecinde kullanılmayan bağımsız bir veri seti üzerinde değerlendirilmesini ifade etmektedir. Bu yaklaşım, modelin yalnızca kendi eğitim veri setine yakın örneklerde değil, farklı veri kaynaklarından gelen görüntülerde de başarılı olup olmadığını anlamak için kullanılmıştır. Bu nedenle external validation, modelin genelleme performansını ölçmek açısından önemli bir değerlendirme adımıdır.

Bu çalışmada external validation amacıyla, model eğitimlerinde kullanılmayan Varroa Mites Detector veri seti değerlendirilmiştir. Bu veri seti; model eğitimi, model seçimi, hiperparametre ayarı veya detection parametresi belirleme süreçlerinde kullanılmamıştır. Böylece modellerin daha önce görmedikleri farklı bir veri dağılımı üzerindeki başarısı daha güvenilir biçimde analiz edilmiştir.

External validation sonuçları özellikle gerçek dünya uygulamalarına daha yakın bir değerlendirme sunduğu için önemlidir. Çünkü gerçek kullanım senaryolarında model, eğitimde gördüğü görüntülerle tamamen aynı koşullara sahip örneklerle karşılaşmayabilir. Görüntü çözünürlüğü, ışık, arka plan, arının pozisyonu, Varroa parazitinin görünürlüğü ve etiketleme tarzı veri setleri arasında değişiklik gösterebilir. External validation, bu farklılıkların model performansı üzerindeki etkisini analiz etmeye yardımcı olur.

Sınıflandırma modellerinde external validation sonuçları Accuracy, Precision, Recall ve F1-score metrikleriyle değerlendirilmiştir. Nesne tespiti modellerinde ise Precision, Recall, F1-score, mAP50 ve mAP50-95 metrikleri kullanılmıştır. Internal ve external validation sonuçlarının birlikte incelenmesi, modelin kendi veri setindeki başarısı ile farklı veri kaynağına genelleme başarısı arasındaki farkı ortaya koymaktadır.

Bu çalışmada external validation sonuçları, modellerin güvenilirliğini ve farklı veri kaynaklarına aktarılabilirliğini değerlendirmek için kritik bir ölçüt olarak ele alınmıştır. Bir modelin internal validation aşamasında yüksek başarı göstermesi olumlu bir sonuç olsa da external validation aşamasında da benzer performansı koruması, modelin daha güçlü bir genelleme kabiliyetine sahip olduğunu göstermektedir. Bu nedenle final değerlendirmelerde internal ve external validation sonuçları birlikte yorumlanmıştır.

7. DENEY SONUÇLARI

Bu bölümde, proje kapsamında değerlendirilen tüm model ailelerinin deney sonuçları sunulmaktadır. Çalışmada geleneksel makine öğrenmesi tabanlı modeller, CNN tabanlı

sınıflandırma modelleri, YOLO tabanlı nesne tespiti modelleri ve transformer tabanlı nesne tespiti modelleri ayrı ayrı değerlendirilmiştir. Her model ailesinin sonuçları, ilgili görevin yapısına uygun metrikler kullanılarak raporlanmıştır.

Sınıflandırma tabanlı modellerde Accuracy, Precision, Recall ve F1-score metrikleri dikkate alınmıştır. Nesne tespiti tabanlı modellerde ise Precision, Recall, F1-score, mAP50 ve mAP50-95 değerleri kullanılmıştır. Geleneksel makine öğrenmesi hattında modeller önce görüntü bölgesi düzeyinde sınıflandırma başarısı açısından, daha sonra sliding-window tabanlı tam görüntü tespiti açısından değerlendirilmiştir. Bu nedenle geleneksel makine öğrenmesi sonuçlarında patch-level classification ve full-image detection sonuçları ayrı ayrı yorumlanmıştır.

Deney sonuçları hem internal değerlendirme hem de external validation açısından ele alınmıştır. Internal değerlendirme, modellerin kendi veri setleri üzerindeki başarısını gösterirken; external validation, eğitim ve model seçimi sürecinde kullanılmayan bağımsız veri seti üzerinde genelleme performansını ortaya koymaktadır. Bu yapı sayesinde yalnızca modelin kendi eğitim dağılımına yakın verilerdeki başarısı değil, farklı veri kaynakları karşısındaki dayanıklılığı da analiz edilmiştir.

7.1. Geleneksel Makine Öğrenmesi Modellerinin Sonuçları

Geleneksel makine öğrenmesi tabanlı modellerin sonuçları iki farklı düzeyde değerlendirilmiştir. İlk düzeyde, modellerin görüntü bölgeleri üzerindeki Varroa/no_varroa sınıflandırma başarısı incelenmiştir. Bu değerlendirme, HOG, HSV, LBP ve PCA tabanlı özelliklerin Varroa içeren ve içermeyen görüntü bölgelerini ayırt etme başarısını göstermektedir. İkinci düzeyde ise seçilen modeller sliding-window yaklaşımıyla tam görüntüler üzerinde çalıştırılmış ve üretilen nihai tespit kutuları üzerinden nesne tespiti performansı değerlendirilmiştir.

Patch-level classification sonuçlarında geleneksel makine öğrenmesi modelleri yüksek performans göstermiştir. Her iki geliştirme veri setinde de en yüksek sınıflandırma başarısı RBF SVM modelleriyle elde edilmiştir. Bu durum, el yapımı görsel özelliklerin görüntü bölgesi düzeyinde Varroa ayrımı için etkili olduğunu göstermektedir.

Tam görüntü üzerinde yapılan sliding-window tabanlı detection değerlendirmelerinde ise sınıflandırma sonuçlarına göre daha düşük performans değerleri elde edilmiştir. Bunun temel nedeni, tam görüntü üzerinde çok sayıda aday pencerenin değerlendirilmesi, yanlış pozitif tespitlerin artabilmesi ve aday kutuların gerçek Varroa konumlarıyla yeterli örtüşmeyi sağlamasının zorlaşmasıdır. Bu nedenle geleneksel makine öğrenmesi hattında yüksek patch-level classification başarısı, doğrudan aynı düzeyde full-image detection başarısına dönüşmemiştir.

Genel olarak geleneksel makine öğrenmesi sonuçları, klasik özellik çıkarımı ve sınıflandırıcıların Varroa ayrımı için kullanılabilir olduğunu; ancak tam görüntü

üzerinde konum belirleme aşamasında sliding-window tabanlı yapının daha sınırlı kaldığını göstermektedir. SVM ve Random Forest modellerine ait ayrıntılı sonuçlar aşağıdaki alt başlıklarda ayrı ayrı sunulmuştur.

7.1.1. SVM Deney Sonuçları

SVM deneylerinde iki aşamalı bir değerlendirme yaklaşımı uygulanmıştır. İlk aşamada Linear SVM modelleri kullanılarak farklı patch boyutları, sınıf dengesi yaklaşımları ve özellik setleri üzerinde geniş bir tarama yapılmıştır. Linear SVM modelleri, hesaplama maliyetinin daha düşük olması nedeniyle çok sayıda konfigürasyonun hızlı biçimde karşılaştırılmasına olanak sağlamıştır. Bu tarama sonucunda başarılı bulunan kombinasyonlar daha sonra RBF kernel tabanlı SVM modelleriyle ayrıntılı olarak değerlendirilmiştir.

Patch-level classification sonuçları incelendiğinde, SVM modellerinin görüntü bölgesi düzeyinde yüksek başarı elde ettiği görülmüştür. Varroa Dataset üzerinde en yüksek sınıflandırma başarısı, 80×80 patch boyutu, balanced sınıf dengesi ve HOG16 + HSV + LBP özellik birleşimi kullanılan RBF SVM modeliyle elde edilmiş ve F1-score değeri 0.94 olarak ölçülmüştür. HoneyBee VarroaMite veri setinde ise en yüksek sınıflandırma başarısı, 48×48 patch boyutu, balanced sınıf dengesi ve HOG16 + HSV + LBP özellik birleşimi kullanılan RBF SVM modeliyle elde edilmiş ve F1-score değeri 0.92 olarak hesaplanmıştır. Bu sonuçlar, RBF kernel kullanımının görüntü bölgeleri üzerindeki doğrusal olmayan ayrımları yakalamada etkili olduğunu göstermektedir.

SVM modelleri full-image detection aşamasında sliding-window yapısı içerisinde de değerlendirilmiştir. Internal detection testinde Varroa Dataset üzerinde $F1@IoU0.20$ metriğinde en başarılı SVM sonucu, 80×80 patch boyutu, balanced sınıf dengesi ve HOG16 + PCA + HSV + LBP özellik birleşimi kullanılan Linear SVM modeliyle elde edilmiştir. Bu model $F1@IoU0.20 = 0.39$ değerine ulaşmıştır. $F1@IoU0.30$ metriğinde ise 80×80 patch boyutu, neg4x sınıf dengesi ve HOG16 + HSV + LBP özellik birleşimi kullanılan RBF SVM modeli daha yüksek sonuç üretmiş ve $F1@IoU0.30 = 0.32$ değerine ulaşmıştır. HoneyBee VarroaMite veri setinde ise internal detection aşamasında 48×48 patch boyutu, neg4x sınıf dengesi ve HOG16 + PCA + HSV + LBP özellik birleşimi kullanılan RBF SVM modeli öne çıkmış; $F1@IoU0.20 = 0.50$ ve $F1@IoU0.30 = 0.36$ değerleri elde edilmiştir. Bu durum, farklı veri setlerinde ve farklı IoU eşiklerinde en başarılı SVM konfigürasyonunun değişebildiğini göstermektedir.

External validation aşamasında ise SVM ailesi içerisinde en güçlü sonuç RBF SVM modeliyle elde edilmiştir. Varroa Dataset kaynaklı, 80×80 patch boyutu, neg4x sınıf dengesi ve HOG16 + HSV + LBP özellik birleşimi kullanılan RBF SVM modeli, bağımsız dış test veri setinde $F1@IoU0.20 = 0.43$ ve $F1@IoU0.30 = 0.41$ değerlerine ulaşmıştır. HoneyBee VarroaMite kaynaklı, 48×48 patch boyutu, neg4x sınıf dengesi ve HOG16 + PCA + HSV + LBP özellik birleşimi kullanılan RBF SVM modeli ise

external detection aşamasında $F1@IoU0.20 = 0.29$ ve $F1@IoU0.30 = 0.24$ değerlerini üretmiştir. Bu sonuçlar, Varroa Dataset üzerinde eğitilen RBF SVM modelinin external validation koşullarında daha dengeli genelleme performansı sunduğunu göstermektedir.

Genel olarak SVM sonuçları, görüntü bölgesi düzeyinde Varroa ayrımı için oldukça güçlü bir performans ortaya koymuştur. Ancak sliding-window tabanlı tam görüntü tespitinde performans, patch-level classification sonuçlarına göre daha sınırlı kalmıştır. Bu durum, geleneksel sınıflandırıcıların tam görüntü üzerinde konum belirleme görevine aktarıldığında pencere boyutu, eşikleme, kutu birleştirme ve IoU örtüşmesi gibi ek faktörlerden önemli ölçüde etkilendiğini göstermektedir.

Tablo 4. SVM modellerinin öne çıkan classification ve detection sonuçları.

Eğitim Veri Seti	Değerlendirme	Model Türü	Patch / Denge / Özellik	Sonuç (Metrik)
Varroa Dataset	Internal Classification	RBF SVM	80×80 / balanced / HOG16 + HSV + LBP	0.94 (F1-score)
HoneyBee VarroaMite	Internal Classification	RBF SVM	48×48 / balanced / HOG16 + HSV + LBP	0.92 (F1-score)
Varroa Dataset	Internal Detection	Linear SVM	80×80 / balanced / HOG16 + PCA + HSV + LBP	0.39 (F1@IoU0.20)
Varroa Dataset	Internal Detection	RBF SVM	80×80 / neg4x / HOG16 + HSV + LBP	0.32 (F1@IoU0.30)
HoneyBee VarroaMite	Internal Detection	RBF SVM	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.50 (F1@IoU0.20)

HoneyBee VarroaMite	Internal Detection	RBF SVM	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.36 (F1@IoU0.30)
Varroa Dataset	External Classification	Linear SVM	80×80 / balanced / HOG16 + PCA + HSV + LBP	0.94 (F1-score)
HoneyBee VarroaMite	External Classification	RBF SVM	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.75 (F1-score)
Varroa Dataset	External Detection	RBF SVM	80×80 / neg4x / HOG16 + HSV + LBP	0.43 (F1@IoU0.20)
Varroa Dataset	External Detection	RBF SVM	80×80 / neg4x / HOG16 + HSV + LBP	0.41 (F1@IoU0.30)
HoneyBee VarroaMite	External Detection	RBF SVM	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.29 (F1@IoU0.20)
HoneyBee VarroaMite	External Detection	RBF SVM	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.24 (F1@IoU0.30)

Tablo incelendiğinde, SVM modellerinin görüntü bölgesi düzeyindeki classification görevinde oldukça yüksek F1-score değerlerine ulaştığı görülmektedir. Her iki eğitim veri setinde de en yüksek internal classification başarısının RBF SVM ile elde edilmesi, doğrusal olmayan karar sınırlarının Varroa/no_varroa ayrımında etkili olduğunu göstermektedir. External classification sonuçlarında ise Varroa Dataset kaynaklı Linear SVM modelinin yüksek F1-score değerini koruması, bu veri setinden öğrenilen görüntü bölgesi temsillerinin dış veri setine sınıflandırma düzeyinde güçlü biçimde

aktarılabildiğini göstermektedir. Detection sonuçlarında ise performansın classification sonuçlarına göre daha düşük kaldığı görülmektedir. Bu durum, sliding-window yaklaşımında modelin yalnızca doğru sınıflandırma yapmasının yeterli olmadığını; aynı zamanda aday pencerenin gerçek Varroa konumuyla yeterli düzeyde örtüşmesi gerektiğini göstermektedir. External detection sonuçlarında Varroa Dataset kaynaklı RBF SVM modelinin HoneyBee VarroaMite kaynaklı modele göre daha yüksek F1 değerleri üretmesi, bu modelin bağımsız dış veri setine daha dengeli biçimde genellenebildiğini göstermektedir.

7.1.2. Random Forest Deney Sonuçları

Random Forest modelleri, Linear SVM taraması sonucunda başarılı bulunan seçili patch boyutu, sınıf dengesi ve özellik seti kombinasyonları üzerinde değerlendirilmiştir. Bu yaklaşım sayesinde tüm olası kombinasyonlar üzerinde yeniden kapsamlı bir eğitim yapmak yerine, ön eleme sonucunda güçlü görülen konfigürasyonlar Random Forest algoritmasıyla test edilmiştir. Random Forest, birden fazla karar ağacının birlikte çalışmasına dayandığı için doğrusal olmayan ilişkileri öğrenebilme ve farklı özellik türlerini birlikte değerlendirebilme potansiyeline sahiptir.

Patch-level classification sonuçları incelendiğinde, Random Forest modellerinin her iki geliştirme veri setinde de yüksek başarı elde ettiği görülmektedir. Varroa Dataset üzerinde en yüksek Random Forest classification başarısı, 80×80 patch boyutu, balanced sınıf dengesi ve HOG16 + HSV + LBP özellik birleşimiyle elde edilmiş ve F1-score değeri 0.92 olarak ölçülmüştür. HoneyBee VarroaMite veri setinde ise 48×48 patch boyutu, balanced sınıf dengesi ve HSV + LBP özellik birleşimi kullanılan Random Forest modeli 0.91 F1-score değerine ulaşmıştır. Bu sonuçlar, Random Forest modellerinin görüntü bölgesi düzeyinde Varroa/no_varroa ayrımı için güçlü bir alternatif sunduğunu göstermektedir.

Random Forest modelleri full-image detection aşamasında özellikle HoneyBee VarroaMite veri seti üzerinde öne çıkmıştır. Internal detection değerlendirmesinde 48×48 patch boyutu, neg4x sınıf dengesi ve HOG16 + PCA + HSV + LBP özellik birleşimi kullanılan Random Forest modeli, $F1@IoU0.20 = 0.53$ ve $F1@IoU0.30 = 0.40$ değerlerine ulaşmıştır. Bu sonuç, Random Forest modelinin Dataset2 üzerinde sliding-window tabanlı tam görüntü tespitinde güçlü bir performans ürettiğini göstermektedir.

External validation aşamasında ise Random Forest modelleri internal detection sonuçlarına göre daha sınırlı bir performans göstermiştir. HoneyBee VarroaMite kaynaklı, 48×48 patch boyutu, neg4x sınıf dengesi ve HOG16 + PCA + HSV + LBP özellik birleşimi kullanılan Random Forest modeli external classification diagnostic aşamasında 0.78 F1-score değerine ulaşmıştır. Ancak aynı model external detection aşamasında $F1@IoU0.20 = 0.23$ ve $F1@IoU0.30 = 0.18$ değerlerinde kalmıştır. Bu

durum, patch-level classification başarısının tam görüntü üzerinde konum belirleme başarısına doğrudan yansımadağını göstermektedir.

Genel olarak Random Forest sonuçları, geleneksel makine öğrenmesi hattında SVM modellerine tamamlayıcı bir alternatif sunmuştur. Random Forest modeli özellikle HoneyBee VarroaMite veri setindeki internal detection değerlendirmesinde başarılı olurken, external validation aşamasında false positive üretme eğilimi nedeniyle daha sınırlı genelleme performansı göstermiştir. Bu sonuç, Random Forest modelinin kendi veri setindeki görsel örüntüleri etkili biçimde öğrenebildiğini; ancak farklı veri dağılımına sahip bağımsız dış test setinde aynı başarıyı korumakta zorlanabildiğini göstermektedir.

Tablo 5. Random Forest modellerinin öne çıkan classification ve detection sonuçları.

Eğitim Veri Seti	Değerlendirme	Model Türü	Patch / Denge / Özellik	Sonuç (Metrik)
Varroa Dataset	Internal Classification	Random Forest	80×80 / balanced / HOG16 + HSV + LBP	0.92 (F1-score)
HoneyBee VarroaMite	Internal Classification	Random Forest	48×48 / balanced / HSV + LBP	0.91 (F1-score)
HoneyBee VarroaMite	Internal Detection	Random Forest	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.53 (F1@IoU0.20)
HoneyBee VarroaMite	Internal Detection	Random Forest	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.40 (F1@IoU0.30)
HoneyBee VarroaMite	External Classification	Random Forest	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.78 (F1-score)

HoneyBee VarroaMite	External Detection	Random Forest	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.23 (F1@IoU0.20)
HoneyBee VarroaMite	External Detection	Random Forest	48×48 / neg4x / HOG16 + PCA + HSV + LBP	0.18 (F1@IoU0.30)

Tablo incelendiğinde, Random Forest modellerinin internal classification aşamasında her iki veri seti için güçlü sonuçlar ürettiği görülmektedir. Bununla birlikte Random Forest ailesinin en belirgin katkısı, HoneyBee VarroaMite veri setindeki internal detection değerlendirmesinde ortaya çıkmıştır. Bu aşamada model, SVM ailesine kıyasla daha yüksek F1@IoU0.20 ve F1@IoU0.30 değerlerine ulaşmıştır. Buna karşılık external validation aşamasında detection performansının düşmesi, Random Forest modelinin farklı veri dağılımlarına aktarımında daha fazla zorlandığını göstermektedir. Bu durum, Dataset2 kaynaklı modellerin dış test veri setinde daha fazla yanlış pozitif üretme eğilimi göstermesiyle ilişkilendirilebilir.

7.2. CNN Tabanlı Modellerin Sonuçları

Bu bölümde CNN tabanlı modeller kapsamında eğitilen ResNet18, EfficientNet-B0, YOLOv8n ve YOLOv26n modellerinin deney sonuçları sunulmuştur. ResNet18 ve EfficientNet-B0 modelleri binary classification görevi için değerlendirilirken, YOLOv8n ve YOLOv26n modelleri nesne tespiti görevi kapsamında ele alınmıştır.

Sınıflandırma modellerinde sonuçlar Accuracy, Precision, Recall ve F1-score metrikleri üzerinden değerlendirilmiştir. Nesne tespiti modellerinde ise Precision, Recall, F1-score, mAP50 ve mAP50-95 metrikleri kullanılmıştır. Her model için eğitim veri setine ait internal validation sonuçları ve Varroa Mites Detector veri seti üzerinde elde edilen external validation sonuçları ayrı ayrı raporlanmıştır.

Bu bölümde verilen sonuçlar, CNN tabanlı modellerin hem kendi eğitim veri setlerine yakın görüntülerdeki başarısını hem de farklı veri kaynağına karşı genelleme performansını değerlendirmek amacıyla kullanılmıştır. Böylece sınıflandırma ve nesne tespiti yaklaşımlarının varroa tespiti problemindeki güçlü ve sınırlı yönleri karşılaştırmalı olarak incelenmiştir.

7.2.1. ResNet Deney Sonuçları

Bu bölümde ResNet18 modeli iki farklı eğitim veri seti üzerinde değerlendirilmiştir. Model ilk olarak Varroa Dataset, daha sonra HoneyBee VarroaMite veri seti üzerinde

eğitilmiştir. Her iki eğitimden sonra modelin başarısı önce kendi validation split'i üzerinde ölçülmüş, ardından eğitim sürecinde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır.

ResNet18 modeli binary classification amacıyla kullanıldığı için değerlendirme metrikleri olarak Accuracy, Precision, Recall ve F1-score kullanılmıştır. Accuracy genel doğru sınıflandırma oranını, precision modelin varroa dediği tahminlerin doğruluğunu, recall gerçek varroa içeren görüntülerin ne kadarının yakalandığını, F1-score ise precision ve recall değerlerinin dengeli ortalamasını göstermektedir.

Tablo 6. ResNet18 modelinin internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Accuracy	Precision	Recall	F1-score
Varroa Dataset	Internal Validation	0.9550	0.9071	0.8944	0.9007
Varroa Dataset	External Validation	0.8820	0.9458	0.7202	0.8177
HoneyBee VarroaMite	Internal Validation	0.8873	0.9440	0.8801	0.9109
HoneyBee VarroaMite	External Validation	0.7521	0.7233	0.5275	0.6101

ResNet18 modeli Varroa Dataset üzerinde eğitildiğinde internal validation aşamasında oldukça yüksek başarı elde etmiştir. Accuracy = 0.9550 ve F1-score = 0.9007 değerleri, modelin kendi validation verisi üzerinde *varroa* ve *no_varroa* sınıflarını başarılı şekilde ayırt edebildiğini göstermektedir. External validation aşamasında performans düşmesine rağmen F1-score = 0.8177 değeri korunmuş ve model farklı veri kaynağında da güçlü bir sınıflandırma performansı göstermiştir. Bu sonuç, Varroa Dataset üzerinde eğitilen ResNet18 modelinin external validation veri setine belirli ölçüde genellenebildiğini göstermektedir.

HoneyBee VarroaMite üzerinde eğitilen ResNet18 modeli ise internal validation aşamasında F1-score = 0.9109 değeriyle yüksek bir başarı göstermiştir. Ancak external validation sonucunda F1-score değeri 0.6101 seviyesine düşmüştür. Bu düşüş, HoneyBee VarroaMite veri seti ile Varroa Mites Detector veri seti arasında görüntü dağılımı, çözünürlük, kontrast ve varroa görünürlüğü açısından farklar olduğunu göstermektedir. Özellikle recall değerinin external validation’da 0.5275 seviyesine düşmesi, modelin farklı veri setindeki bazı varroa içeren görüntüleri kaçırdığını ortaya koymaktadır.

Genel olarak ResNet18 modeli, her iki veri setinde de internal validation aşamasında başarılı sonuçlar üretmiştir. Ancak external validation sonuçları incelendiğinde Varroa Dataset üzerinde eğitilen ResNet18 modelinin daha dengeli ve daha güçlü genelleme performansı sunduğu görülmektedir. Bu durum, eğitim veri setinin external validation veri setiyle olan dağılımsal benzerliğinin model başarısı üzerinde önemli bir etkisi olduğunu göstermektedir.

7.2.2. EfficientNet Deney Sonuçları

Bu bölümde EfficientNet-B0 modelinin iki farklı eğitim veri seti üzerindeki binary classification sonuçları değerlendirilmiştir. Model, ilk olarak Varroa Dataset, daha sonra HoneyBee VarroaMite veri seti üzerinde eğitilmiştir. Her iki eğitimden sonra model önce kendi validation split’i üzerinde test edilmiş, ardından eğitim sürecinde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır.

EfficientNet-B0 modeli binary classification görevi için kullanıldığı için değerlendirme metrikleri olarak Accuracy, Precision, Recall ve F1-score kullanılmıştır. Bu metrikler modelin *varroa* ve *no_varroa* sınıflarını ayırt etme başarısını farklı açılardan değerlendirmek için kullanılmıştır.

Tablo 7. EfficientNet-B0 modelinin Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerindeki internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Accuracy	Precision	Recall	F1-score
Varroa Dataset	Internal Validation	0.9507	0.8866	0.8991	0.8928
Varroa Dataset	External Validation	0.9005	0.9543	0.7661	0.8499

HoneyBee VarroaMite	Internal Validation	0.8911	0.9074	0.9284	0.9178
HoneyBee VarroaMite	External Validation	0.6661	0.5413	0.6009	0.5696

EfficientNet-B0 modeli Varroa Dataset üzerinde eğitildiğinde internal validation aşamasında yüksek bir sınıflandırma başarısı elde etmiştir. Accuracy = 0.9507 ve F1-score = 0.8928 değerleri, modelin kendi validation verisi üzerinde *varroa* ve *no_varroa* sınıflarını başarılı şekilde ayırt edebildiğini göstermektedir. External validation aşamasında da model güçlü sonuçlar üretmiş ve Accuracy = 0.9005, F1-score = 0.8499 değerlerine ulaşmıştır. Bu sonuç, Varroa Dataset üzerinde eğitilen EfficientNet-B0 modelinin farklı veri kaynağına karşı da dengeli bir genelleme performansı sunduğunu göstermektedir. Özellikle external validation sonucunda Precision = 0.9543 olması, modelin varroa olarak tahmin ettiği görüntülerin büyük kısmında doğru karar verdiğini göstermektedir.

HoneyBee VarroaMite veri seti üzerinde eğitilen EfficientNet-B0 modeli internal validation aşamasında oldukça yüksek bir başarı göstermiştir. F1-score = 0.9178 ve Recall = 0.9284 değerleri, modelin kendi veri setindeki varroa içeren görüntüleri yüksek oranda yakalayabildiğini göstermektedir. Ancak external validation aşamasında modelin performansı belirgin şekilde düşmüş ve F1-score = 0.5696 seviyesine gerilemiştir. Bu düşüş, HoneyBee VarroaMite veri seti ile Varroa Mites Detector veri seti arasında görüntü dağılımı, çözünürlük, ışık koşulları ve varroa görünürlüğü açısından farklar olduğunu göstermektedir. External validation'da Precision = 0.5413 olması, modelin farklı veri setinde daha fazla yanlış pozitif tahmin ürettiğini göstermektedir.

Genel olarak EfficientNet-B0 modeli iki veri setinde de internal validation aşamasında başarılı sonuçlar üretmiştir. Ancak external validation sonuçları incelendiğinde, Varroa Dataset üzerinde eğitilen EfficientNet-B0 modelinin daha güçlü ve dengeli bir genelleme performansı sunduğu görülmektedir. HoneyBee VarroaMite üzerinde eğitilen model kendi veri setinde başarılı olsa da farklı veri kaynağına geçildiğinde performans kaybı yaşamıştır. Bu durum, eğitim veri setinin external validation veri setiyle olan dağılımsal benzerliğinin model başarısı üzerinde önemli bir etkiye sahip olduğunu göstermektedir.

7.2.3. YOLOv8 Deney Sonuçları

Bu bölümde YOLOv8n modelinin iki farklı eğitim veri seti üzerindeki nesne tespiti sonuçları değerlendirilmiştir. Model, ilk olarak Varroa Dataset, daha sonra HoneyBee VarroaMite veri seti üzerinde eğitilmiştir. Her iki eğitimden sonra model önce kendi

validation split'i üzerinde test edilmiş, ardından eğitim sürecinde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır.

YOLOv8n modeli nesne tespiti amacıyla kullanıldığı için değerlendirme metrikleri olarak Precision, Recall, mAP50 ve mAP50-95 kullanılmıştır. Precision değeri modelin varroa olarak tahmin ettiği bölgelerin ne kadarının doğru olduğunu gösterirken, recall değeri gerçek varroa örneklerinin ne kadarının yakalandığını ifade etmektedir. mAP50 ve mAP50-95 değerleri ise modelin bounding box ile konumlandırma başarısını ölçmek için kullanılmıştır.

Tablo 8. YOLOv8n modelinin Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerindeki internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Precision	Recall	F1	mAP50	mAP50-95
Varroa Dataset	Internal	0.890	0.775	0.829	0.860	0.368
Varroa Dataset	External	0.817	0.549	0.657	0.629	0.222
HoneyBee VarroaMite	Internal	0.898	0.695	0.783	0.750	0.291
HoneyBee VarroaMite	External	0.133	0.303	0.185	0.0885	0.0195

YOLOv8n modeli Varroa Dataset üzerinde eğitildiğinde internal validation aşamasında yüksek bir nesne tespiti başarısı elde etmiştir. Precision = 0.890 ve mAP50 = 0.860 değerleri, modelin kendi validation verisi üzerinde varroa paraziti başarılı şekilde tespit edebildiğini göstermektedir. Recall değerinin 0.775 olması, modelin gerçek varroa örneklerinin önemli bir bölümünü yakalayabildiğini ancak bazı örnekleri kaçırdığını göstermektedir. External validation aşamasında mAP50 değeri 0.629 seviyesine düşmüş olsa da model farklı veri setinde belirli düzeyde tespit başarısını korumuştur. Bu durum, Varroa Dataset üzerinde eğitilen YOLOv8n modelinin external veri setine kısmen genellenebildiğini göstermektedir.

HoneyBee VarroaMite veri seti üzerinde eğitilen YOLOv8n modeli internal validation aşamasında yüksek precision değeri elde etmiştir. Precision = 0.898 olması, modelin HoneyBee validation split'i üzerinde yaptığı varroa tahminlerinin büyük kısmının doğru olduğunu göstermektedir. Ancak external validation aşamasında modelin performansı ciddi şekilde düşmüş ve mAP50 = 0.0885 seviyesine gerilemiştir. Bu düşüş, HoneyBee VarroaMite veri seti ile Varroa Mites Detector veri seti arasında görüntü dağılımı, çözünürlük, bounding box ölçeği ve varroa görünürlüğü açısından önemli farklar olduğunu göstermektedir. External validation'da recall değerinin 0.303 olması, modelin farklı veri setindeki birçok varroa örneğini kaçırdığını ortaya koymaktadır.

Genel olarak YOLOv8n modeli, her iki veri setinde de internal validation aşamasında kabul edilebilir sonuçlar üretmiştir. Ancak external validation sonuçları incelendiğinde, Varroa Dataset üzerinde eğitilen YOLOv8n modelinin HoneyBee VarroaMite üzerinde eğitilen modele göre çok daha güçlü genelleme performansı sunduğu görülmektedir. Bu sonuç, nesne tespiti modellerinde eğitim veri setinin external validation veri setine olan benzerliğinin model başarısını doğrudan etkilediğini göstermektedir. YOLOv8n özelinde en güçlü detection performansı Varroa Dataset üzerinde eğitilen modelden elde edilmiştir.

7.2.4. YOLOv26 Deney Sonuçları

Bu bölümde YOLO26n modelinin iki farklı eğitim veri seti üzerindeki nesne tespiti sonuçları değerlendirilmiştir. Model, ilk olarak Varroa Dataset, daha sonra HoneyBee VarroaMite veri seti üzerinde eğitilmiştir. Her iki eğitimden sonra model önce kendi validation split'i üzerinde test edilmiş, ardından eğitim sürecinde kullanılmayan Varroa Mites Detector veri seti üzerinde external validation yapılmıştır.

YOLO26n modeli nesne tespiti amacıyla kullanıldığı için değerlendirme metrikleri olarak Precision, Recall, mAP50 ve mAP50-95 kullanılmıştır. Precision değeri modelin varroa olarak tahmin ettiği bölgelerin ne kadarının doğru olduğunu, recall değeri gerçek varroa örneklerinin ne kadarının yakalandığını göstermektedir. mAP50 ve mAP50-95 değerleri ise modelin bounding box konumlandırma başarısını farklı IoU eşiklerinde değerlendirmek için kullanılmıştır.

Tablo 9. YOLOv26n modelinin Varroa Dataset ve HoneyBee VarroaMite veri setleri üzerindeki internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Precision	Recall	F1	mAP50	mAP50-95

Varroa Dataset	Internal	0.758	0.695	0.725	0.787	0.344
Varroa Dataset	External	0.625	0.496	0.553	0.557	0.208
HoneyBee VarroaMite	Internal	0.850	0.681	0.756	0.748	0.275
HoneyBee VarroaMite	External	0.189	0.268	0.222	0.093	0.0217

YOLO26n modeli Varroa Dataset üzerinde eğitildiğinde internal validation aşamasında kabul edilebilir bir nesne tespiti başarısı elde etmiştir. $mAP50 = 0.787$ değeri, modelin kendi validation split'i üzerinde varroa paraziti belirli bir başarıyla tespit edebildiğini göstermektedir. Precision değerinin 0.758, recall değerinin ise 0.695 olması, modelin pozitif tahminlerinde makul bir doğruluk sağladığını ancak bazı varroa örneklerini kaçırdığını göstermektedir. External validation aşamasında $mAP50$ değeri 0.557 seviyesine düşmüştür. Bu düşüş, modelin farklı veri kaynağına geçtiğinde performans kaybı yaşadığını göstermektedir.

HoneyBee VarroaMite veri seti üzerinde eğitilen YOLO26n modeli internal validation aşamasında $mAP50 = 0.748$ değerine ulaşmıştır. Bu sonuç, modelin HoneyBee veri seti içerisinde varroa tespiti öğrenebildiğini göstermektedir. Ancak external validation sonucunda $mAP50$ değeri 0.093 seviyesine düşmüştür. External validation'da precision değerinin 0.189, recall değerinin ise 0.268 olması, modelin farklı veri setindeki varroa örneklerini tespit etmekte zorlandığını göstermektedir. Bu durum, HoneyBee VarroaMite veri seti ile Varroa Mites Detector veri seti arasında görüntü yapısı, çözünürlük, nesne ölçeği ve anotasyon tarzı açısından önemli farklar olduğunu düşündürmektedir.

Genel olarak YOLO26n modeli her iki eğitim veri setinde de internal validation aşamasında kullanılabilir sonuçlar üretmiştir. Ancak external validation sonuçları incelendiğinde, Varroa Dataset üzerinde eğitilen YOLO26n modelinin HoneyBee VarroaMite üzerinde eğitilen modele göre daha dengeli bir genelleme performansı sunduğu görülmektedir. HoneyBee üzerinde eğitilen model kendi veri setinde başarılı görünmesine rağmen external validation aşamasında belirgin performans kaybı

yaşamıştır. Bu sonuç, nesne tespiti modellerinde model mimarisinin yanında eğitim veri setinin external veri setine olan benzerliğinin de başarı üzerinde güçlü bir etkisi olduğunu göstermektedir.

7.3. Transformer Tabanlı Modellerin Sonuçları

Bu bölümde Transformer tabanlı modeller kapsamında eğitilen DETR, Deformable DETR, RT-DETR modellerinin deney sonuçları sunulmuştur.

Sınıflandırma modellerinde sonuçlar Accuracy, Precision, Recall ve F1-score metrikleri üzerinden değerlendirilmiştir. Nesne tespiti modellerinde ise Precision, Recall, F1-score, mAP50 ve mAP50-95 metrikleri kullanılmıştır. Her model için eğitim veri setine ait internal validation sonuçları ve Varroa Mites Detector veri seti üzerinde elde edilen external validation sonuçları ayrı ayrı raporlanmıştır.

Bu bölümde verilen sonuçlar, Transformer tabanlı modellerin hem kendi eğitim veri setlerine yakın görüntülerdeki başarısını hem de farklı veri kaynağına karşı genelleme performansını değerlendirmek amacıyla kullanılmıştır. Böylece sınıflandırma ve nesne tespiti yaklaşımlarının varroa tespiti problemindeki güçlü ve sınırlı yönleri karşılaştırmalı olarak incelenmiştir.

7.3.1. DETR Deney Sonuçları

Standart DETR mimarisi, projenin başlangıç aşamasında temel bir referans noktası (baseline) oluşturmak amacıyla test edilmiş, ancak elde edilen öncül sonuçlar ve mimari kısıtlar nedeniyle kapsamlı eğitim süreçleri tamamlanmadan sonlandırılmıştır. Modelin ilk veri seti (Varroa Dataset) üzerindeki içsel doğrulama (internal validation) aşamasında elde edilen öncül performans verileri şu şekildedir:

Tablo 10. DETR modelinin internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Precision	Recall	F1	mAP50	mAP50-95
Varroa Dataset	Internal	0.4964	0.4424	0.4678	0.4964	0.4168
Varroa Dataset	External	0.3820	0.3150	0.3452	0.3540	0.2240

- mAP @0.50 (Başarı Skoru): 0.4964
- Genel mAP (50-95): 0.4168
- Hassasiyet (Precision): 0.4964
- Duyarlılık (Recall): 0.4424
- F1 Skoru: 0.4678

Elde edilen bu ilk sonuçlar, modelin varroa paraziti tespiti probleminde tam kapasiteyle optimize edilmemesi kararının temel gerekçelerini oluşturmuştur. Sonuçların analizi doğrultusunda eğitim sürecinin durdurulma nedenleri şu şekildedir:

- Yavaş Yakınsama ve Hesaplama Maliyeti: Standart DETR'in küresel dikkat (global attention) mekanizması, pikseller arasındaki tüm ilişkileri hesaplamaya çalıştığı için çok yavaş yakınsamakta ve Google Colab ortamında aşırı uzun eğitim süreleri gerektirmektedir.
- Küçük Nesne Tespiti Yetersizliği: Modelin tek ölçekli (single-scale) öznitelik haritası kullanması, arı üzerinde çok küçük bir alan kaplayan varroa akarlarının geometrik özniteliklerini yakalamada başarısız olmasına yol açmış ve bu durum 0.4964 gibi düşük bir mAP50 skoruyla sonuçlanmıştır.
- Gelişmiş Alternatiflerin Varlığı: Standart DETR'in bu donanımsal ve yapısal kısıtlarını doğrudan aşmak üzere tasarlanan Deformable DETR ve RT-DETR gibi çok ölçekli seyrek dikkat mekanizmalarına sahip alternatiflerin varlığı, zaman ve hesaplama kaynaklarının bu modellere aktarılmasını gerekli kılmıştır.

7.3.2. Deformable-DETR Deney Sonuçları

Standart DETR mimarisinin yavaş yakınsama kısıtını ve küçük nesneler üzerindeki odaklanma sorununu aşmak amacıyla geliştirilen Deformable DETR modeli, bu çalışmada alternatif bir Transformer tabanlı yaklaşım olarak değerlendirilmiştir. Modelin çok ölçekli (multi-scale) öznitelik haritalarını ve sınırlı sayıdaki örnekleme noktasını temel alan seyrek dikkat (sparse attention) mekanizması sayesinde, mikro ölçekli bir parazit olan varroa tespitinde yapısal bir avantaj hedeflenmiştir.

Model, belirlenen iki farklı veri seti üzerinde eğitilmiş ve elde edilen sonuçlar içsel doğrulama (internal validation) ile harici doğrulama (external validation) ayırımında test edilmiştir. Deformable DETR modeline ait deneysel sonuçların dağılımı aşağıdaki tabloda gösterilmiştir:

Tablo 11. Deformable DETR modelinin internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Precision	Recall	F1	mAP50	mAP50-95
Varroa Dataset	Internal	0.8650	0.6324	0.7306	0.8650	0.5273
Varroa Dataset	External	0.7120	0.5210	0.6015	0.6980	0.3840
HoneyBee VarroaMite	Internal	0.3905	0.3538	0.3713	0.3905	0.1193
HoneyBee VarroaMite	External	0.2840	0.2110	0.2420	0.2315	0.0520

- Model, Varroa Dataset eğitiminde 0.8650 mAP50 değerine ulaşarak son derece güçlü bir performans sergilemiştir. Varroa paraziti gibi mikro ölçekli ve ayırt edilmesi zor olan nesneler için elde edilen bu başarı skoru, literatürde benzer veri setleriyle yürütülen geleneksel CNN tabanlı çalışmaların ve standart nesne tespiti modellerinin başarı ortalamasını geride bırakmıştır. Çok ölçekli öznitelik yapısı, küçük nesnelerin ayırt edici geometrik detaylarını yakalamada yüksek verimlilik sunmuştur.
- Varroa Dataset üzerinde eğitilen model, harici doğrulama (external validation) testlerinde tamamen farklı bir veri dağılımıyla karşılaşmasına rağmen 0.6980 mAP50 skorunu korumayı başarmıştır. Görüntü tespiti çalışmalarında dış veri setlerinde yaşanan keskin performans düşüşleri göz önüne alındığında, bu seviyedeki bir koruma oranı, modelin yüksek genelleme yeteneğine sahip olduğunu ve literatürdeki birçok alternatifine kıyasla aşırı öğrenme (overfitting) problemine karşı direnç gösterdiğini kanıtlamaktadır.

Sonuç olarak; Deformable DETR mimarisi, standart DETR modelinin kısıtlarını tamamen aşarak hem yakınsama hızı hem de küçük nesne tespiti performansında

literatürdeki mevcut çalışmaların üzerine çıkan başarılı bir optimizasyon seviyesi yakalamıştır. Elde edilen yüksek doğruluk oranları ve dış veri kaynaklarına karşı sergilenen direnç, bu modeli varroa paraziti tespiti probleminde güçlü ve güvenilir bir çözüm haline getirmektedir.

7.3.3. RT-DETR Deney Sonuçları

Uçtan uca Transformer mimarilerinin yüksek doğruluk kabiliyetini gerçek zamanlı (real-time) çalışma hızıyla birleştiren RT-DETR modeli, çalışmada değerlendirilen son yenilikçi yaklaşımı oluşturmaktadır. Model, hem işlem verimliliği hem de hassas konumlandırma dengesi sunarak operasyonel senaryolarda yüksek potansiyel göstermiştir. Gelişmiş hibrit kodlayıcı (hybrid encoder) yapısı sayesinde, nesne özniteliklerini çok ölçekli seviyede ve hız kaybı yaratmadan işleyebilmektedir.

Modelin her iki veri seti üzerindeki genel performansı, içsel (internal) ve harici (external) doğrulama metrikleri ayrımında incelenmiş ve elde edilen tüm bulgular aşağıdaki ana performans tablosunda özetlenmiştir:

Tablo 12. RT-DETR modelinin internal ve external validation sonuçları.

Eğitim Veri Seti	Değerlendirme	Precision	Recall	F1	mAP50	mAP50-95
Varroa Dataset	Internal	0.8640	0.8060	0.8340	0.8446	0.5194
Varroa Dataset	External	0.7250	0.6540	0.6877	0.7120	0.3950
HoneyBee VarroaMite	Internal	0.8576	0.7817	0.8179	0.8448	0.3724
HoneyBee VarroaMite	External	0.6950	0.6120	0.6509	0.6780	0.2650

- **Sınıf Bazlı Kararlılık:** Sınıf bazlı sonuçlar incelendiğinde, morfolojik olarak belirgin özneliklere sahip olan arı (bee) sınıfında 0.9930 mAP50 gibi kusursuza yakın bir başarı yakalanırken; tespiti son derece güç olan mikro boyutlu varroa sınıfında ise 0.6740 mAP50 skoru elde edilmiştir. Bu durum, modelin karmaşık ve küçük nesne senaryolarında dahi arka plan gürültüsünü verimli bir şekilde filtreleyebildiğini göstermektedir.
- **Güçlü Genelleme Yeteneği:** Her iki veri seti eğitiminin ardından gerçekleştirilen bağımsız dış doğrulama (external validation) testlerinde, RT-DETR modelinin performans koruma katsayısı yüksek çıkmıştır. Model, tamamen farklı dağılımlara sahip harici testlerde sırasıyla 0.7120 ve 0.6780 mAP50 seviyelerinde kalarak aşırı öğrenme (overfitting) problemine karşı güçlü bir direnç göstermiş ve gerçek hayat senaryolarına uyarlanabilirliğini kanıtlamıştır.
- **Konumlandırma Hassasiyeti:** Katı IoU eşiklerini içeren mAP50-95 metriklerinde model, özellikle Varroa Dataset üzerinde 0.5194 gibi yüksek bir konumlandırma doğruluğuna ulaşmıştır. Bu durum, RT-DETR bünyesindeki gerçek zamanlı tahmin kafasının sadece nesne varlığını saptamakla kalmayıp, nesne sınır çizgilerini (bounding box) de literatürdeki çalışmalara kıyasla çok daha hassas şekilde çizbildiğini doğrulamaktadır.

7.4. Tüm Modellerin Genel Sonuç Tablosu

Bu bölümde proje kapsamında değerlendirilen tüm model ailelerine ait öne çıkan sonuçlar görev türlerine göre ayrı tablolar halinde sunulmuştur. Modeller farklı görev yapılarına sahip olduğu için classification ve detection sonuçları ayrı ayrı değerlendirilmiştir. Classification modellerinde temel karşılaştırma metriği olarak F1-score kullanılırken, nesne tespiti modellerinde mAP50 veya geleneksel sliding-window tabanlı modeller için F1@IoU0.20 metriği dikkate alınmıştır.

Tablo 13. Classification Modellerinin Genel Sonuçları.

Model Ailesi	Model	Eğitim Veri Seti	Metrik	Internal	External
Geleneksel ML	SVM	Varroa	F1-score	0.9400	0.9400
Geleneksel ML	SVM	HoneyBee	F1-score	0.9200	0.7500
Geleneksel ML	Random Forest	Varroa	F1-score	0.9200	-
Geleneksel ML	Random Forest	HoneyBee	F1-score	0.9100	0.7800

CNN	ResNet18	Varroa	F1-score	0.9007	0.8177
CNN	ResNet18	HoneyBee	F1-score	0.9109	0.6101
CNN	EfficientNet-B0	Varroa	F1-score	0.8928	0.8499
CNN	EfficientNet-B0	HoneyBee	F1-score	0.9178	0.5696

Tablo 14. Nesne Tespiti Modellerinin Genel Sonuçları.

Model Ailesi	Model	Eğitim Veri Seti	Metrik	Internal	External
Geleneksel ML	SVM	Varroa	F1@IoU0.20	0.3900	0.4300
Geleneksel ML	Random Forest	HoneyBee	F1@IoU0.20	0.5300	0.2300
CNN	YOLOv8n	Varroa	mAP50	0.8600	0.6290
CNN	YOLOv8n	HoneyBee	mAP50	0.7500	0.0885
CNN	YOLO26n	Varroa	mAP50	0.7870	0.5570
CNN	YOLO26n	HoneyBee	mAP50	0.7480	0.0930
Transformer	DETR	Varroa	mAP50	0.4964	0.3540
Transformer	Deformable DETR	Varroa	mAP50	0.8650	0.6980
Transformer	Deformable DETR	HoneyBee	mAP50	0.3905	0.2315
Transformer	RT-DETR	Varroa	mAP50	0.8446	0.7120
Transformer	RT-DETR	HoneyBee	mAP50	0.8448	0.6780

Tablo 15. Model Ailelerine Göre En İyi External Sonuçlar

Model Ailesi	Görev	En İyi Model	Metrik	External
Geleneksel ML	Classification	SVM - Varroa	F1-score	0.9400
Geleneksel ML	Detection	SVM - Varroa	F1@IoU0.20	0.4300
CNN	Classification	EfficientNet-B0 - Varroa	F1-score	0.8499
CNN	Detection	YOLOv8n - Varroa	mAP50	0.6290
Transformer	Detection	RT-DETR - Varroa	mAP50	0.7120

Tablolar incelendiğinde classification görevinde geleneksel makine öğrenmesi ve CNN tabanlı modellerin yüksek F1-score değerlerine ulaşabildiği görülmektedir. Detection görevinde ise transformer tabanlı RT-DETR ve Deformable DETR modelleri external validation aşamasında güçlü sonuçlar üretmiştir. YOLO tabanlı modeller özellikle Varroa Dataset üzerinde eğitildiğinde kabul edilebilir external sonuçlar verirken, HoneyBee VarroaMite üzerinde eğitilen YOLO modellerinde external validation performansının belirgin şekilde düştüğü görülmektedir. Bu durum, model başarısının yalnızca mimariye değil, eğitim veri setinin external veri setine olan benzerliğine de bağlı olduğunu göstermektedir.

8. PERFORMANS GRAFİKLERİ VE KARŞILAŞTIRMALI ANALİZ

Bu bölümde, proje kapsamında değerlendirilen model ailelerinin deney sonuçları grafikler üzerinden karşılaştırmalı olarak incelenmiştir. Geleneksel makine öğrenmesi tabanlı modeller, CNN tabanlı sınıflandırma modelleri, YOLO tabanlı nesne tespiti modelleri ve transformer tabanlı yaklaşımlar; kendi görev türlerine uygun performans metrikleriyle değerlendirilmiştir.


Grafiksel değerlendirme sürecinde classification modelleri için Accuracy, Precision, Recall ve F1-score gibi metrikler; nesne tespiti modelleri için ise Precision, Recall, F1-score, mAP50 ve mAP50-95 değerleri dikkate alınmıştır. Böylece modellerin yalnızca sayısal tablo sonuçları değil, internal validation ve external validation aşamaları arasındaki performans değişimleri de daha anlaşılır biçimde görselleştirilmiştir.

Bu bölümde özellikle internal ve external sonuçlar arasındaki farklara odaklanılmıştır. Internal değerlendirme, modelin kendi eğitim veri dağılımına yakın örneklerdeki başarısını gösterirken; external validation, modelin farklı veri kaynaklarına karşı genelleme kapasitesini ortaya koymaktadır. Bu nedenle grafikler, model ailelerinin yalnızca kendi veri setlerindeki başarılarını değil, farklı veri dağılımlarına karşı dayanıklılıklarını da karşılaştırmak amacıyla kullanılmıştır.

8.1. Geleneksel Makine Öğrenmesi Modellerinin Grafiksel Değerlendirmesi

Bu bölümde geleneksel makine öğrenmesi tabanlı SVM ve Random Forest modellerinin performansları grafikler üzerinden değerlendirilmiştir. Geleneksel makine öğrenmesi hattında modeller önce görüntü bölgesi düzeyinde Varroa/no_varroa sınıflandırması için kullanılmış, daha sonra seçilen modeller sliding-window tabanlı yapı içerisinde tam görüntü üzerinde nesne tespiti amacıyla değerlendirilmiştir. Bu nedenle grafiksel analiz, classification ve detection sonuçları olmak üzere iki ayrı alt başlık altında ele alınmıştır.

8.1.1. Geleneksel Makine Öğrenmesi Modellerinin Classification F1-score Değerlerine Göre Değerlendirilmesi




Şekil 3. Geleneksel ML modellerinin internal ve external classification F1-score karşılaştırması.

Şekil 3’de geleneksel makine öğrenmesi modellerinin internal ve external classification F1-score değerleri karşılaştırılmıştır. Grafik incelendiğinde, SVM ve Random Forest modellerinin internal classification aşamasında yüksek F1-score değerlerine ulaştığı görülmektedir. Özellikle SVM ailesi, her iki geliştirme veri setinde de güçlü sınıflandırma başarısı göstermiştir.

External classification sonuçlarında ise Varroa Dataset kaynaklı SVM modelinin yüksek F1-score değerini koruduğu, HoneyBee VarroaMite kaynaklı SVM ve Random Forest modellerinde ise daha belirgin bir performans düşüşü olduğu görülmektedir. Bu durum, görüntü bölgesi düzeyindeki sınıflandırma probleminde bile eğitim veri seti ile external validation veri seti arasındaki dağılım farkının model başarısını etkileyebildiğini göstermektedir.

8.1.2. Geleneksel Makine Öğrenmesi Modellerinin Detection F1-score Değerlerine Göre Değerlendirilmesi



Şekil 4. Geleneksel ML modellerinin internal ve external detection F1@IoU0.20 karşılaştırması.

Şekil 4’de geleneksel makine öğrenmesi modellerinin full-image detection sonuçları F1@IoU0.20 metriği üzerinden karşılaştırılmıştır. Detection sonuçları incelendiğinde, classification aşamasına göre daha düşük performans değerleri elde edildiği görülmektedir. Bu fark, sliding-window yaklaşımında modelin yalnızca Varroa içeren pencereyi doğru sınıflandırmasının yeterli olmamasından kaynaklanmaktadır. Aday pencerelerin gerçek Varroa konumuyla yeterli düzeyde örtüşmesi ve yanlış pozitif tespitlerin sınırlı kalması da detection başarısını doğrudan etkilemektedir.

Internal detection değerlendirmesinde HoneyBee VarroaMite üzerinde eğitilen Random Forest modeli güçlü sonuç üretirken, external validation aşamasında Varroa Dataset kaynaklı SVM modeli daha dengeli bir genelleme performansı göstermiştir. Bu sonuç, geleneksel makine öğrenmesi modellerinde yüksek internal performansın external validation başarısını her zaman garanti etmediğini göstermektedir.

Genel olarak grafikler, geleneksel makine öğrenmesi modellerinin görüntü bölgesi düzeyinde güçlü sınıflandırma performansı gösterebildiğini; ancak tam görüntü


üzerinde konum belirleme ve yanlış pozitif kontrolü gerektiren detection görevinde daha sınırlı kaldığını ortaya koymaktadır. Bu durum, klasik özellik çıkarımı ve geleneksel sınıflandırıcıların Varroa ayrımı için kullanılabilir olduğunu, ancak nesne tespiti senaryosunda sliding-window, eşikleme ve kutu birleştirme gibi ek adımlara bağımlı olduklarını göstermektedir.

8.2. CNN Tabanlı Modellerin Grafıksel Değerlendirmesi

Bu bölümde, CNN tabanlı sınıflandırma modelleri ve YOLO tabanlı nesne tespiti modellerinin deney sonuçları grafikler üzerinden değerlendirilmiştir. Grafiklerde modellerin internal validation ve external validation performansları karşılaştırılmıştır. Böylece modellerin yalnızca kendi eğitim veri setlerine ait validation splitlerinde değil, eğitim sürecinde kullanılmayan farklı bir external validation veri seti üzerindeki genelleme performansları da incelenmiştir.

YOLO tabanlı modeller için Precision, Recall, F1-score, mAP50 ve mAP50-95 metrikleri dikkate alınmıştır. ResNet18 ve EfficientNet-B0 gibi binary classification modelleri için ise Accuracy, Precision, Recall ve F1-score değerleri değerlendirilmiştir. Bu metrikler, modellerin hem doğru pozitif tahmin üretme başarısını hem de gerçek varroa örneklerini yakalama düzeyini analiz etmek amacıyla kullanılmıştır.

8.2.1. YOLO Modellerinin mAP50 Değerlerine Göre Değerlendirilmesi




Şekil 5. YOLO modellerinin internal ve external validation mAP50 karşılaştırması

Şekil 5’de YOLOv8n ve YOLO26n modellerinin internal ve external validation mAP50 değerleri karşılaştırılmıştır. mAP50 metriği, nesne tespiti modellerinde IoU 0.50 eşliğinde genel tespit başarısını göstermektedir. Grafik incelendiğinde, Varroa Dataset

üzerinde eğitilen YOLO modellerinin external validation aşamasında performanslarını HoneyBee VarroaMite üzerinde eğitilen modellere göre daha iyi koruduğu görülmektedir.

YOLOv8n modeli Varroa Dataset üzerinde internal validation aşamasında mAP50 = 0.860 değerine, external validation aşamasında ise mAP50 = 0.629 değerine ulaşmıştır. YOLO26n modeli de Varroa Dataset üzerinde external validation aşamasında mAP50 = 0.557 değerini elde etmiştir. Buna karşılık HoneyBee VarroaMite üzerinde eğitilen YOLO modellerinde external mAP50 değerleri oldukça düşük kalmıştır. Bu durum, HoneyBee VarroaMite veri seti ile external validation veri seti arasında görüntü dağılımı, nesne ölçeği ve anotasyon yapısı açısından belirgin farklar olduğunu göstermektedir.

8.2.2. YOLO Modellerinin Recall Değerlerine Göre Değerlendirilmesi




Şekil 6. YOLO modellerinin internal ve external validation recall karşılaştırması

Şekil 6’da YOLO modellerinin internal ve external validation recall değerleri gösterilmiştir. Recall metriği, modelin gerçek varroa örneklerini ne kadar yakalayabildiğini ifade etmektedir. Varroa tespiti probleminde recall önemli bir metriktir çünkü modelin varroa parazitini kaçırmaması, uygulama açısından riskli bir durum oluşturabilir.

Grafik incelendiğinde, tüm YOLO modellerinde external validation aşamasında recall değerlerinin internal validation değerlerine göre düştüğü görülmektedir. En yüksek external recall değeri Varroa Dataset üzerinde eğitilen YOLOv8n modelinde elde edilmiştir. YOLOv8n - Varroa modeli external validation’da recall = 0.549 değerine ulaşırken, YOLO26n - Varroa modeli recall = 0.496 değerini elde etmiştir. HoneyBee

VarroaMite üzerinde eğitilen YOLO modellerinde external recall değerlerinin daha düşük kalması, bu modellerin farklı veri setindeki varroa örneklerini yakalamakta zorlandığını göstermektedir.

8.2.3. YOLO Modellerinin mAP50-95 Değerlerine Göre Değerlendirilmesi




Şekil 7. YOLO modellerinin internal ve external validation mAP50-95 karşılaştırması

Şekil 7’de YOLO modellerinin internal ve external validation mAP50-95 değerleri karşılaştırılmıştır. mAP50-95 metriği, farklı IoU eşiklerinde hesaplandığı için bounding box konumlandırma başarısını daha katı biçimde değerlendirmektedir. Bu nedenle mAP50-95 değeri genellikle mAP50 değerinden daha düşük çıkmaktadır.

Grafik incelendiğinde tüm YOLO modellerinde mAP50-95 değerlerinin mAP50 değerlerine göre daha düşük olduğu görülmektedir. Bu durum beklenen bir sonuçtur çünkü varroa paraziti görüntü içerisinde küçük alan kaplayan bir nesnedir. Küçük nesnelerde bounding box tahminindeki küçük konum hataları bile IoU değerini belirgin biçimde düşürebilmektedir. External validation sonuçlarında özellikle HoneyBee VarroaMite üzerinde eğitilen modellerin mAP50-95 değerlerinin oldukça düşük kalması, bu modellerin farklı veri setinde varroa konumlandırmasını hassas şekilde yapamadığını göstermektedir.

8.2.4. YOLO Modellerinin F1-score Değerlerine Göre Değerlendirilmesi




Şekil 8. YOLO modellerinin internal ve external validation F1-score karşılaştırması

Şekil 8’de YOLO modellerinin Precision ve Recall değerleri kullanılarak hesaplanan F1-score değerleri gösterilmiştir. F1-score, precision ve recall değerlerini birlikte değerlendirdiği için modelin pozitif tahmin doğruluğu ile gerçek varroa örneklerini yakalama başarısını dengeli şekilde ifade etmektedir.

Grafik incelendiğinde, Varroa Dataset üzerinde eğitilen YOLO modellerinin external validation aşamasında F1-score değerlerini HoneyBee VarroaMite üzerinde eğitilen modellere göre daha iyi koruduğu görülmektedir. YOLOv8n - Varroa modeli external validation aşamasında F1-score = 0.657 değerine ulaşırken, YOLO26n - Varroa modeli F1-score = 0.553 değerini elde etmiştir. HoneyBee VarroaMite üzerinde eğitilen YOLO modellerinde ise external F1-score değerleri oldukça düşük kalmıştır. Bu sonuç, HoneyBee veri setinden öğrenilen nesne tespit örüntülerinin external validation veri setine yeterince genellenemediğini göstermektedir.

8.2.5. Classification Modellerinin F1-score Değerlerine Göre Değerlendirilmesi




Şekil 9. Classification modellerinin internal ve external validation F1-score karşılaştırması

Şekil 9’da ResNet18 ve EfficientNet-B0 modellerinin internal ve external validation F1-score değerleri karşılaştırılmıştır. F1-score, precision ve recall değerlerini birlikte değerlendirdiği için classification modellerinin dengeli başarısını göstermektedir. Grafik incelendiğinde, tüm modellerin internal validation aşamasında yüksek F1-score değerleri elde ettiği görülmektedir.

External validation sonuçları incelendiğinde, Varroa Dataset üzerinde eğitilen ResNet18 ve EfficientNet-B0 modellerinin F1-score değerlerini daha iyi koruduğu görülmektedir. EfficientNet-B0 - Varroa modeli external validation aşamasında F1-score = 0.8499 değeriyle en güçlü classification sonuçlarından birini üretmiştir. HoneyBee VarroaMite üzerinde eğitilen modellerde ise internal F1-score değerleri yüksek olmasına rağmen external F1-score değerlerinde belirgin düşüş görülmüştür. Bu durum, HoneyBee veri setiyle öğrenilen özelliklerin external veri setine sınırlı şekilde aktarıldığını göstermektedir.

8.2.6. Classification Modellerinin Recall Değerlerine Göre Değerlendirilmesi




Şekil 10. Classification modellerinin internal ve external validation recall karşılaştırması

Şekil 10’da classification modellerinin internal ve external validation recall değerleri karşılaştırılmıştır. Recall metriği, gerçek varroa içeren görüntülerin ne kadarının model tarafından doğru şekilde varroa olarak sınıflandırıldığını göstermektedir. Bu nedenle varroa tespiti probleminde recall metriği önemli bir değerlendirme ölçütüdür.

Grafik incelendiğinde, internal validation aşamasında modellerin recall değerlerinin genel olarak yüksek olduğu görülmektedir. External validation aşamasında ise tüm modellerde belirli ölçüde düşüş meydana gelmiştir. Varroa Dataset üzerinde eğitilen modeller, HoneyBee VarroaMite üzerinde eğitilen modellere göre external validation aşamasında recall değerlerini daha iyi korumuştur. Bu durum, Varroa Dataset’in external validation veri setiyle daha benzer bir dağılıma sahip olabileceğini göstermektedir.

8.2.7. Classification Modellerinin External Accuracy Değerlerine Göre Değerlendirilmesi



Şekil 11. Classification modellerinin external validation accuracy karşılaştırması

Şekil 11’de classification modellerinin external validation accuracy değerleri karşılaştırılmıştır. External accuracy, modellerin eğitim sürecinde kullanılmayan Varroa Mites Detector veri seti üzerindeki genel doğru sınıflandırma oranını göstermektedir. Bu grafik, modellerin farklı bir veri kaynağına karşı genelleme başarısını özet şekilde değerlendirmek için kullanılmıştır.

Grafik incelendiğinde en yüksek external accuracy değerinin Varroa Dataset üzerinde eğitilen EfficientNet-B0 modelinde elde edildiği görülmektedir. EfficientNet-B0 - Varroa modeli external validation aşamasında accuracy = 0.9005 değerine ulaşmıştır. ResNet18 - Varroa modeli de accuracy = 0.8820 değeriyle güçlü bir external validation performansı göstermiştir. Buna karşılık HoneyBee VarroaMite üzerinde eğitilen ResNet18 ve EfficientNet-B0 modellerinin external accuracy değerleri daha düşük kalmıştır. Bu durum, Varroa Dataset ile eğitilen classification modellerinin external veri setine daha iyi genellendiğini göstermektedir.


Genel olarak grafikler incelendiğinde, modellerin internal validation aşamasında yüksek başarı değerlerine ulaşabildiği ancak external validation aşamasında performans kaybı yaşayabildiği görülmektedir. Bu performans kaybı özellikle HoneyBee VarroaMite üzerinde eğitilen modellerde daha belirgindir. Hem YOLO tabanlı nesne tespiti modellerinde hem de ResNet18/EfficientNet-B0 tabanlı classification modellerinde

Varroa Dataset üzerinde eğitilen modellerin external validation sonuçları daha dengeli kalmıştır.

Bu sonuçlar, model başarısının yalnızca kullanılan mimariye bağlı olmadığını göstermektedir. Eğitim veri setinin görüntü dağılımı, çözünürlük yapısı, anotasyon kalitesi ve external validation veri setine olan benzerliği model başarısı üzerinde doğrudan etkilidir. Bu nedenle varroa tespiti gibi küçük nesne içeren biyolojik görüntü problemlerinde yalnızca internal validation sonuçlarına bakmak yeterli değildir. External validation sonuçları, modelin farklı veri kaynaklarındaki gerçekçi başarısını değerlendirmek için kritik öneme sahiptir.


8.3. Transformer Tabanlı Modellerin Grafıksel Değerlendirmesi

8.3.1 Modellerin Precision Değerine Göre Değerlendirmesi




Şekil 12. Transformer modellerinin precision değerleri.

8.3.2 Modellerin Recall Değerine Göre Değerlendirmesi




Şekil 13. Transformer modellerinin recall değerleri.

8.3.3 Modellerin F1 Değerine Göre Değerlendirmesi




Şekil 14. Transformer modellerinin F1-score değerleri.

8.3.4 Modellerin mAP50 Değerine Göre Değerlendirmesi



Şekil 15. Transformer modellerinin mAP50 değerleri.

8.3.5 Modellerin mAP50-95 Değerine Göre Değerlendirmesi



Şekil 16. Transformer modellerinin mAP50-95 değerleri.

8.4. Tüm Model Ailelerinin Genel Karşılaştırması

Bu bölümde, proje kapsamında değerlendirilen geleneksel makine öğrenmesi, CNN tabanlı modeller ve transformer tabanlı modeller genel performans açısından karşılaştırılmıştır. Model aileleri farklı görev türleri üzerinde çalıştığı için değerlendirme süreci classification ve detection sonuçları üzerinden ayrı ayrı ele alınmıştır. Classification modellerinde temel karşılaştırma metriği olarak F1-score,


detection modellerinde ise mAP50 veya geleneksel sliding-window tabanlı modeller için F1@IoU0.20 metriği dikkate alınmıştır.

Model ailelerine göre en iyi external validation sonuçları incelendiğinde, classification görevinde geleneksel makine öğrenmesi tabanlı SVM modelinin ve CNN tabanlı EfficientNet-B0 modelinin güçlü sonuçlar ürettiği görülmektedir. SVM modeli Varroa Dataset üzerinde external classification aşamasında F1-score = 0.94 değerini korurken, EfficientNet-B0 modeli Varroa Dataset üzerinde external validation aşamasında F1-score = 0.8499 değerine ulaşmıştır. Bu durum, classification görevinde hem el yapımı özelliklere dayalı geleneksel yaklaşımların hem de CNN tabanlı derin öğrenme modellerinin başarılı sonuçlar üretebildiğini göstermektedir.

Detection görevi açısından sonuçlar incelendiğinde, transformer tabanlı RT-DETR ve Deformable DETR modellerinin external validation aşamasında güçlü sonuçlar ürettiği görülmektedir. RT-DETR modeli Varroa Dataset üzerinde external mAP50 = 0.7120 değerine ulaşırken, Deformable DETR modeli external mAP50 = 0.6980 değerini elde etmiştir. CNN tabanlı YOLO modelleri içerisinde en güçlü external detection sonucu YOLOv8n modelinin Varroa Dataset eğitimiyle elde edilmiş ve external mAP50 = 0.6290 olarak ölçülmüştür.


Geleneksel makine öğrenmesi tabanlı modeller ise classification aşamasında yüksek sonuçlar üretmesine rağmen, sliding-window tabanlı detection aşamasında daha sınırlı performans göstermiştir. Bu durum, patch-level classification başarısının tam görüntü üzerinde nesne konumlandırma başarısına doğrudan yansımadığını göstermektedir. Özellikle küçük nesne karakteri taşıyan Varroa parazitinde, aday pencere seçimi, eşikleme ve kutu birleştirme adımları detection başarısını önemli ölçüde etkilemektedir.

Genel olarak model aileleri karşılaştırıldığında, classification görevi için geleneksel makine öğrenmesi ve CNN tabanlı modellerin güçlü sonuçlar verdiği; detection görevi için ise transformer tabanlı modellerin daha yüksek external validation başarısı sunduğu görülmektedir. Bununla birlikte YOLO tabanlı modeller, daha hafif ve pratik nesne tespiti yaklaşımları olarak özellikle Varroa Dataset üzerinde kabul edilebilir genelleme performansı göstermiştir. Bu nedenle model seçiminin, projenin hedeflediği kullanım senaryosuna göre yapılması gerektiği sonucuna varılmıştır.



Şekil 17. Model ailelerine göre en iyi external validation sonuçları.


Şekil 17 incelendiğinde, external validation açısından en yüksek classification sonucunun Geleneksel ML - SVM modelinde, en yüksek detection sonucunun ise transformer tabanlı RT-DETR modelinde elde edildiği görülmektedir. Bu durum, farklı görev türlerinde farklı model ailelerinin öne çıkabildiğini göstermektedir.



Şekil 18. Classification modellerinin internal ve external F1-score karşılaştırması.

Classification modellerinin F1-score değerleri incelendiğinde, internal validation aşamasında modellerin genel olarak yüksek başarı gösterdiği görülmektedir. Ancak external validation aşamasına geçildiğinde özellikle HoneyBee VarroaMite üzerinde

eğitilen bazı modellerde performans düşüşü yaşanmıştır. Varroa Dataset üzerinde eğitilen modeller ise external validation aşamasında daha dengeli sonuçlar üretmiştir.




Şekil 19. Nesne tespiti modellerinin internal ve external mAP50 karşılaştırması.

Detection modellerinin mAP50 değerleri incelendiğinde, transformer tabanlı RT-DETR ve Deformable DETR modellerinin external validation aşamasında en güçlü sonuçları verdiği görülmektedir. YOLOv8n modeli de Varroa Dataset üzerinde eğitildiğinde external validation aşamasında kabul edilebilir bir performans göstermiştir. Buna karşılık HoneyBee VarroaMite üzerinde eğitilen YOLO modellerinde external validation performansının belirgin biçimde düştüğü görülmektedir.

8.5. Internal ve External Validation Sonuçlarının Karşılaştırılması

Internal ve external validation sonuçlarının birlikte değerlendirilmesi, modellerin yalnızca kendi veri setlerine ait örneklerdeki başarısını değil, farklı veri dağılımlarına karşı genelleme kapasitesini de analiz etmeyi sağlamaktadır. Internal validation, modelin eğitim aldığı veri dağılımına yakın örneklerdeki performansını gösterirken; external validation, eğitim ve model seçimi sürecinde kullanılmayan bağımsız bir veri seti üzerindeki başarısını ifade etmektedir.

Bu bölümde, farklı model ailelerinden seçilen güçlü modellerin internal ve external validation sonuçları karşılaştırılmıştır. Classification modelleri için F1-score değerleri, nesne tespiti modelleri için ise mAP50 veya geleneksel sliding-window yaklaşımında $F1@IoU0.20$ değerleri dikkate alınmıştır. Böylece farklı görev türlerine sahip modellerin internal-external performans değişimleri daha anlaşılır biçimde görselleştirilmiştir.




Şekil 20. Seçili modellerde internal ve external validation sonuçlarının karşılaştırılması.

Şekil 20 incelendiğinde, seçili modellerin büyük bölümünde external validation sonucunun internal validation sonucuna göre daha düşük olduğu görülmektedir. Bu durum beklenen bir sonuçtur; çünkü external validation veri seti, modellerin eğitim sürecinde görmediği farklı bir veri dağılımını temsil etmektedir. Buna karşılık bazı modeller external validation aşamasında performansını daha iyi koruyarak daha güçlü genelleme kabiliyeti göstermiştir.

Classification tarafında SVM ve EfficientNet-B0 modellerinin external validation sonuçlarını güçlü şekilde koruduğu görülmektedir. SVM modeli Varroa Dataset üzerinde internal ve external classification sonuçlarında aynı F1-score değerini üretmiştir. EfficientNet-B0 modeli ise internal F1-score değerine yakın bir external F1-score değeri elde ederek CNN tabanlı classification modelleri içerisinde dengeli bir genelleme performansı sunmuştur.

Detection tarafında RT-DETR ve Deformable DETR modelleri external validation aşamasında yüksek mAP50 değerlerini koruyarak öne çıkmıştır. YOLOv8n modeli de Varroa Dataset üzerinde eğitildiğinde external validation aşamasında kabul edilebilir bir performans göstermiştir. Bu sonuçlar, farklı veri kaynaklarına genelleme açısından transformer tabanlı detection modellerinin güçlü bir potansiyel sunduğunu göstermektedir.



Şekil 21. Seçili modellerde internal validation'dan external validation'a geçişte oluşan performans kaybı.

Performans kaybı grafiği, internal validation'dan external validation'a geçişte modellerin ne kadar düşüş yaşadığını göstermektedir. Grafikteki düşük performans kaybı, modelin eğitim aldığı veri setine aşırı bağımlı kalmadığını ve farklı veri dağılımlarında da benzer başarıyı sürdürebildiğini ifade etmektedir. Buna karşılık yüksek performans kaybı, modelin kendi veri setindeki örüntülere daha fazla uyum sağladığını ve dış veri setine aktarımda zorlandığını gösterebilir.

Seçili modeller arasında classification görevinde SVM modelinin performansını koruduğu, EfficientNet-B0 modelinin ise düşük bir performans kaybıyla external validation aşamasında güçlü kalabildiği görülmektedir. Detection görevinde ise RT-DETR ve Deformable DETR modelleri, YOLOv8n modeline göre external validation aşamasında daha yüksek skorlar üretmiştir. Bu durum, transformer tabanlı detection modellerinin farklı veri kaynaklarına karşı daha dayanıklı olabileceğini göstermektedir.

Genel olarak internal ve external validation sonuçları arasındaki farklar, veri seti seçiminin ve veri dağılımının model başarısı üzerinde önemli bir etkiye sahip olduğunu ortaya koymaktadır. Internal validation sonuçları modelin kendi veri setindeki öğrenme başarısını gösterirken, external validation sonuçları gerçekçi genelleme performansını değerlendirmek için daha kritik bir ölçüt olarak ele alınmalıdır.

9. BULGULAR VE DEĞERLENDİRME

Bu bölümde, proje kapsamında elde edilen deney sonuçları genel bulgular açısından değerlendirilmiştir. Farklı model ailelerinin classification ve detection görevlerindeki performansları, internal validation ve external validation sonuçları birlikte dikkate

alınarak yorumlanmıştır. Böylece modellerin yalnızca kendi veri setlerine ait değerlendirme sonuçları değil, farklı veri kaynaklarına karşı gösterdikleri genelleme başarıları da analiz edilmiştir.

Deneysel sonuçlar incelendiğinde, model başarısının yalnızca kullanılan algoritmaya bağlı olmadığı görülmektedir. Eğitim veri setinin yapısı, sınıf dağılımı, görüntü çözünürlüğü, hedef nesnenin görüntüdeki boyutu, anotasyon kalitesi ve external validation veri setiyle olan benzerliği model performansını doğrudan etkilemiştir. Bu nedenle bulgular, model aileleri kadar veri seti seçimi ve değerlendirme yaklaşımı açısından da ele alınmıştır.

9.1. Veri Seti Seçiminin Model Başarısına Etkisi

Deney sonuçları, veri seti seçiminin model başarısı üzerinde önemli bir etkiye sahip olduğunu göstermektedir. Projede kullanılan Varroa Dataset ve HoneyBee VarroaMite veri setleri, farklı görüntü dağılımlarına ve farklı sınıf dengelerine sahiptir. Bu durum, modellerin internal validation ve external validation sonuçları arasında belirgin farklılıkların oluşmasına neden olmuştur.

Varroa Dataset üzerinde eğitilen modellerin birçok durumda external validation aşamasında daha dengeli sonuçlar ürettiği görülmüştür. Özellikle CNN tabanlı classification modellerinde Varroa Dataset üzerinde eğitilen ResNet18 ve EfficientNet-B0 modelleri external validation aşamasında güçlü F1-score değerlerini koruyabilmiştir. Benzer şekilde YOLO tabanlı nesne tespiti modellerinde de Varroa Dataset üzerinde eğitilen modeller, HoneyBee VarroaMite üzerinde eğitilen modellere göre external validation aşamasında daha yüksek mAP50 değerleri üretmiştir.

HoneyBee VarroaMite veri seti üzerinde eğitilen bazı modeller ise internal validation aşamasında yüksek sonuçlar elde etmesine rağmen external validation aşamasında belirgin performans düşüşü yaşamıştır. Bu durum, HoneyBee VarroaMite veri setinin kendi içinde öğrenilebilir örüntüler sunduğunu ancak external validation için kullanılan Varroa Mites Detector veri setiyle dağılımsal olarak daha fazla farklılık gösterebildiğini düşündürmektedir. Görüntü çözünürlüğü, arıların konumu, varroa parazitinin çözünürlüğü, bounding box ölçeği ve anotasyon yapısındaki farklılıklar bu performans değişiminde etkili olabilecek faktörlerdir.

Geleneksel makine öğrenmesi tabanlı modellerde de veri seti etkisi gözlemlenmiştir. Patch-level classification aşamasında yüksek F1-score değerleri elde edilmesine rağmen, tam görüntü üzerinde sliding-window tabanlı detection aşamasında performans daha sınırlı kalmıştır. Bu durum, veri setinden elde edilen görüntü bölgeleri üzerinde sınıflandırma yapmanın nispeten daha kolay olduğunu; ancak aynı başarının tam görüntü üzerinde konum belirleme görevine doğrudan taşınamayabileceğini göstermektedir.

Transformer tabanlı modellerde ise özellikle Varroa Dataset üzerinde eğitilen Deformable DETR ve RT-DETR modellerinin external validation aşamasında güçlü sonuçlar ürettiği görülmüştür. Bu sonuç, çok ölçekli ve attention tabanlı mimarilerin farklı veri dağılımlarına karşı daha dayanıklı özellikler öğrenebileceğini düşündürmektedir. Ancak bu modellerde de veri seti seçiminin etkisi tamamen ortadan kalkmamış, HoneyBee VarroaMite üzerinde eğitilen bazı modellerde external validation performansı daha düşük kalmıştır.

Genel olarak değerlendirildiğinde, eğitim veri setinin external validation veri setine görsel ve anotasyon açısından yakın olması model başarısını olumlu etkilemiştir. Bu nedenle Varroa tespiti gibi küçük nesne içeren biyolojik görüntü problemlerinde yalnızca model mimarisinin seçimi değil, veri setinin çeşitliliği, etiket tutarlılığı ve farklı veri kaynaklarını temsil edebilme kapasitesi de kritik öneme sahiptir.

9.2. Model Ailelerinin Genel Performans Karşılaştırması

Deney sonuçları genel olarak değerlendirildiğinde, farklı model ailelerinin Varroa tespiti probleminde farklı güçlü yönler sunduğu görülmektedir. Geleneksel makine öğrenmesi tabanlı modeller, CNN tabanlı modeller, YOLO tabanlı nesne tespiti modelleri ve Transformer tabanlı modeller; görev türü, veri hazırlama biçimi, hesaplama maliyeti ve genelleme başarısı açısından birbirinden farklı davranışlar göstermiştir.

Geleneksel makine öğrenmesi tabanlı modeller, özellikle görüntü bölgesi düzeyindeki classification görevinde güçlü sonuçlar üretmiştir. SVM ve Random Forest modelleri, HOG, HSV, LBP ve PCA gibi el yapımı özellikler kullanılarak Varroa/no_varroa ayrımı yapabilmektedir. Özellikle SVM modeli, classification aşamasında yüksek F1-score değerleriyle öne çıkmıştır. Bu durum, doğru özellik çıkarımı yapıldığında geleneksel yöntemlerin görüntü bölgeleri üzerinde etkili bir sınıflandırma başarısı sağlayabileceğini göstermektedir.

Bununla birlikte geleneksel makine öğrenmesi modellerinin tam görüntü üzerinde nesne tespiti başarısı, classification başarısına göre daha sınırlı kalmıştır. Bunun temel nedeni, bu modellerin doğrudan bounding box tahmini yapan mimariler olmaması ve sliding-window tabanlı ek bir tespit hattına ihtiyaç duymasıdır. Sliding-window yaklaşımında pencere boyutu, kaydırma adımı, eşik değeri ve kutu birleştirme işlemleri detection başarısını doğrudan etkilemektedir. Bu nedenle patch-level classification başarısı yüksek olsa bile, tam görüntü üzerinde Varroa konumunu doğru belirlemek daha zor hale gelmiştir.

CNN tabanlı classification modelleri olan ResNet18 ve EfficientNet-B0, görüntü düzeyinde Varroa var/yok kararını başarılı şekilde verebilmiştir. Bu modeller, görüntüden otomatik özellik çıkarabilmeleri sayesinde el yapımı özelliklere ihtiyaç duymadan sınıflandırma yapabilmektedir. EfficientNet-B0 modeli özellikle external validation aşamasında güçlü sonuçlar üreterek CNN tabanlı classification modelleri

içerisinde dengeli bir genelleme performansı göstermiştir. Bu sonuç, transfer learning yaklaşımının Varroa sınıflandırma probleminde etkili biçimde kullanılabileceğini göstermektedir.

YOLO tabanlı modeller, Varroa tespiti problemini doğrudan nesne tespiti görevi olarak ele almıştır. YOLOv8n ve YOLOv26n modelleri, görüntü üzerinde Varroa parazitinin konumunu bounding box ile tahmin edebilmesi açısından classification modellerine göre daha açıklayıcı çıktılar üretmiştir. Özellikle Varroa Dataset üzerinde eğitilen YOLOv8n modeli, external validation aşamasında YOLO ailesi içinde en güçlü sonucu vermiştir. Ancak HoneyBee VarroaMite üzerinde eğitilen YOLO modellerinde external validation performansının belirgin şekilde düşmesi, YOLO modellerinin veri seti dağılımı ve anotasyon tarzı farklılıklarından güçlü biçimde etkilenebildiğini göstermektedir.

Transformer tabanlı modeller, özellikle detection görevi açısından güçlü bir alternatif sunmuştur. DETR, Deformable DETR ve RT-DETR modelleri içerisinde RT-DETR ve Deformable DETR modelleri daha başarılı sonuçlar üretmiştir. RT-DETR modeli external validation aşamasında yüksek mAP50 değerlerini koruyarak farklı veri kaynaklarına karşı güçlü bir genelleme performansı göstermiştir. Deformable DETR modeli de çok ölçekli dikkat mekanizması sayesinde küçük nesne karakteri taşıyan Varroa parazitinin tespitinde başarılı sonuçlar üretmiştir.

Model aileleri genel olarak karşılaştırıldığında, classification görevinde geleneksel makine öğrenmesi ve CNN tabanlı modellerin yüksek başarı elde edebildiği görülmektedir. Ancak bu modeller görüntü düzeyinde veya görüntü bölgesi düzeyinde Varroa var/yok kararı üretmekte, doğrudan konum bilgisi sağlamamaktadır. Nesne tespiti görevi açısından ise YOLO ve Transformer tabanlı modeller daha uygun yaklaşımlar sunmaktadır. Bu modeller, Varroa parazitinin görüntü üzerindeki yerini bounding box ile gösterebildiği için pratik kullanım senaryolarında daha açıklayıcı sonuçlar üretmektedir.

Genel değerlendirme sonucunda, tek bir model ailesinin tüm görevlerde açık ara üstün olduğu söylenemez. Classification odaklı bir kullanım senaryosunda SVM ve EfficientNet-B0 gibi modeller güçlü alternatifler olarak öne çıkarken, Varroa parazitinin görüntü üzerindeki konumunun belirlenmesi gereken detection senaryolarında RT-DETR, Deformable DETR ve YOLOv8n modelleri daha uygun görünmektedir. Bu nedenle model seçimi, yalnızca sayısal başarı değerlerine göre değil; kullanım amacı, ihtiyaç duyulan çıktı türü, hesaplama kaynağı, hız beklentisi ve external validation başarısı birlikte değerlendirilerek yapılmalıdır.

9.3. Internal Validation ve External Validation Arasındaki Farklar

Deney sonuçları incelendiğinde, birçok modelde internal validation sonuçlarının external validation sonuçlarına göre daha yüksek olduğu görülmektedir. Bu durum

beklenen bir sonuçtur; çünkü internal validation, modelin eğitim aldığı veri setine ait veya aynı veri dağılımına yakın örnekler üzerinde yapılan değerlendirmeyi ifade etmektedir. External validation ise modelin eğitim ve model seçimi sürecinde hiç görmediği farklı bir veri seti üzerinde test edilmesi anlamına geldiği için, modelin gerçek genelleme başarısını daha net biçimde ortaya koymaktadır.

Internal validation sonuçlarının yüksek olması, modelin kendi veri setindeki görsel örüntüleri, sınıf dağılımını ve anotasyon yapısını öğrenebildiğini göstermektedir. Ancak bu başarı, modelin farklı veri kaynaklarında da aynı performansı göstereceğini garanti etmemektedir. Özellikle Varroa tespiti gibi küçük nesne içeren görüntü problemlerinde, veri setleri arasındaki çözünürlük, ışık koşulları, arı pozisyonları, arka plan yapısı, Varroa parazitinin görünürlüğü ve bounding box anotasyon tarzı performans üzerinde belirgin etki oluşturmaktadır.

External validation sonuçlarında gözlenen performans düşüşleri, modellerin eğitim veri setine özgü bazı örüntülere bağımlı kalabildiğini göstermektedir. Özellikle HoneyBee VarroaMite üzerinde eğitilen bazı CNN ve YOLO tabanlı modellerde external validation aşamasında belirgin düşüşler yaşanmıştır. Bu durum, modelin kendi veri setinde başarılı görünmesine rağmen farklı veri dağılımına sahip görüntülerde aynı başarıyı sürdüremeyebileceğini ortaya koymaktadır.

Buna karşılık bazı modeller external validation aşamasında performanslarını daha iyi korumuştur. Classification tarafında SVM ve EfficientNet-B0 modelleri, özellikle Varroa Dataset üzerinde eğitildiklerinde external validation sonuçlarında güçlü değerler üretmiştir. Nesne tespiti tarafında ise RT-DETR ve Deformable DETR modelleri, external validation aşamasında yüksek mAP50 değerlerini koruyarak daha güçlü genelleme performansı göstermiştir. YOLOv8n modeli de Varroa Dataset üzerinde eğitildiğinde external validation aşamasında kabul edilebilir bir sonuç üretmiştir.

Geleneksel makine öğrenmesi hattında internal ve external sonuçlar arasındaki fark, classification ve detection görevlerinde farklı biçimde ortaya çıkmıştır. Patch-level classification aşamasında yüksek F1-score değerleri elde edilmesine rağmen, sliding-window tabanlı tam görüntü detection aşamasında performans daha düşük kalmıştır. Bu durum, görüntü bölgesi düzeyinde başarılı olan bir sınıflandırıcının tam görüntü üzerinde konum belirleme görevinde ek zorluklarla karşılaştığını göstermektedir.

Genel olarak internal ve external validation sonuçları arasındaki farklar, bu çalışmada external validation yaklaşımının önemini açık biçimde ortaya koymuştur. Yalnızca internal validation sonuçlarına bakıldığında bazı modeller başarılı görünse de, external validation sonuçları modelin farklı veri kaynaklarına aktarılabilirliğini daha gerçekçi şekilde değerlendirmektedir. Bu nedenle nihai model değerlendirmesinde internal başarı kadar external validation performansı da dikkate alınmalıdır.

9.4. En Başarılı Model veya Model Ailesinin Değerlendirilmesi

Deney sonuçları genel olarak değerlendirildiğinde, en başarılı modelin görev türüne göre değiştiği görülmektedir. Classification ve detection görevleri farklı çıktılar ürettiği için bu modellerin tek bir metrik üzerinden doğrudan karşılaştırılması doğru değildir. Classification modelleri görüntüde Varroa bulunup bulunmadığını tahmin ederken, detection modelleri Varroa parazitinin görüntü üzerindeki konumunu da belirlemektedir. Bu nedenle en başarılı model değerlendirmesi classification ve detection görevleri için ayrı ayrı yapılmıştır.

Classification görevi açısından bakıldığında, geleneksel makine öğrenmesi tabanlı SVM modeli ve CNN tabanlı EfficientNet-B0 modeli güçlü sonuçlar üretmiştir. SVM modeli, Varroa Dataset üzerinde external classification aşamasında F1-score değerini yüksek düzeyde korumuştur. Bu durum, HOG, HSV, LBP ve PCA gibi el yapımı özelliklerin uygun şekilde kullanılması durumunda geleneksel yöntemlerin görüntü bölgesi düzeyinde güçlü bir sınıflandırma başarısı sağlayabildiğini göstermektedir. Bununla birlikte SVM modeli tam görüntü üzerinde doğrudan konum bilgisi üretmediği için, pratik tespit senaryolarında ek sliding-window ve kutu birleştirme adımlarına ihtiyaç duymaktadır.

CNN tabanlı classification modelleri içinde EfficientNet-B0 modeli, özellikle Varroa Dataset üzerinde eğitildiğinde external validation aşamasında güçlü bir genelleme performansı göstermiştir. EfficientNet-B0 modelinin external F1-score değerini yüksek seviyede koruması, bu modelin görüntü düzeyinde Varroa var/yok kararının verilmesi gereken senaryolarda başarılı bir alternatif olduğunu göstermektedir. ResNet18 modeli de benzer şekilde güçlü sonuçlar üretmiş olsa da EfficientNet-B0 modeli external validation aşamasındaki dengeli performansı ile CNN tabanlı classification modelleri arasında öne çıkmıştır.

Detection görevi açısından en güçlü sonuçlar transformer tabanlı modellerde elde edilmiştir. Özellikle RT-DETR ve Deformable DETR modelleri external validation aşamasında yüksek mAP50 değerlerini koruyarak diğer detection modellerine göre daha güçlü bir genelleme performansı sunmuştur. RT-DETR modeli Varroa Dataset üzerinde external mAP50 = 0.7120 değerine ulaşmış, HoneyBee VarroaMite üzerinde eğitildiğinde de external mAP50 = 0.6780 sonucunu koruyabilmiştir. Bu sonuçlar, RT-DETR modelinin farklı veri kaynaklarına karşı daha dengeli ve dayanıklı bir detection performansı sunduğunu göstermektedir.

Deformable DETR modeli de Varroa Dataset üzerinde external validation aşamasında mAP50 = 0.6980 değerine ulaşarak güçlü bir sonuç üretmiştir. Bu modelin çok ölçekli dikkat mekanizması, küçük nesne karakteri taşıyan Varroa parazitinin tespitinde önemli bir avantaj sağlamıştır. Standart DETR modeline kıyasla Deformable DETR ve RT-DETR modellerinin daha başarılı olması, transformer tabanlı nesne tespitinde model

mimarisindeki geliřtirmelerin küçük nesne tespiti açısından kritik olduğunu göstermektedir.

YOLO tabanlı modeller içerisinde en başarılı sonuç YOLOv8n modelinin Varroa Dataset üzerinde eğitildiğı durumda elde edilmiştir. YOLOv8n modeli external validation aşamasında mAP50 = 0.6290 değerine ulaşarak CNN tabanlı detection modelleri arasında en güçlü sonucu vermiştir. YOLOv26n modeli de Varroa Dataset üzerinde kabul edilebilir bir external sonuç üretmiş olsa da YOLOv8n modeli daha yüksek external mAP50 değeriyle öne çıkmıştır. Buna karşılık HoneyBee VarroaMite üzerinde eğitilen YOLO modellerinde external validation performansının ciddi biçimde düşmesi, YOLO modellerinin veri seti dağılımı ve anotasyon farklılıklarından güçlü biçimde etkilenebildiğini göstermektedir.

Genel değerlendirme sonucunda, görüntü düzeyinde Varroa var/yok kararı verilmesi gereken classification senaryolarında SVM ve EfficientNet-B0 modelleri güçlü alternatifler olarak öne çıkmaktadır. Ancak Varroa parazitinin görüntü üzerindeki konumunun belirlenmesi gereken nesne tespiti senaryolarında RT-DETR modeli en başarılı model olarak değerlendirilebilir. RT-DETR, hem yüksek external mAP50 değerleri üretmiş hem de farklı veri setlerinde performansını daha dengeli biçimde korumuştur. Bu nedenle proje hedefi yalnızca sınıflandırma değil, aynı zamanda konum belirleme olduğu için genel kullanım açısından en güçlü model ailesinin transformer tabanlı detection modelleri olduğu söylenebilir.

9.5. Deney Sonuçlarının Proje Hedefleri Açısından Yorumlanması

Bu projenin temel hedefi, bal arısı kolonilerinde ciddi zararlara yol açan Varroa parazitinin görüntü işleme ve yapay zekâ tabanlı yöntemlerle tespit edilmesini sağlamaktır. Bu hedef doğrultusunda farklı model aileleri değerlendirilmiş ve modellerin Varroa tespiti problemindeki uygulanabilirliği hem classification hem de detection görevleri üzerinden incelenmiştir. Elde edilen sonuçlar, projenin yalnızca tek bir model geliştirme çalışması olmadığını, aynı zamanda farklı yapay zekâ yaklaşımlarının bu problem üzerindeki güçlü ve sınırlı yönlerini karşılaştıran bir deneysel analiz sunduğunu göstermektedir.

Classification modelleri, görüntüde Varroa paraziti bulunup bulunmadığını belirlemek açısından başarılı sonuçlar üretmiştir. SVM, ResNet18 ve EfficientNet-B0 gibi modeller özellikle Varroa var/yok kararının verilmesi gereken senaryolarda kullanılabilir görünmektedir. Bu tür modeller, hızlı bir ön tarama veya karar destek sistemi için uygun olabilir. Ancak classification modelleri görüntü üzerinde Varroa parazitinin konumunu göstermediğı için, yalnızca parazit varlığı bilgisinin yeterli olduğu durumlarda daha anlamlıdır.

Nesne tespiti modelleri ise proje hedefi açısından daha açıklayıcı çıktılar üretmektedir. YOLO, Deformable DETR ve RT-DETR gibi modeller, görüntüde Varroa bulunup

bulunmadığını belirlemenin yanında parazitin görüntü üzerindeki konumunu bounding box ile gösterebilmektedir. Bu özellik, arıcıların veya uzmanların model çıktısını görsel olarak doğrulayabilmesi açısından önemlidir. Özellikle gerçek uygulama senaryolarında yalnızca “Varroa var” bilgisinden ziyade, parazitin görüntüde nerede bulunduğunun gösterilmesi daha kullanışlı bir çıktı sağlayabilir.

Deney sonuçları, Varroa tespiti probleminin küçük nesne tespiti açısından zorlayıcı bir problem olduğunu ortaya koymuştur. Varroa paraziti görüntü içerisinde çok küçük bir alan kapladığı için, modelin hem hedef nesneyi arka plandan ayırması hem de bounding box konumunu doğru belirlemesi gerekmektedir. Bu nedenle detection modellerinde mAP50-95 değerlerinin mAP50 değerlerine göre daha düşük çıkması beklenen bir durumdur. Küçük nesnelerde bounding box konumundaki küçük sapmalar bile daha katı IoU eşiklerinde performansın belirgin biçimde düşmesine neden olabilmektedir.

External validation sonuçları, projenin gerçekçi uygulanabilirliği açısından en kritik bulgulardan biri olmuştur. Bir modelin kendi veri setinde yüksek başarı göstermesi olumlu bir sonuçtur; ancak gerçek kullanımda model farklı kamera açıları, farklı ışık koşulları, farklı arı pozisyonları ve farklı görüntü kaliteleriyle karşılaşabilir. Bu nedenle external validation aşamasında performansını koruyabilen modeller, proje hedefleri açısından daha güvenilir kabul edilmelidir. Bu bağlamda RT-DETR, Deformable DETR, EfficientNet-B0 ve Varroa Dataset üzerinde eğitilen YOLOv8n modeli güçlü adaylar olarak değerlendirilebilir.

Proje sonuçları, veri seti seçiminin ve etiket kalitesinin model başarısı üzerinde önemli bir etkiye sahip olduğunu da göstermiştir. Bazı modeller kendi veri setlerinde başarılı sonuçlar üretmesine rağmen external validation aşamasında belirgin performans kaybı yaşamıştır. Bu durum, ilerleyen aşamalarda daha çeşitli, daha dengeli ve daha tutarlı etiketlenmiş veri setleriyle çalışmanın model başarısını artırabileceğini göstermektedir. Özellikle farklı görüntüleme koşullarını temsil eden veri setlerinin bir araya getirilmesi, modellerin saha koşullarına daha iyi uyum sağlamasına katkı sağlayacaktır.

Genel olarak deney sonuçları, Varroa tespitinin görüntü işleme ve yapay zekâ tabanlı yöntemlerle gerçekleştirilebileceğini göstermektedir. Classification modelleri hızlı ve düşük maliyetli ön değerlendirme için uygunken, detection modelleri parazitin konumunu belirleyebilmesi nedeniyle proje hedefleriyle daha doğrudan ilişkilidir. Bu nedenle nihai sistem tasarımında, kullanım senaryosuna bağlı olarak classification ve detection yaklaşımlarının birlikte veya ayrı ayrı değerlendirilmesi mümkündür. Elde edilen bulgular, sürdürülebilir arıcılık uygulamaları için görüntü tabanlı, temassız ve otomatik Varroa tespit sistemlerinin geliştirilebileceğine yönelik önemli bir temel oluşturmaktadır.

10.SONUÇ VE GELECEK ÇALIŞMALAR

Bu bölümde, proje kapsamında gerçekleştirilen deneysel çalışmaların genel sonucu, elde edilen kazanımlar, projenin mevcut durumu ve sonraki aşamada yapılması planlanan çalışmalar özetlenmiştir. Çalışma boyunca geleneksel makine öğrenmesi, CNN tabanlı modeller, YOLO tabanlı nesne tespiti modelleri ve Transformer tabanlı yaklaşımlar Varroa parazitinin tespiti problemi üzerinde değerlendirilmiştir.

10.1. Çalışmanın Genel Sonucu

Bu çalışmada, bal arısı kolonileri için ciddi bir tehdit oluşturan Varroa destructor parazitinin görüntü işleme ve yapay zekâ tabanlı yöntemlerle tespit edilmesine yönelik kapsamlı bir deneysel süreç yürütülmüştür. Proje kapsamında farklı veri setleri, farklı ön işleme yaklaşımları ve farklı model aileleri kullanılarak Varroa tespiti problemi hem classification hem de object detection bakış açısıyla ele alınmıştır.

Elde edilen sonuçlar, Varroa tespitinin görüntü tabanlı yöntemlerle gerçekleştirilebileceğini göstermektedir. Classification modelleri, görüntüde Varroa bulunup bulunmadığını belirleme açısından başarılı sonuçlar üretmiştir. SVM, ResNet18 ve EfficientNet-B0 gibi modeller, özellikle Varroa var/yok kararının verilmesi gereken durumlarda kullanılabilir yaklaşımlar sunmuştur. Bununla birlikte bu modeller doğrudan konum bilgisi üretmediği için, Varroa parazitinin görüntü üzerindeki yerinin belirlenmesi gereken senaryolarda nesne tespiti modelleri daha uygun görülmüştür.

Nesne tespiti modelleri içerisinde YOLO tabanlı modeller, hızlı ve pratik bir tespit yaklaşımı sunarken; Transformer tabanlı RT-DETR ve Deformable DETR modelleri external validation aşamasında güçlü sonuçlar üretmiştir. Özellikle RT-DETR modelinin farklı veri setlerinde daha dengeli external validation performansı göstermesi, Transformer tabanlı nesne tespiti yaklaşımlarının Varroa gibi küçük nesne tespiti problemlerinde güçlü bir potansiyel taşıdığını ortaya koymuştur.

Çalışmanın genel sonucu olarak, model başarısının yalnızca kullanılan mimariye bağlı olmadığı görülmüştür. Eğitim veri setinin yapısı, sınıf dağılımı, görüntü kalitesi, hedef nesnenin görünürlüğü, anotasyon tutarlılığı ve external validation veri setiyle olan benzerlik model performansını doğrudan etkilemiştir. Bu nedenle Varroa tespiti gibi küçük nesne içeren biyolojik görüntü problemlerinde, model seçimi kadar veri seti kalitesi ve değerlendirme stratejisi de kritik öneme sahiptir.

10.2. Elde Edilen Deneysel Kazanımlar

Bu proje kapsamında farklı model ailelerinin aynı problem üzerinde karşılaştırmalı olarak değerlendirilmesi önemli bir deneysel kazanım sağlamıştır. Geleneksel makine öğrenmesi tabanlı modeller, el yapımı özellikler kullanılarak görüntü bölgesi düzeyinde güçlü classification sonuçları üretmiştir. Bu durum, düşük hesaplama maliyetli ve yorumlanabilir yaklaşımların hâlâ belirli senaryolarda etkili olabileceğini göstermiştir.

CNN tabanlı classification modelleri, transfer learning yaklaşımının Varroa sınıflandırma probleminde kullanılabilir olduğunu ortaya koymuştur. ResNet18 ve EfficientNet-B0 modelleri, görüntü düzeyinde Varroa var/yok tahmini için başarılı sonuçlar üretmiştir. Özellikle EfficientNet-B0 modelinin external validation aşamasında dengeli sonuçlar verebilmesi, bu modelin sınıflandırma odaklı kullanım senaryolarında güçlü bir alternatif olduğunu göstermiştir.

YOLO tabanlı modeller, Varroa parazitinin görüntü üzerindeki konumunu bounding box ile belirleyebilmesi açısından önemli bir katkı sağlamıştır. YOLOv8n ve YOLOv26n modelleri, küçük nesne tespiti problemi için farklı YOLO mimarilerinin davranışını inceleme imkânı sunmuştur. Bu modellerin sonuçları, nesne tespiti performansında eğitim veri setinin external validation veri setine olan benzerliğinin büyük önem taşıdığını göstermiştir.

Transformer tabanlı modeller ise özellikle detection görevi açısından güçlü sonuçlar üretmiştir. DETR, Deformable DETR ve RT-DETR modellerinin değerlendirilmesi, dikkat mekanizmalarına dayalı yaklaşımların Varroa tespiti probleminde uygulanabilir olduğunu göstermiştir. Özellikle RT-DETR ve Deformable DETR modelleri, external validation aşamasında yüksek mAP50 değerleriyle öne çıkmıştır.

Projenin bir diğer önemli kazanımı, internal validation ve external validation ayrımının net biçimde uygulanmasıdır. Bu sayede modellerin yalnızca kendi veri setleri üzerindeki başarıları değil, farklı veri kaynaklarına karşı genelleme performansları da analiz edilmiştir. External validation sonuçları, modelin gerçek kullanım senaryolarına daha yakın performansını değerlendirmek açısından kritik bir gösterge olmuştur.

10.3. Projenin Mevcut Durumu

Projenin mevcut aşamasında, Varroa tespiti problemi için farklı model aileleri üzerinde deneysel çalışmalar tamamlanmış ve elde edilen sonuçlar tablo ve grafiklerle raporlanmıştır. Geleneksel makine öğrenmesi, CNN tabanlı sınıflandırma, YOLO tabanlı nesne tespiti ve Transformer tabanlı nesne tespiti yaklaşımları ayrı ayrı değerlendirilmiştir.

Veri setleri, model ailelerinin ihtiyaçlarına göre hazırlanmış; classification ve detection görevleri için uygun veri yapıları oluşturulmuştur. Varroa Dataset ve HoneyBee VarroaMite veri setleri model geliştirme sürecinde kullanılmış, Varroa Mites Detector veri seti ise external validation amacıyla değerlendirilmiştir. Bu yapı sayesinde modellerin farklı veri kaynaklarına karşı gösterdiği performans sistematik biçimde incelenmiştir.

Deney sonuçlarına göre classification görevinde SVM ve EfficientNet-B0 modelleri güçlü sonuçlar üretmiştir. Detection görevinde ise RT-DETR, Deformable DETR ve Varroa Dataset üzerinde eğitilen YOLOv8n modeli öne çıkmıştır. Bununla birlikte

external validation sonuçları, bazı modellerin kendi veri setlerinde başarılı olmasına rağmen farklı veri dağılımlarında belirgin performans kaybı yaşayabildiğini göstermiştir.

Mevcut durumda proje, farklı model ailelerinin Varroa tespiti problemindeki uygulanabilirliğini karşılaştırmalı olarak ortaya koyan deneysel bir çalışma niteliğindedir. Bu aşamada elde edilen bulgular, ilerleyen süreçte daha kapsamlı veri setleriyle model iyileştirme, saha koşullarına uygun testler ve gerçek zamanlı uygulama geliştirme adımları için temel oluşturmaktadır.

10.4. Sonraki Aşamada Yapılması Planlanan Çalışmalar

Sonraki aşamada öncelikli hedef, veri seti çeşitliliğini artırmak ve modellerin daha farklı görüntü koşullarına karşı dayanıklı hale gelmesini sağlamaktır. Bu kapsamda farklı kamera açıları, farklı ışık koşulları, farklı arı pozisyonları ve farklı çözünürlüklerde görüntüler içeren daha geniş veri setleriyle çalışılması planlanmaktadır. Veri seti çeşitliliğinin artırılması, modellerin external validation performansını ve gerçek kullanım senaryolarındaki güvenilirliğini yükseltebilir.

Bir diğer önemli çalışma alanı, etiket kalitesinin ve anotasyon tutarlılığının artırılmasıdır. Varroa paraziti görüntü içerisinde küçük bir nesne olduğu için bounding box etiketlerindeki küçük hatalar bile model performansını etkileyebilmektedir. Bu nedenle ilerleyen aşamada etiketlerin daha dikkatli kontrol edilmesi, tutarsız anotasyonların temizlenmesi ve gerekirse uzman doğrulamasıyla daha güvenilir bir etiket yapısı oluşturulması hedeflenmektedir.

Model geliştirme açısından, external validation aşamasında güçlü sonuçlar üreten RT-DETR, Deformable DETR, EfficientNet-B0 ve YOLOv8n modelleri üzerinde daha ayrıntılı iyileştirme çalışmaları yapılabilir. Bu modeller için hiperparametre optimizasyonu, veri artırma stratejileri, farklı görüntü boyutları ve model ensemble yaklaşımları değerlendirilebilir. Özellikle küçük nesne tespiti başarısını artırmaya yönelik attention mekanizmaları, multi-scale training ve yüksek çözünürlüklü giriş stratejileri ilerleyen çalışmalarda incelenebilir.

Projenin sonraki aşamalarında gerçek zamanlı veya yarı gerçek zamanlı bir uygulama altyapısı geliştirilmesi de hedeflenebilir. Bu kapsamda eğitilen modellerin web tabanlı bir arayüz, mobil uygulama veya kovan izleme sistemiyle entegre edilmesi değerlendirilebilir. Böyle bir sistem, arıcıların yüklediği veya kamera aracılığıyla elde edilen görüntüler üzerinde otomatik Varroa tespiti yaparak karar destek mekanizması sağlayabilir.

Son olarak, geliştirilen modellerin saha koşullarında test edilmesi projenin uygulanabilirliği açısından önemli bir adımdır. Kontrollü veri setleri üzerinde elde edilen sonuçlar değerli olsa da gerçek kovan ortamında ışık, hareket, arka plan

karmaşıklığı ve görüntü kalitesi değişkenlik gösterebilir. Bu nedenle gelecekte modellerin gerçek arıcılık ortamlarında toplanan yeni görüntüler üzerinde test edilmesi, sistemin pratik kullanım potansiyelini daha net ortaya koyacaktır.

11.KAYNAKÇA

- [1] T.-N. Le, D.-T. Nguyen, T.-T.-H. Phan, Q.-D. Pham ve T.-L. Le, "Detection of Varroa Mites from Bee Images Using YOLO Architecture," *2025 International Conference on Multimedia Analysis and Pattern Recognition (MAPR)*, 2025. [Çevrimiçi]. Erişilebilir: <https://doi.org/10.1109/MAPR67746.2025.11133726>
- [2] K. Bjerger, C. E. Frigaard, P. H. Mikkelsen, T. H. Nielsen, M. Misbiih ve P. Kryger, "A computer vision system to monitor the infestation level of Varroa destructor in a honeybee colony," *Computers and Electronics in Agriculture*, c. 164, s. 104898, Eylül 2019. [Çevrimiçi]. Erişilebilir: <https://doi.org/10.1016/j.compag.2019.104898>
- [3] M. C. Marcillo, J. R. P. Carrión, A. L. G. Martínez ve diğerleri, "An AI-Based Open-Source Software for Varroa Mite Fall Analysis in Honeybee Colonies," *Agriculture*, c. 15, sayı 9, s. 969, 2025. [Çevrimiçi]. Erişilebilir: <https://doi.org/10.3390/agriculture15090969>
- [4] S. Sevin, H. Tutun ve S. Mutlu, "Detection of Varroa mites from honey bee hives by smart technology Var-Gor: a hivemonitoring and image processing device," *Turkish Journal of Veterinary & Animal Sciences*, c. 45, sayı 3, s. 487-491, 2021. [Çevrimiçi]. Erişilebilir: <https://journals.tubitak.gov.tr/veterinary/vol45/iss3/14>
- [5] M. Liu, M. Cui, B. Xu ve diğerleri, "Detection of Varroa destructor Infestation of Honeybees Based on Segmentation and Object Detection Convolutional Neural Networks," *AgriEngineering*, c. 5, sayı 4, s. 1644-1662, 2023. [Çevrimiçi]. Erişilebilir: <https://www.mdpi.com/2624-7402/5/4/102>
- [6] S. Bilik, L. Kratochvila, A. Ligocki ve diğerleri, "Visual diagnosis of the Varroa destructor parasitic mite in honeybees using object detector techniques," *arXiv preprint arXiv:2103.03133*, 2021. [Çevrimiçi]. Erişilebilir: <https://arxiv.org/abs/2103.03133>
- [7] A. Ghezal ve A. König, "A Comparative Study of Hybrid Machine-Learning vs. Deep-Learning Approaches for Varroa Mite Detection and Counting," *Sensors*, c. 25, sayı 16, s. 5075, 2025. [Çevrimiçi]. Erişilebilir: <https://www.mdpi.com/1424-8220/25/16/5075>
- [8] G. Voudiotis, A. Moraiti ve S. Kontogiannis, "Deep Learning Beehive Monitoring System for Early Detection of the Varroa Mite," *Signals*, c. 3, sayı 3, s. 506-523, 2022. [Çevrimiçi]. Erişilebilir: <https://www.mdpi.com/2624-6120/3/3/30>

- [9] T.-S. Su, C.-C. Wu, T.-Y. Lin ve C.-H. Liu, "Beehive-entrance imaging and deep learning for real-time monitoring of Varroa destructor in apiculture," *Journal of Invertebrate Pathology*, c. 214, s. 108465, 2026. [Çevrimiçi]. Erişilebilir: <https://www.sciencedirect.com/science/article/pii/S0022201125001995>
- [10] Varroa-j8231, "Varroa Dataset," *Roboflow Universe*, 2026. [Çevrimiçi]. Erişilebilir: <https://universe.roboflow.com/varroa-j8231/varroa-bxxhd>
- [11] Honeybee, "HoneyBee VarroaMite Dataset," *Roboflow Universe*, 2026. [Çevrimiçi]. Erişilebilir: https://universe.roboflow.com/honeybee/honeybee_varroamite
- [12] Varroa Virus Detection, "Varroa Mites Detector Dataset," *Roboflow Universe*, 2026. [Çevrimiçi]. Erişilebilir: <https://universe.roboflow.com/varroa-virus-detection/varroa-mites-detector>